

通用视觉框架OpenMMLab

第2讲 图像分类与MMClassification

王若晖

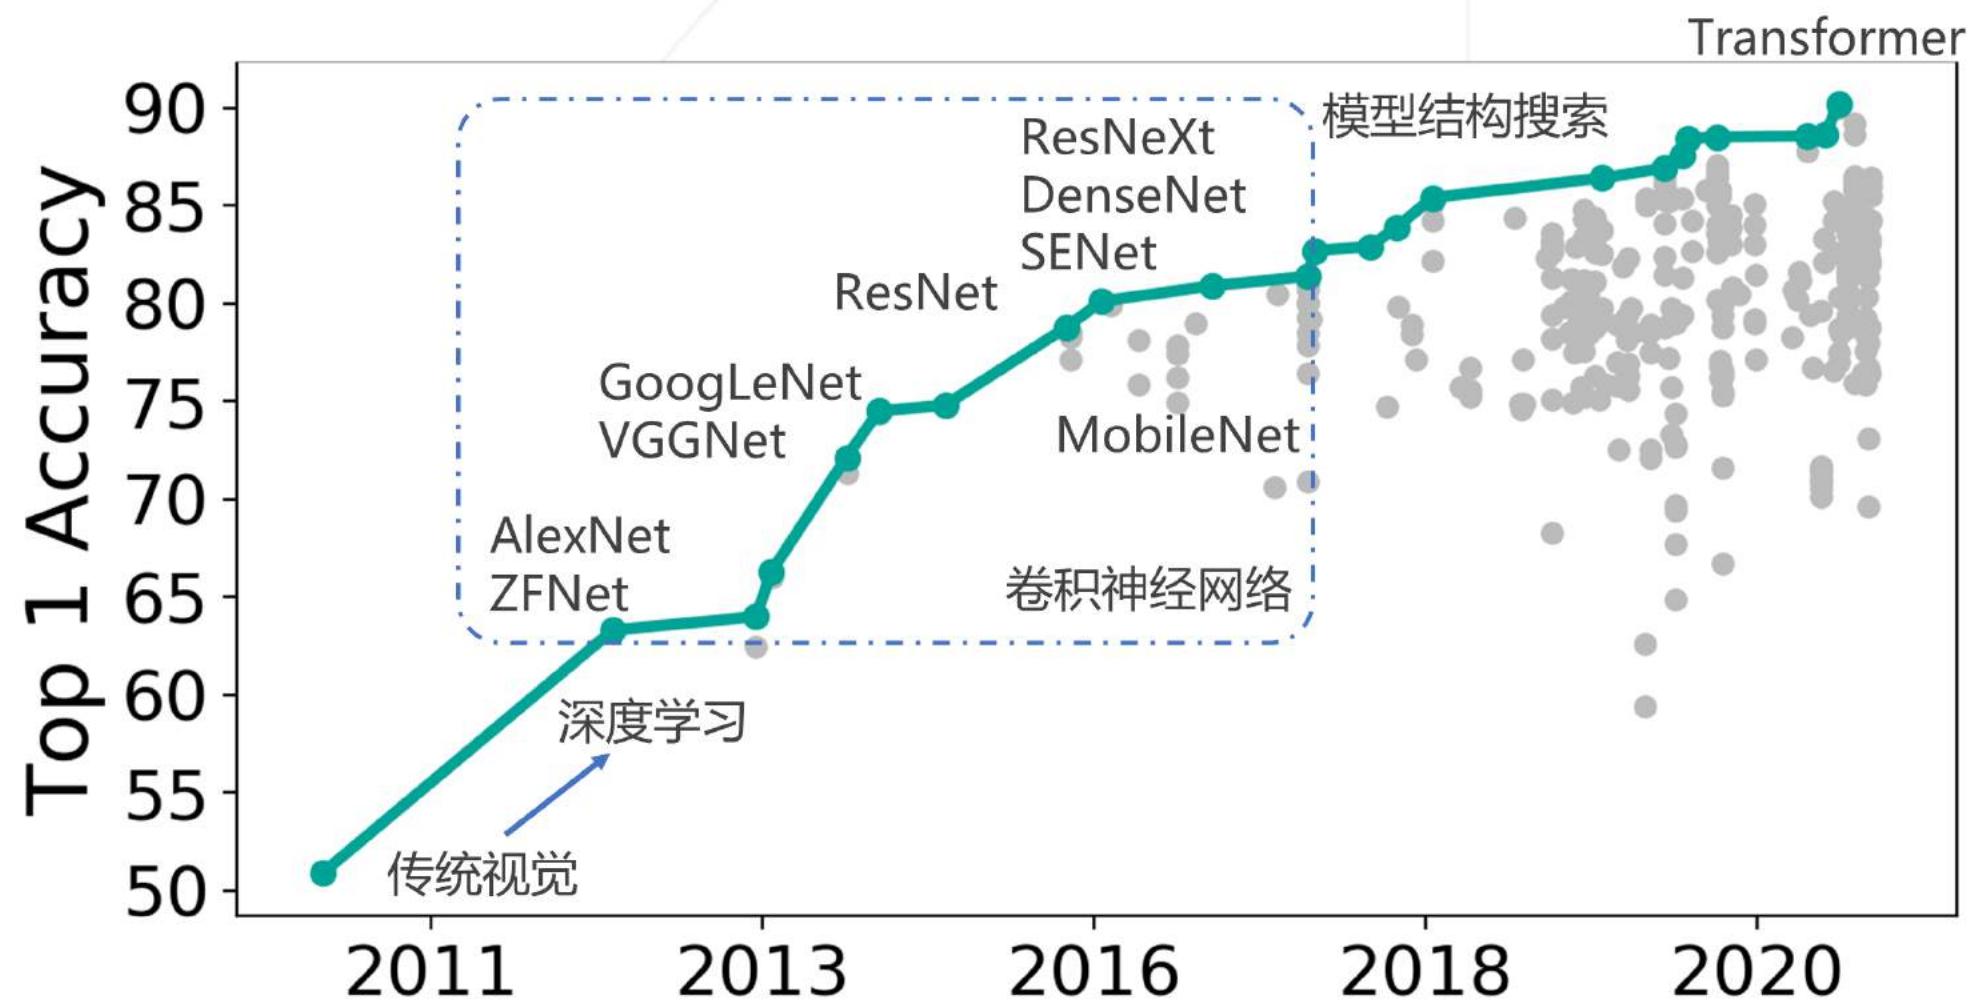
2021 年 4 月

任务目标：

给定一张图片，识别图像中的物体是什么。

pred_label: 954
pred_score: 1.00
pred_class: banana

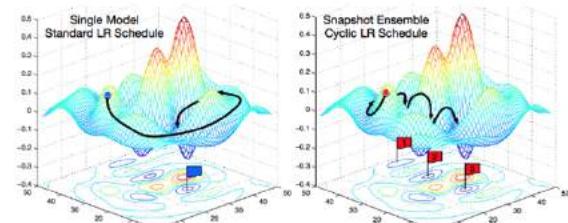
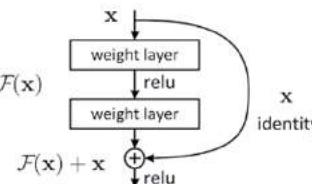
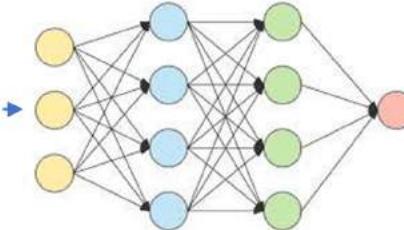
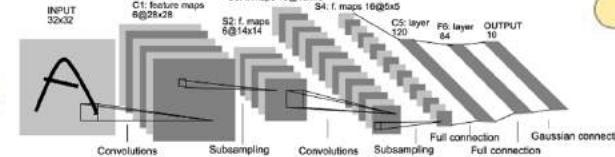




- 机器学习视角下的图像分类
- 多层感知机
- 卷积神经网络
- 图像分类模型设计**
- 图像分类模型训练**
- PyTorch 介绍
- MMClassification 图像分类框架**

$$\mathcal{H} = \{h(x; \theta) \mid \theta \in \Theta\}$$

$$h^* = \underset{h \in \mathcal{H}}{\operatorname{argmin}} \mathcal{L}(h | \mathcal{D})$$



PYTORCH

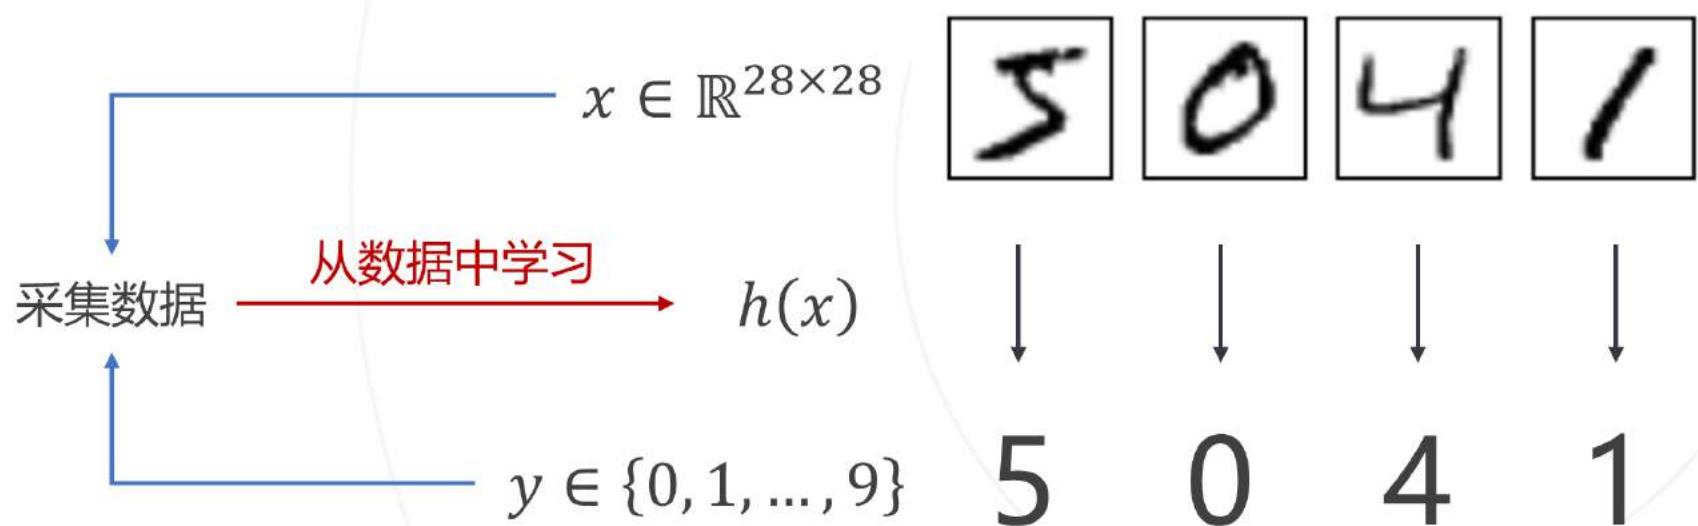
MMClassification

机器学习视角下的图像分类

- 从数据集 $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$ 中学习一个分类函数

$$y = h(x) \text{ 或 } P(y|x) = h(x)$$

- 其中, $x \in \mathbb{R}^N$ 为输入模型的数据, $y \in \mathcal{Y}$ 为模型预测的类别, $P(y|x)$ 为模型预测数据属于不同类别的概率。 $h(x)$ 也称为**分类器**。



1. 构建函数族 \mathcal{H} 包含全部可能的分类器函数 $h(x)$

- 例：线性分类器 $\mathcal{H} = \{\sigma(\theta^T x + \theta_0) \mid \theta \in \mathbb{R}^N, \theta_0 \in \mathbb{R}\}$
- 例：神经网络 $\mathcal{H} = \{\sigma(\theta_2^T \sigma(\theta_1^T x + \theta_{10}) + \theta_{20}) \mid \theta_1 \in \mathbb{R}^{N \times M}, \theta_2 \in \mathbb{R}^M, \theta_{10}, \theta_{20} \in \mathbb{R}\}$
- 例：参数化函数族 $\mathcal{H} = \{h(x; \theta) \mid \theta \in \Theta\}$, 对于每一个 θ , $h(x; \theta)$ 是一个分类器

2. 在 \mathcal{H} 中搜索最好的分类器

- 怎么描述 “好” -> 错误率越低越好 -> 损失函数=错误率
- 怎么找到这个最好的 -> 调整 θ 降低损失函数 -> 最优化问题

1. 函数族 $\mathcal{H} = \{h(x; \theta) \mid \theta \in \Theta\}$ 应该是什么样的?

- (确定结构的) 卷积神经网络

2. 怎么衡量分类模型的好坏?

- 交叉熵损失函数

3. 怎么在 \mathcal{H} 中搜索最佳模型?

- 随机梯度下降为主
- 各种经验策略辅助

目标：寻找损失函数曲面 $L(\theta)$ 的谷点

Step 1：随机选取找一个起始点 $\theta^{(0)}$

Step 2：寻找下降最快的方向，即负梯度

方向 $\nabla_{\theta} L(\theta^{(0)})$ ，并前进一步

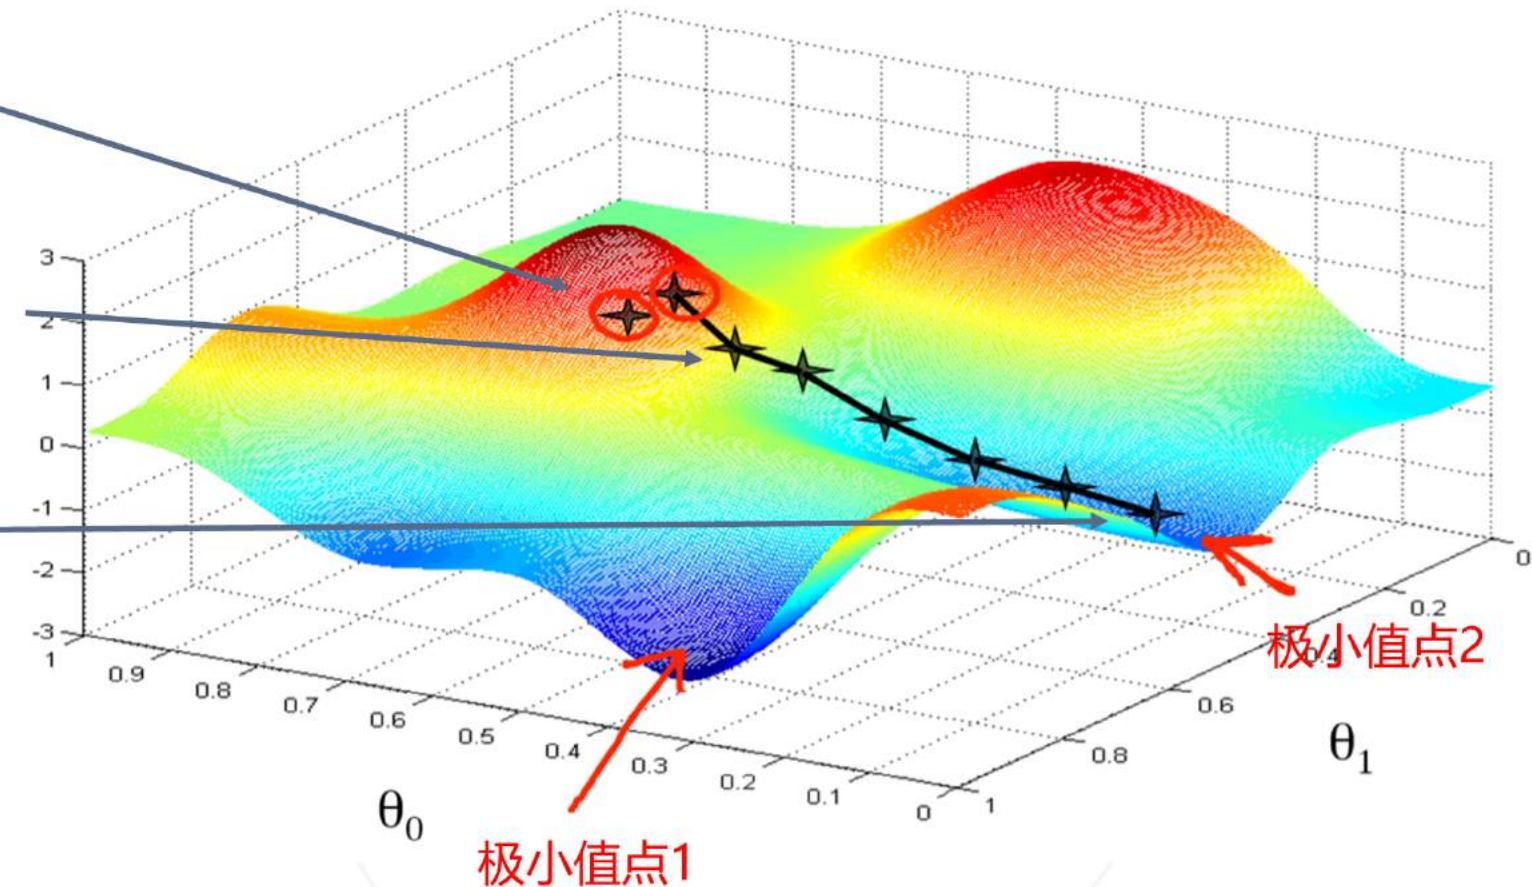
$$\theta^{(1)} = \theta^{(0)} - \eta \nabla_{\theta} L(\theta^{(0)})$$

学习率

Step 3：重复直到不能再下降

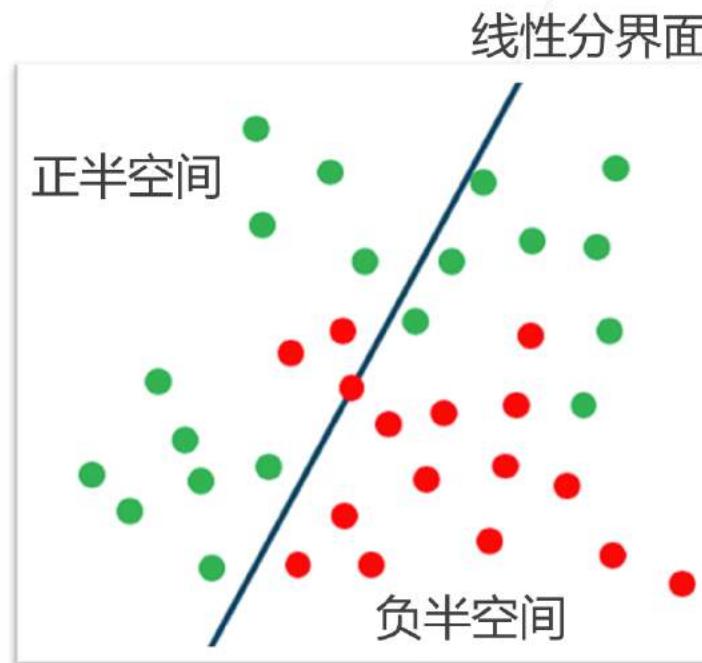
凸函数：保证找到最小值点

非凸函数：不能保证，和起始位置、每步的步长有关系

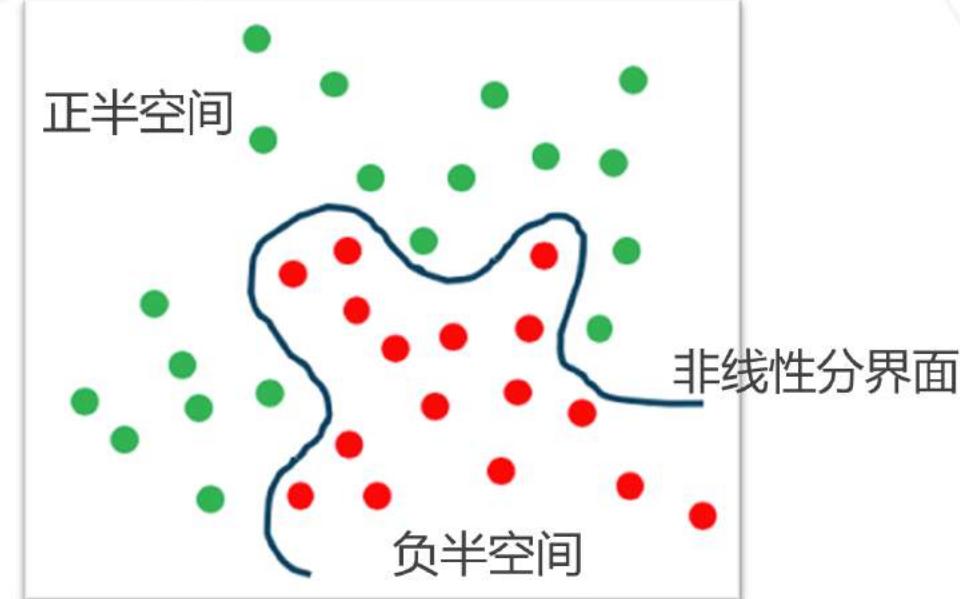


多层感知器

考虑二分类问题：定义正半空间 $\mathcal{X}^+ = \{x | h(x) = 1\}$ ，负半空间 $\mathcal{X}^- = \{x | h(x) = 0\}$



数据空间 \mathbb{R}^2

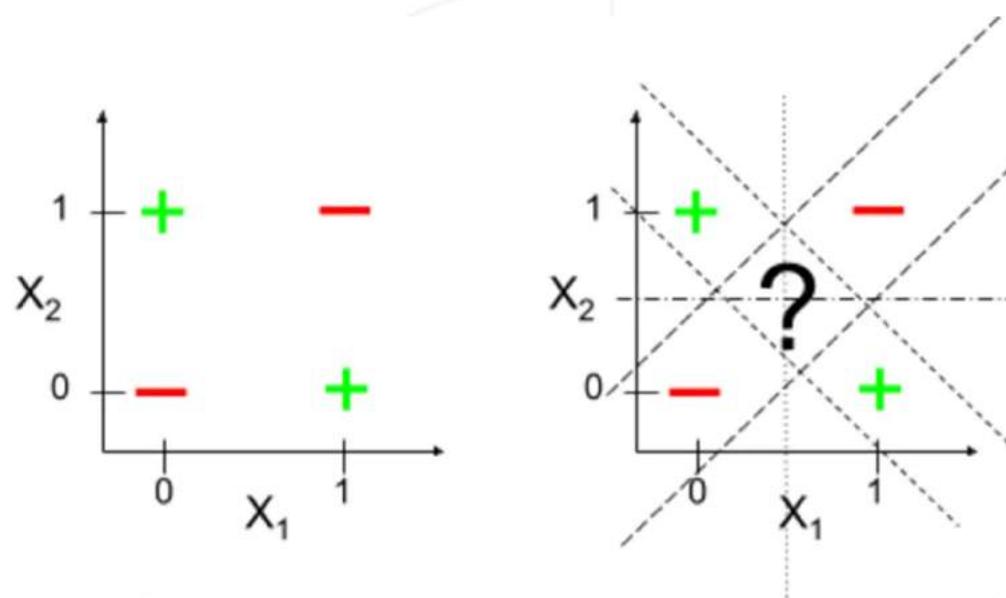


数据空间 \mathbb{R}^2

异或 (XOR) 是一个基本的布尔函数，是线性不可分的。

X_1	X_2	Y
0	0	0
0	1	1
1	0	1
1	1	0

XOR 的真值表

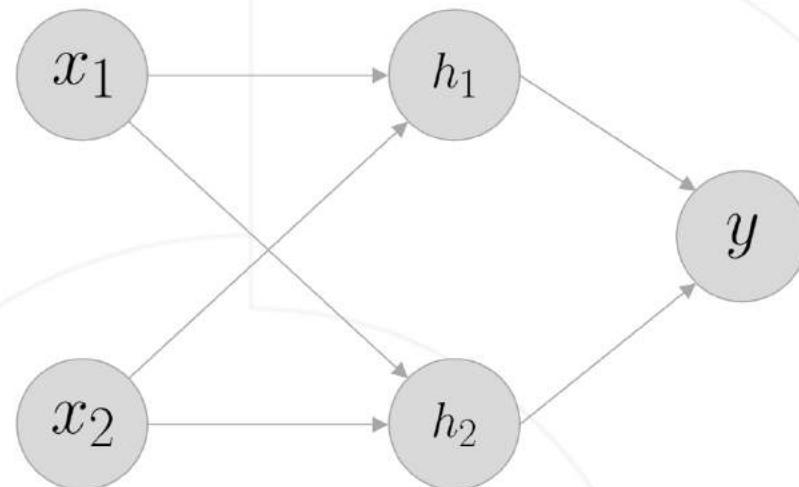


XOR 是线性不可分的

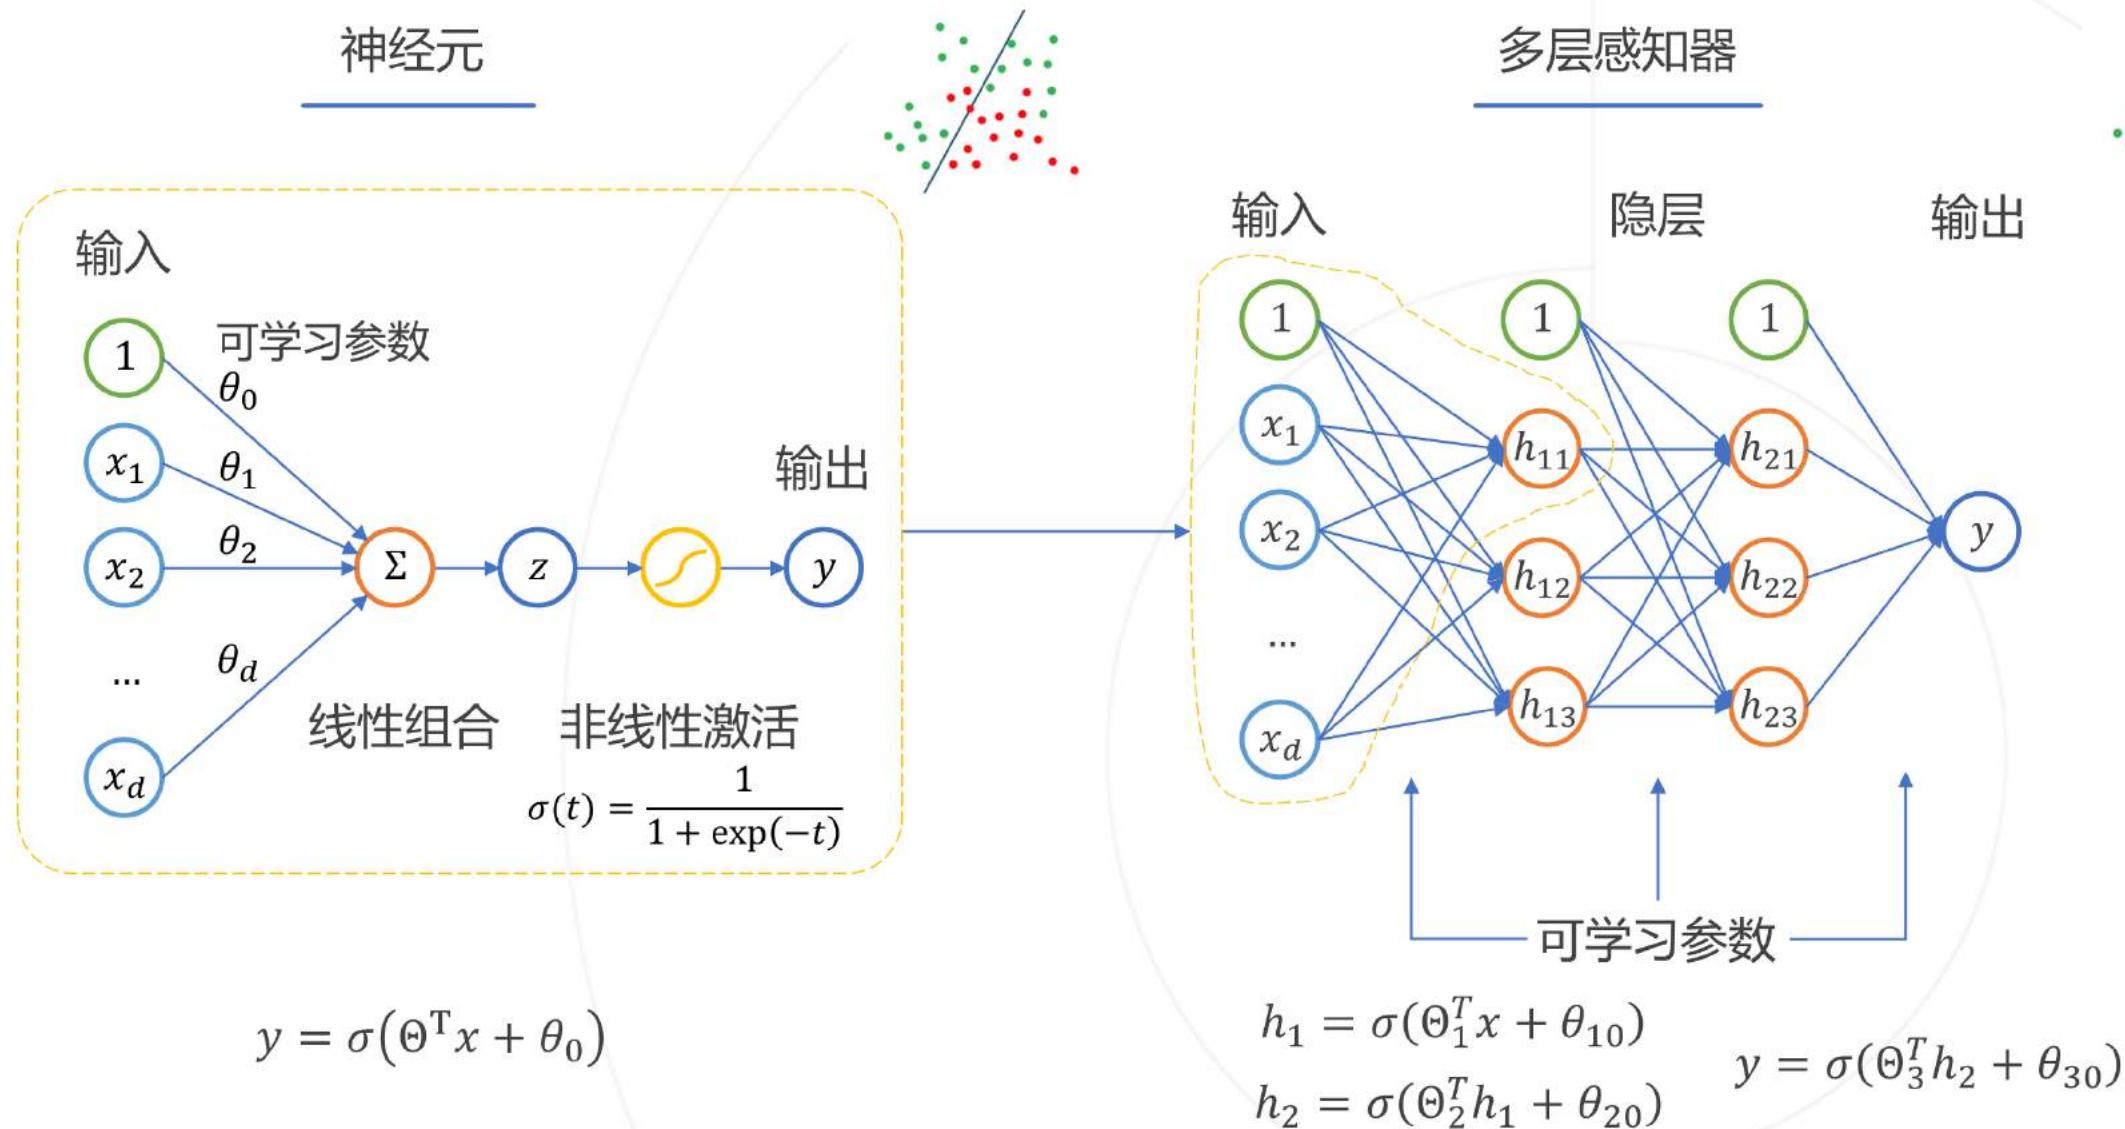
异或函数可以由一个两层的计算图所表达：

第一层由输入 x_1, x_2 到隐变量 h_1, h_2

第二层由由 h_1, h_2 到输出 y 。

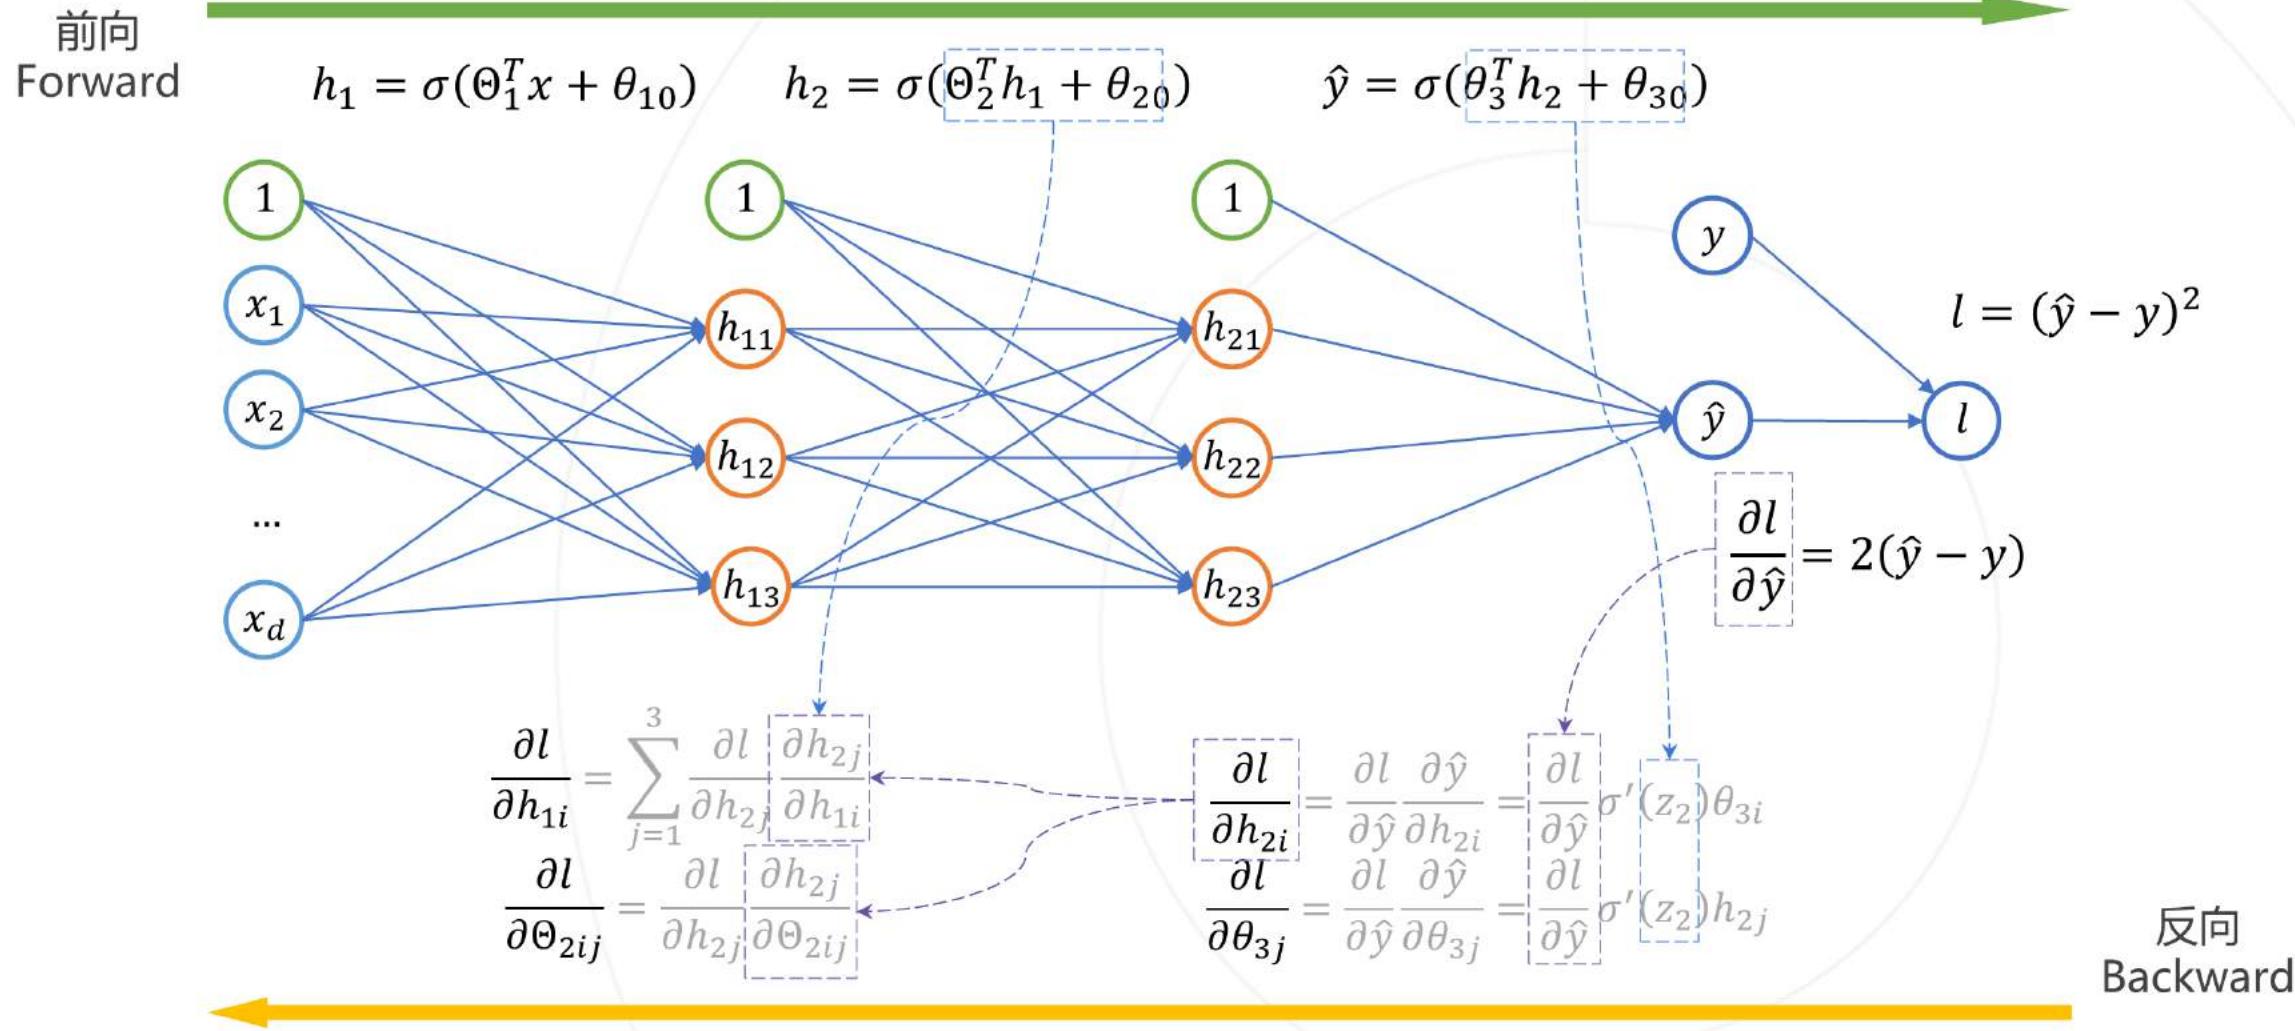


x_1	x_2	$x_1 - x_2$	$x_2 - x_1$	$h_1 = a(x_1 - x_2)$	$h_2 = a(x_2 - x_1)$	$y = h_1 + h_2$
0	0	0	0	0	0	0
0	1	-1	1	0	1	1
1	0	1	-1	1	0	1
1	1	0	0	0	0	0



1. 确定结构（层数、每层单元数）的多层感知器构成了一个分类器族 \mathcal{H} ，不同的连接权重对应了族内不同的分类器
 2. 基于梯度下降寻找最优参数，进而得到最优（准确率最高）的网络
- 如何计算损失函数对于网络参数的梯度？ \rightarrow 反向传播算法

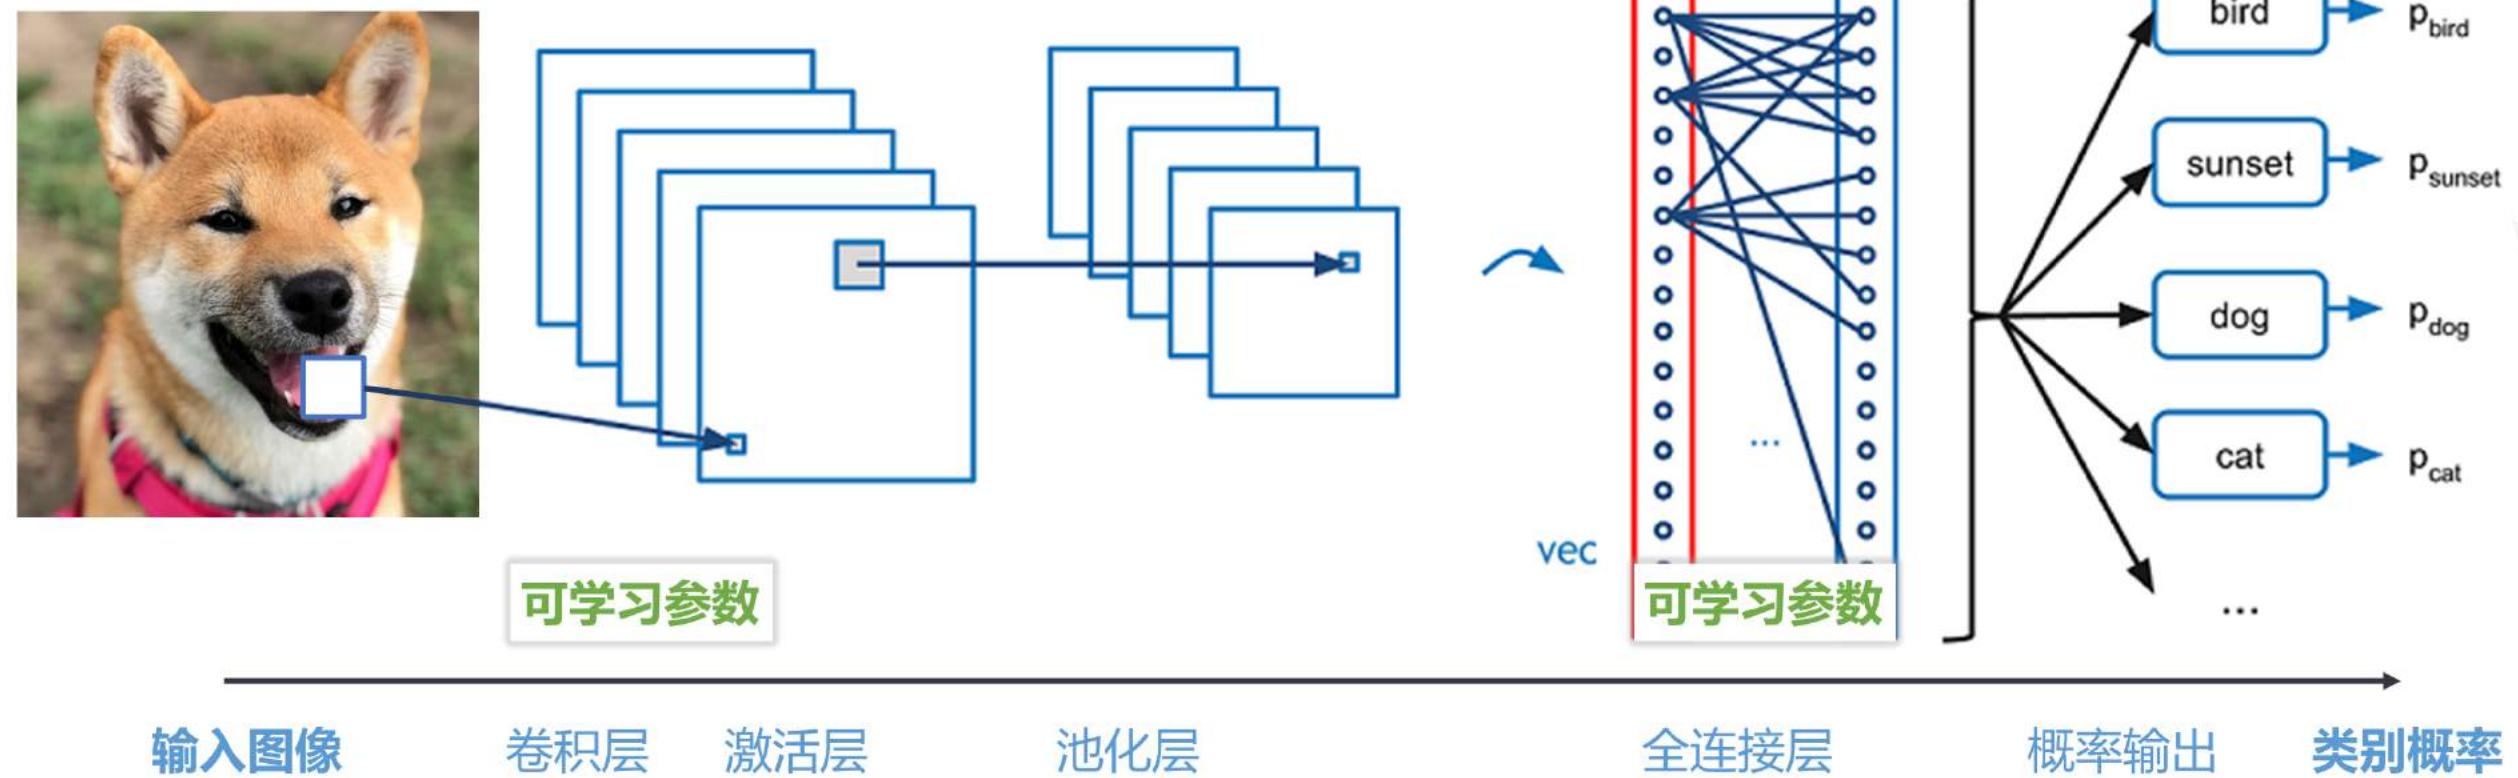
➤ 目标：计算损失函数 l 对于所有隐层参数 Θ 的梯度



- 在神经元数目足够的情况下，单隐层的神经网络可以逼近任意连续函数 (1990s~2000s)
- 所需的神经元的数目随数据维度指数级增长
- 图像分类 \neq 拟合**任意复杂**的分类函数
- 从实用角度讲，需要根据图像的特点设计更高效的模型

卷积神经网络

卷积神经网络的整体结构



输入图像

卷积层

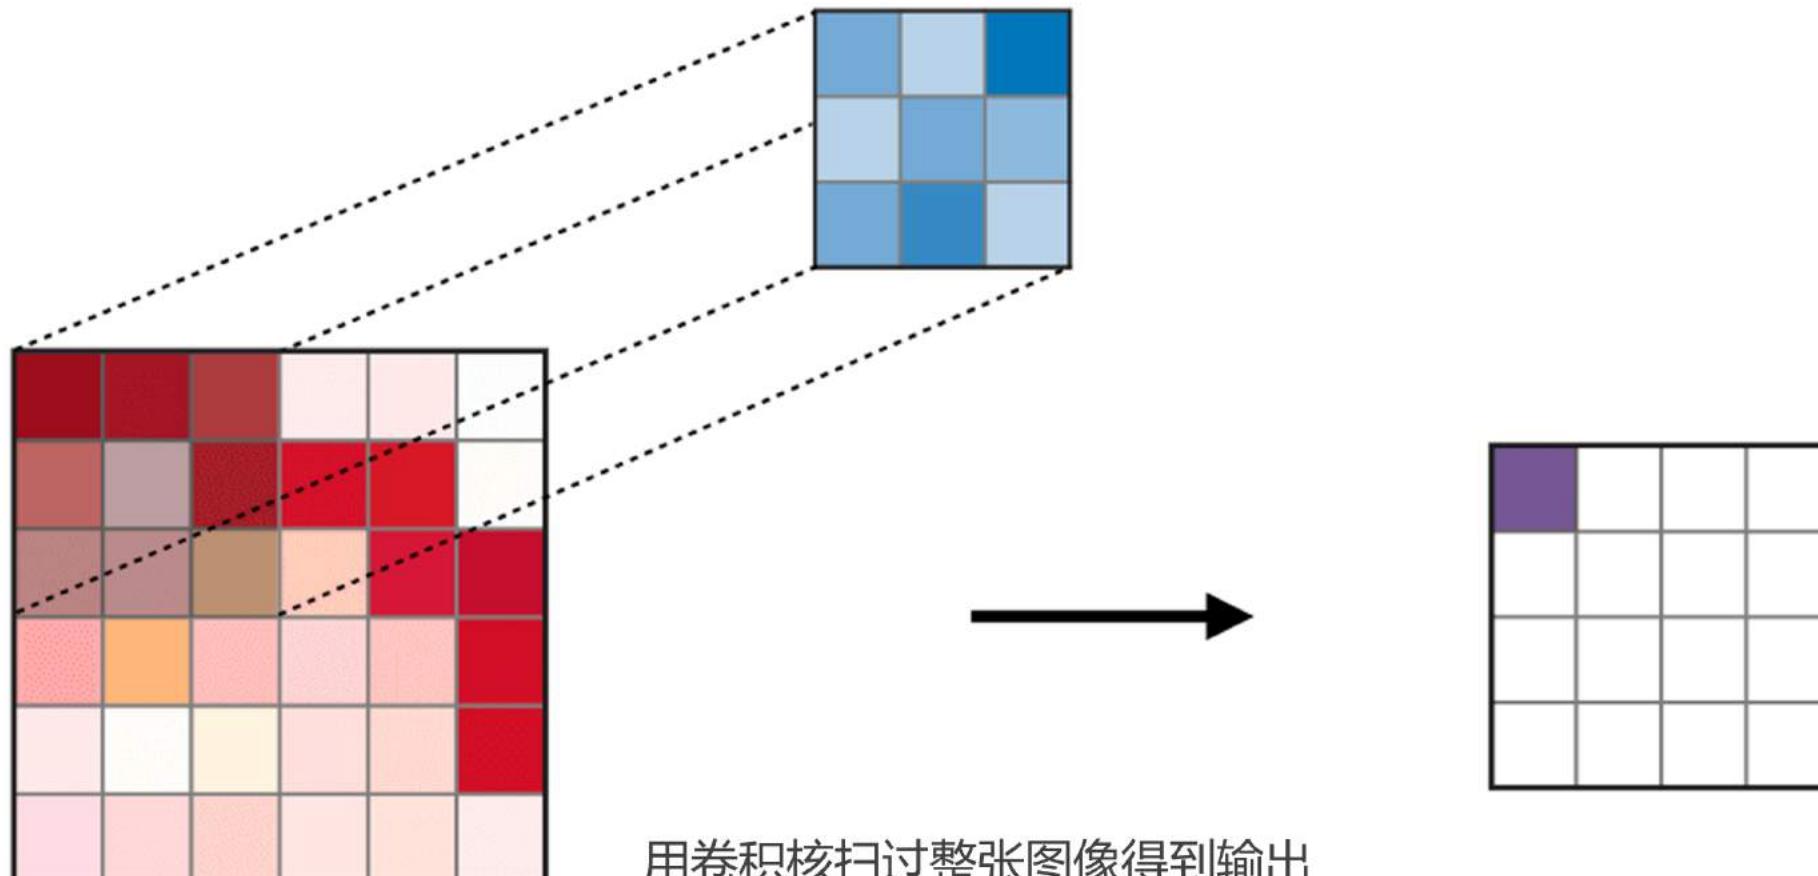
激活层

池化层

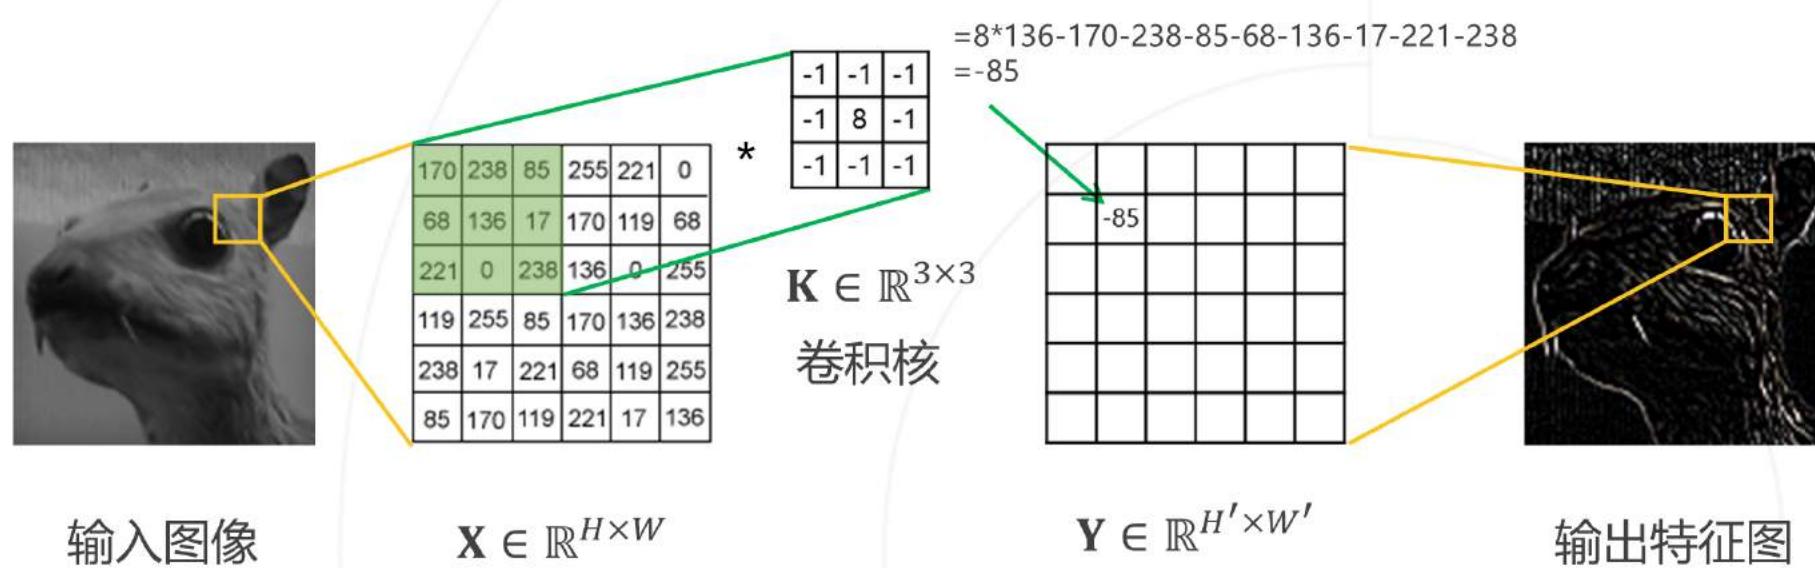
全连接层

概率输出

类别概率

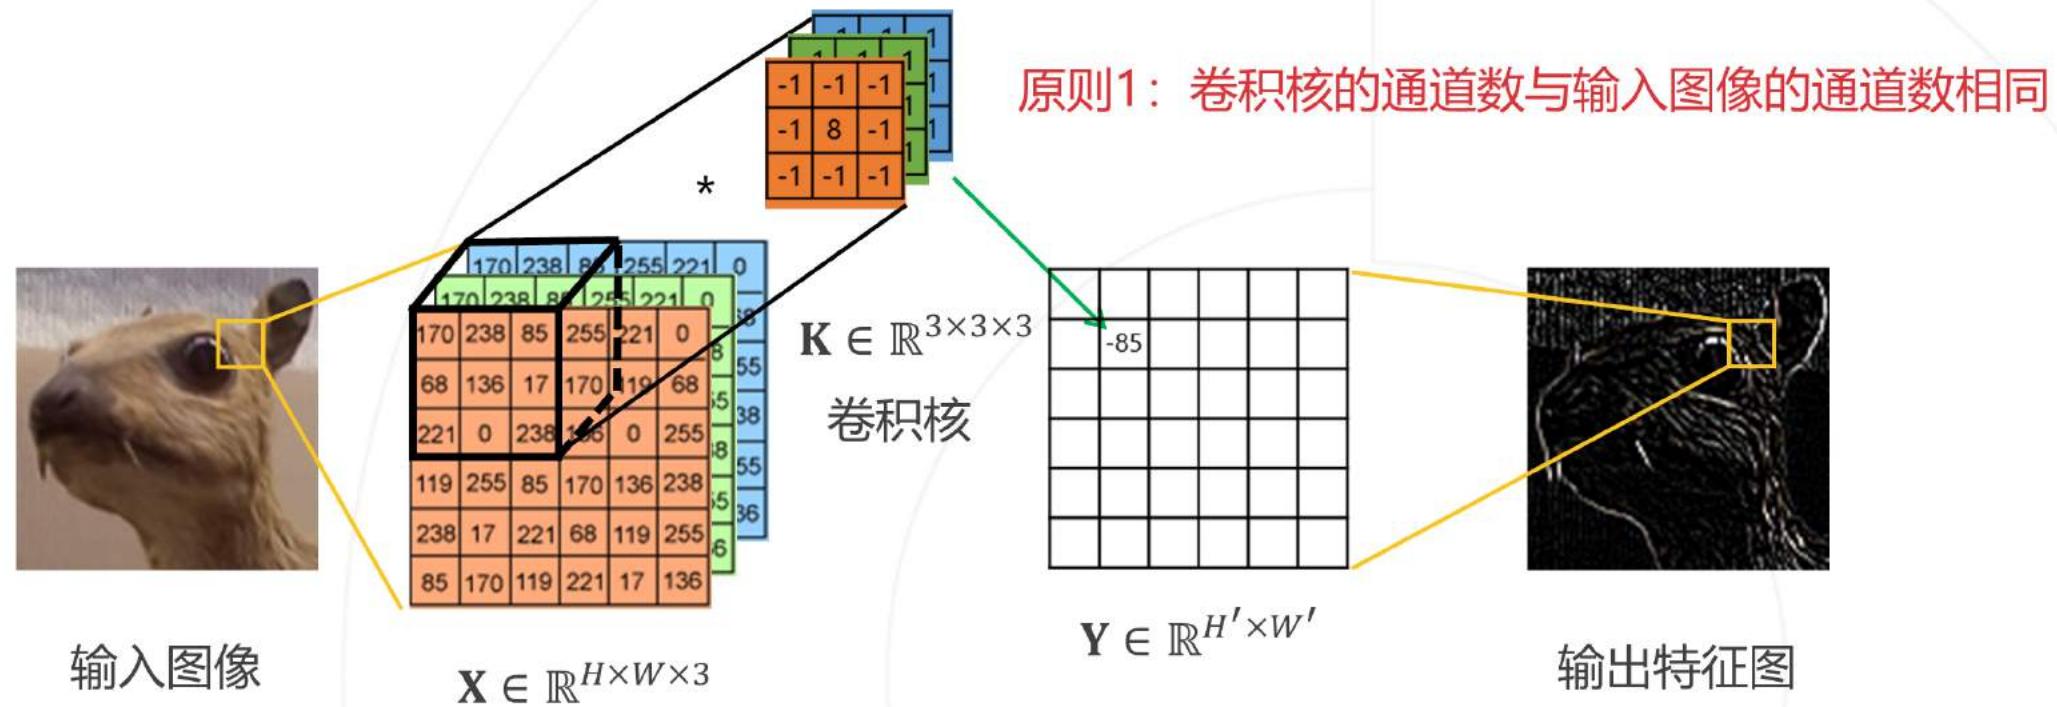


$$Y[h, w] = \sum_{i=-1}^1 \sum_{j=-1}^1 X[h + i, w + j] K[i, j]$$

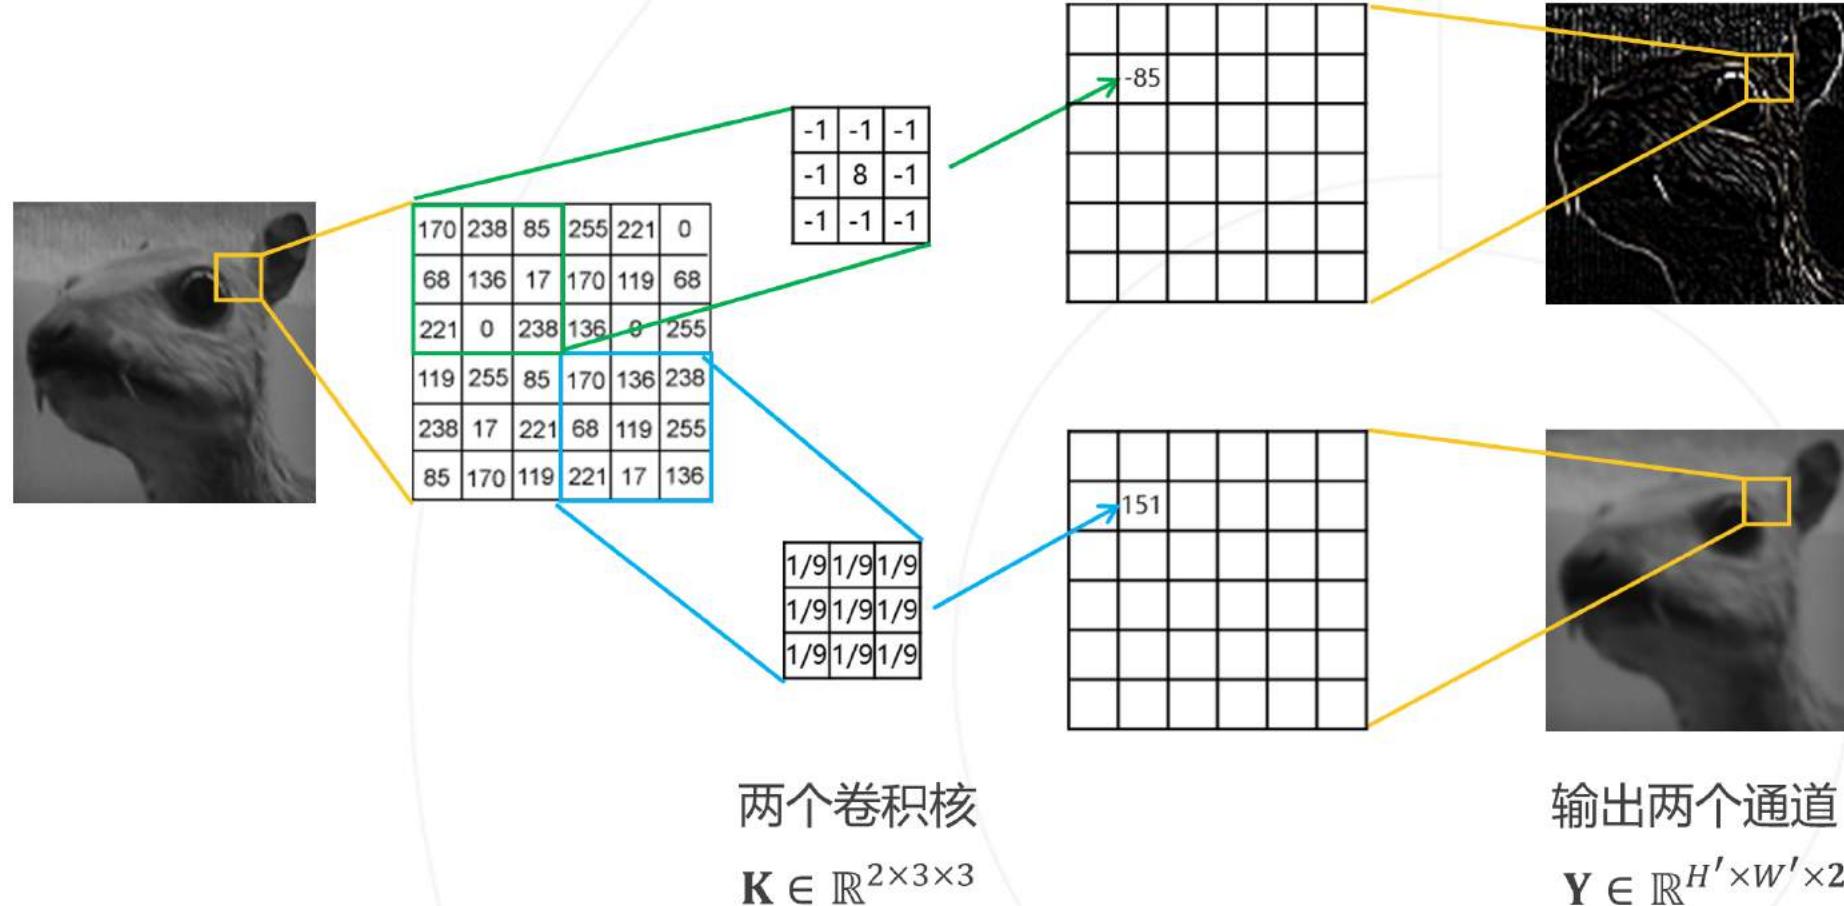


用卷积核扫过整张图像得到输出

$$\mathbf{Y}[h, w] = \sum_{i=-1}^1 \sum_{j=-1}^1 \mathbf{X}[h + i, w + j] \mathbf{K}[i, j]$$



$$Y[h, w] = \sum_{i=-1}^1 \sum_{j=-1}^1 \sum_{k=1}^3 X[h + i, w + j, k] K[i, j, k]$$

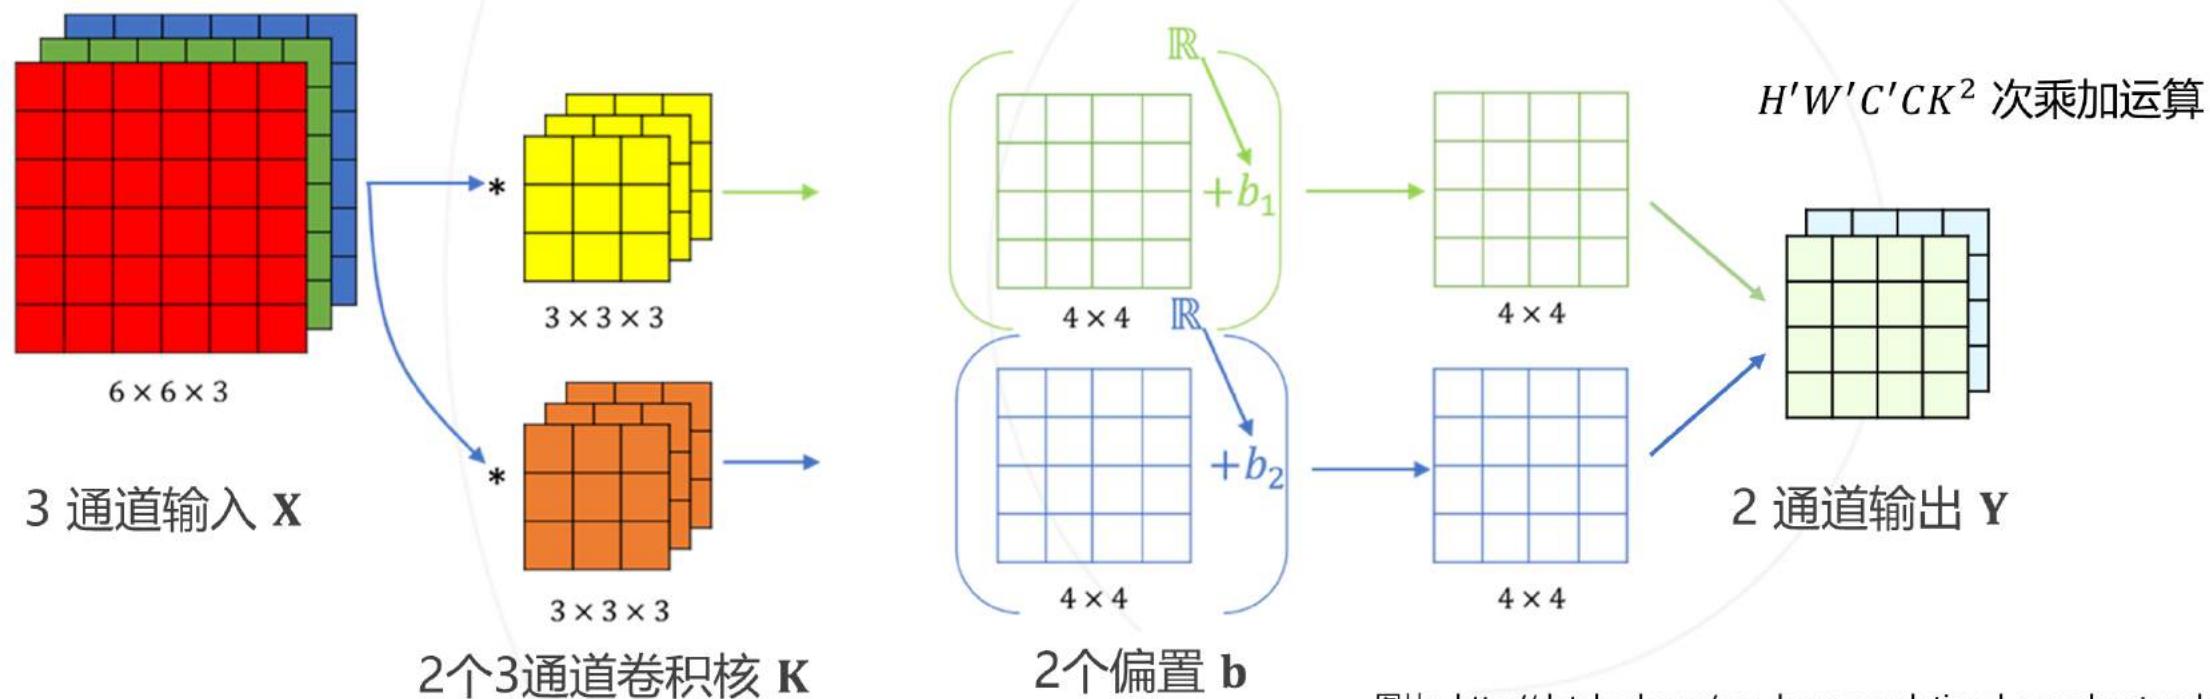


原则2：输出特征图的通道数与卷积核的个数相同

卷积层通过卷积运算，将 C 通道的特征图 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ 变换为 C' 通道的特征图 $\mathbf{Y} \in \mathbb{R}^{H' \times W' \times C'}$ ，计算公式为：

$$\mathbf{Y}[h, w, c] = \sum_{i=1}^K \sum_{j=1}^K \sum_{k=1}^C \mathbf{X}[h+i, w+j, k] \mathbf{K}_c[i, j, k] + \mathbf{b}[c]$$

其中， $\mathbf{K} \in \mathbb{R}^{C' \times K \times K \times C}$ 为 C' 个 C 通道的卷积核， $\mathbf{b} \in \mathbb{R}^{C'}$ 为每个输出通道对应的偏置，二者均为可学习的参数。



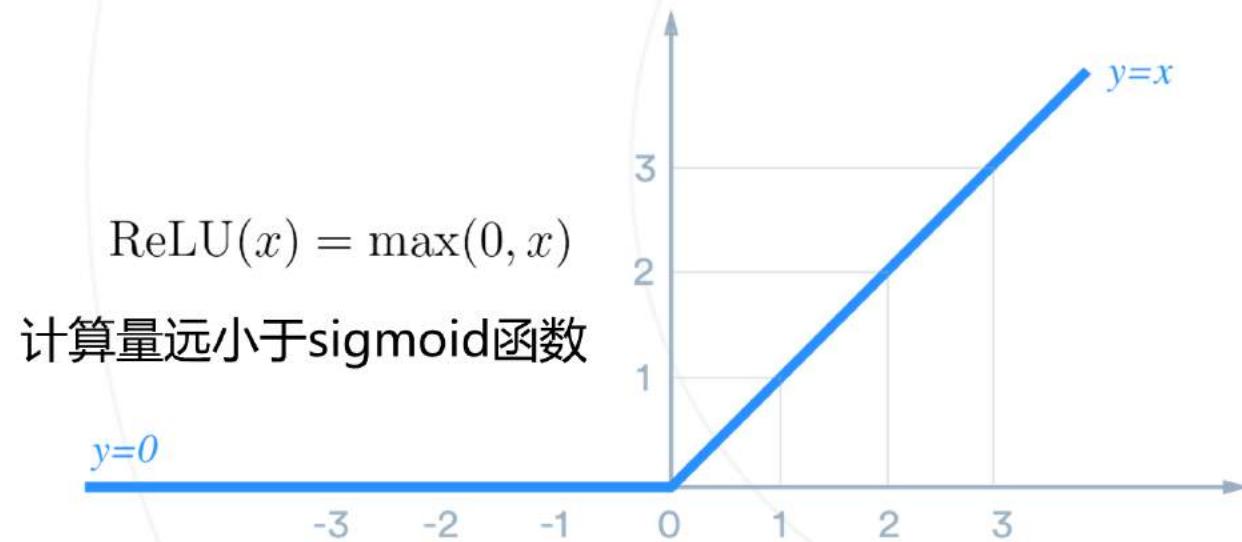
```
# Functional API

```

- 激活层基于一个非线性函数 $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 对输入特征图 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ 进行逐元素的变换：

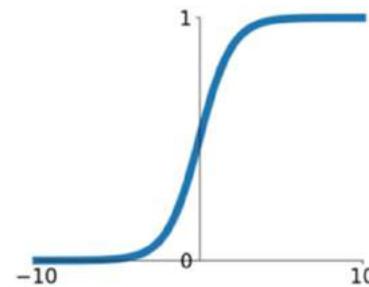
$$\mathbf{Y}[h, w, c] = \sigma(\mathbf{X}[h, w, c])$$

- 激活层通常不包含可学习参数。
- ReLU (Rectified Linear Unit) 是卷积网络中最常用的非线性激活函数。



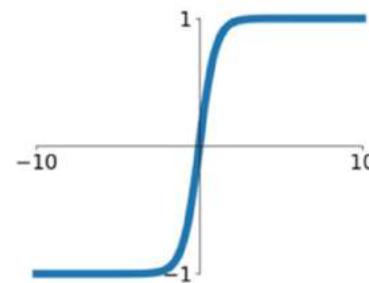
Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



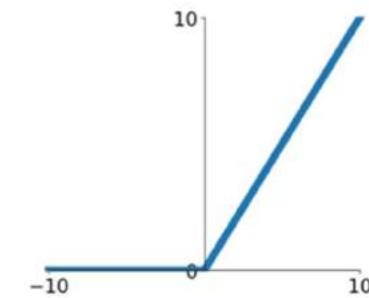
tanh

$$\tanh(x)$$



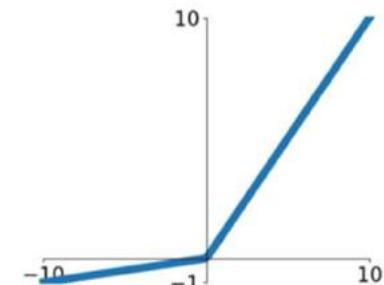
ReLU

$$\max(0, x)$$



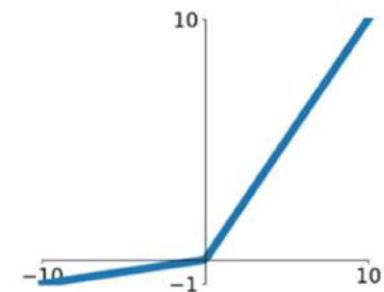
Leaky ReLU

$$\max(0.1x, x)$$



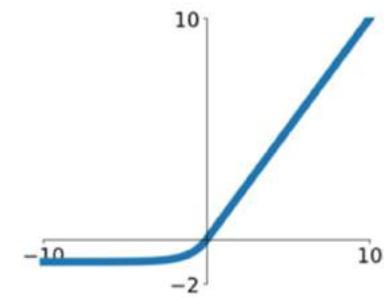
PReLU

$$\max(ax, x)$$



ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



```
x = torch.randn(3, 3)
```

```
# Functional API
```

```
y = F.relu(x)
```

```
# Class API
```

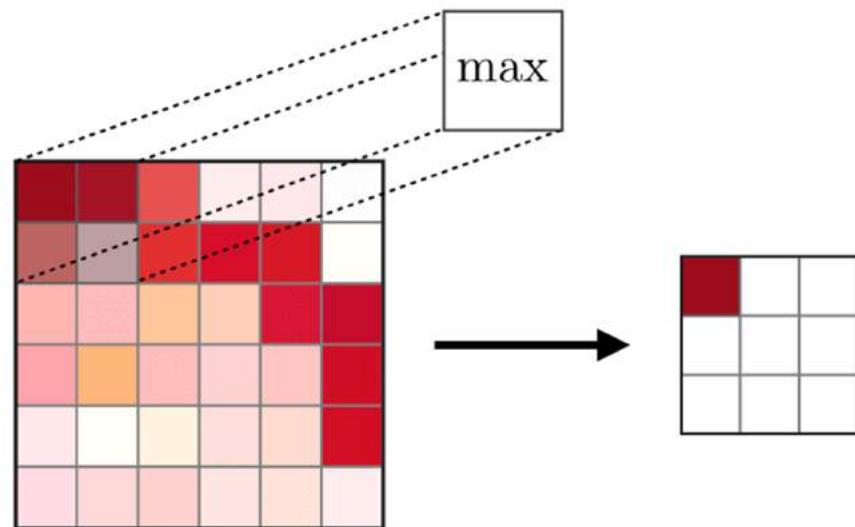
```
relu = nn.ReLU()
```

```
y = relu(x)
```

池化层在特征图的局部区域内计算最大值或平均值，从而降低特征图分辨率，节省计算量，提高特征的空间鲁棒性。

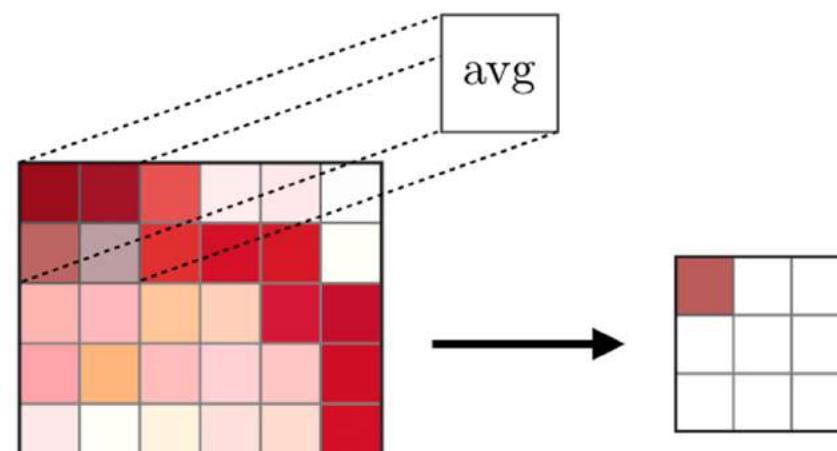
最大池化

$$\mathbf{Y}[h, w, c] = \max_{1 \leq i, j \leq k} \mathbf{X}[sh + i, sw + j, c]$$



平均池化

$$\mathbf{Y}[h, w, c] = \frac{1}{k^2} \sum_{1 \leq i, j \leq k} \mathbf{X}[sh + i, sw + j, c]$$

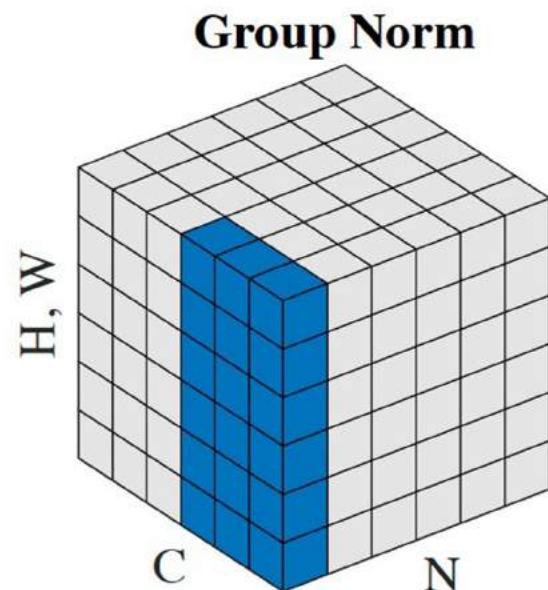
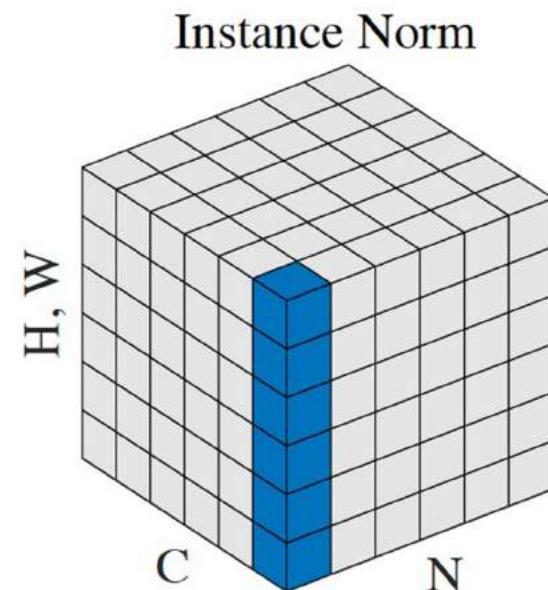
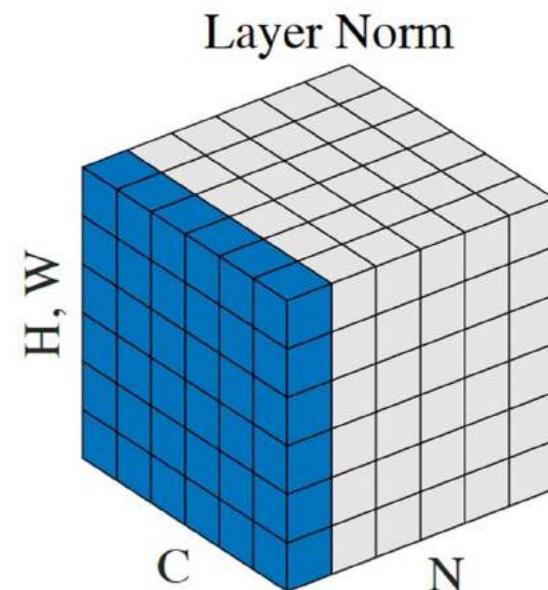
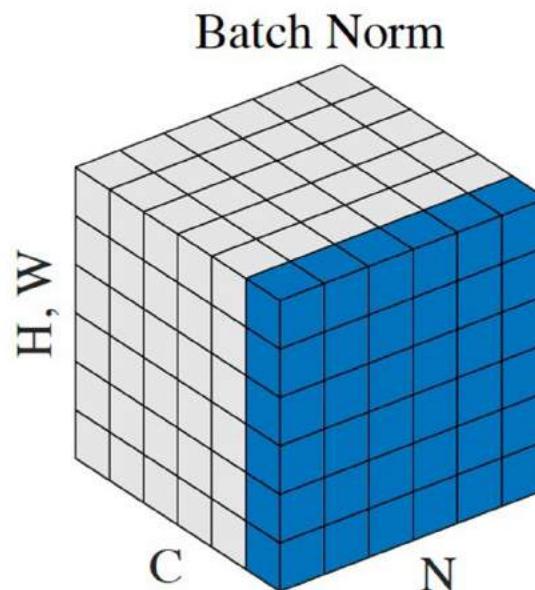


```
x = torch.randn(1, 1, 4, 4)

# Functional API
y = F.max_pool2d(x, kernel_size=2, stride=2)

# Class API
pool = nn.MaxPool2d(kernel_size=(2, 2), stride=2)
y = pool(x)
```

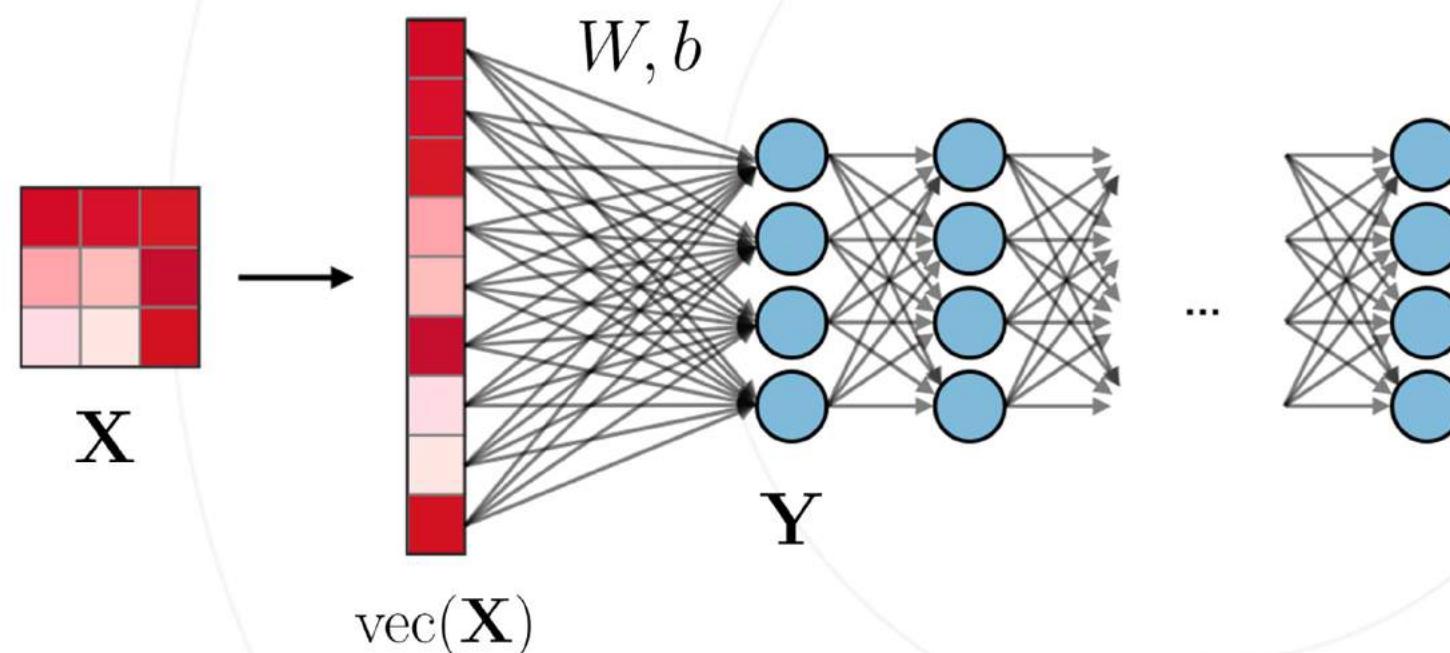
将特征图中的激活值进行归一化处理，例如0均值1方差，降低训练难度。



- 全连接层通过矩阵乘法将输入特征 $\mathbf{X} \in \mathbb{R}^N$ 映射为输出特征 $\mathbf{Y} \in \mathbb{R}^M$

$$\mathbf{Y} = W\mathbf{X} + b \quad \text{或} \quad \mathbf{Y} = W\text{vec}(\mathbf{X}) + b$$

- 全连接层包含可学习参数 $W \in \mathbb{R}^{M \times N}, b \in \mathbb{R}^M$ 。
- 多层感知器中的层就是全连接层。



```
# Vectorize
fmap = torch.randn(1, 2, 2, 2)
x = fmap.view(-1, 8)

# Functional API
weight = torch.randn(6, 8)
bias = torch.randn(6)
y = F.linear(x, weight, bias)

# Class API
linear = nn.Linear(8, 6) # in_features=8, out_features=6
y = linear(x)
```

- 概率输出层 $S: \mathbb{R}^K \rightarrow [0,1]^K$ 将任意特征向量转换为概率概率向量

$$P(y|x) = S(h(x; \Theta))$$

- 二分类，全连接层输出标量 $z \in \mathbb{R}$ ，通过 Sigmoid 函数计算正类的概率

$$P(y = 1|x) = \frac{1}{1 + \exp(-z)}$$

- 多分类，全连接层输出 K 维向量 $z \in \mathbb{R}^K$ ，通过 Softmax 函数计算 K 类的概率

$$P(y = k|x) = \frac{\exp z_k}{\sum_{i=1}^K \exp(z_k)}$$



网络

$$\mathbf{z} = \begin{bmatrix} -0.5 \\ 0.1 \\ 1 \end{bmatrix}$$

$$\mathbf{P} = \begin{bmatrix} 0.14 \\ 0.25 \\ 0.61 \end{bmatrix}$$

```
z = torch.rand(3)
```

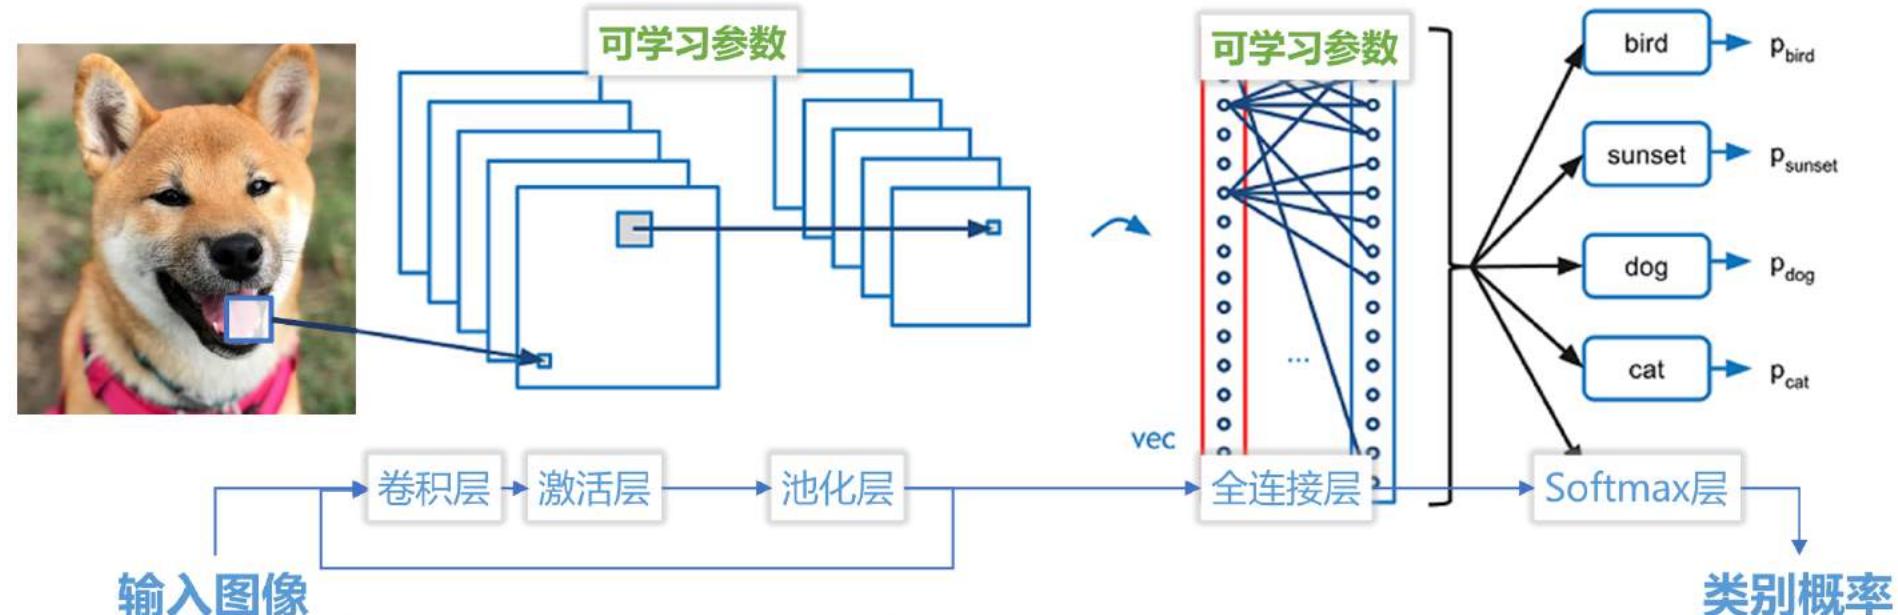
```
# Functional API
```

```
p = F.softmax(z)
```

```
# Class API
```

```
s = nn.Softmax()
```

```
p = s(z)
```



一个端到端学习的分类器 $P(y|x) = h(x; \theta)$

学习一个好的图像特征

视觉任务的初衷

简单的分类器完成分类

稳健表达图像内容，不受像素外观影响

再谈卷积

- 二者都是线性层，实现了输入到输出的线性映射

$$\mathbf{Y}[h, w, c] = \sum_{i=1}^K \sum_{j=1}^K \sum_{k=1}^C \mathbf{X}[h+i, w+j, k] \mathbf{K}_c[i, j, k] + \mathbf{b}[c]$$

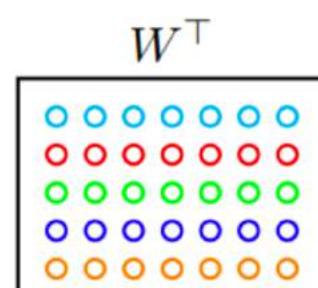
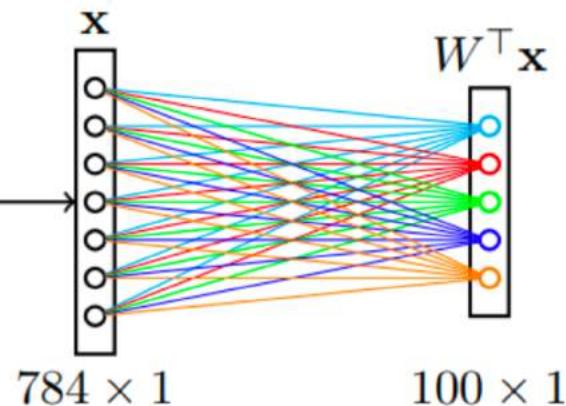
$$\mathbf{Y}[m] = \sum_{i=1}^N W_{mi} \mathbf{X}[i] + b[m]$$

- 卷积层输入输出之间的连接仅存在于局部空间，且连接的权重在不同输出单元之间是共享的。

全连接层：

- 密集连接
- 独立权重

大量冗余参数

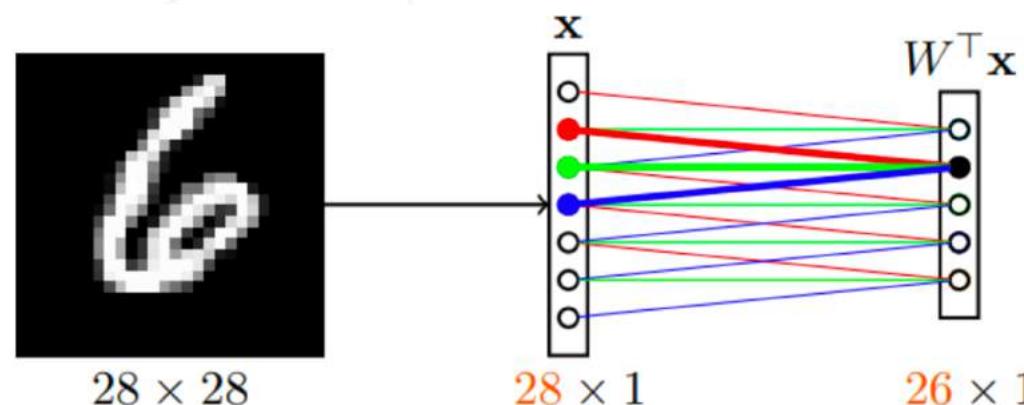


100 × 784

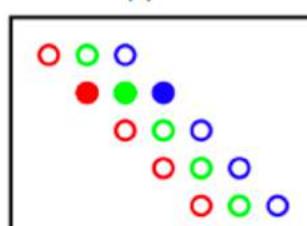
卷积层：

- 局部连接：像素局部相关
- 共享权重：位移不变性

大量节约参数
有效提取图像特征



Weight matrix W^T (为示意方便仅展示一维像素)

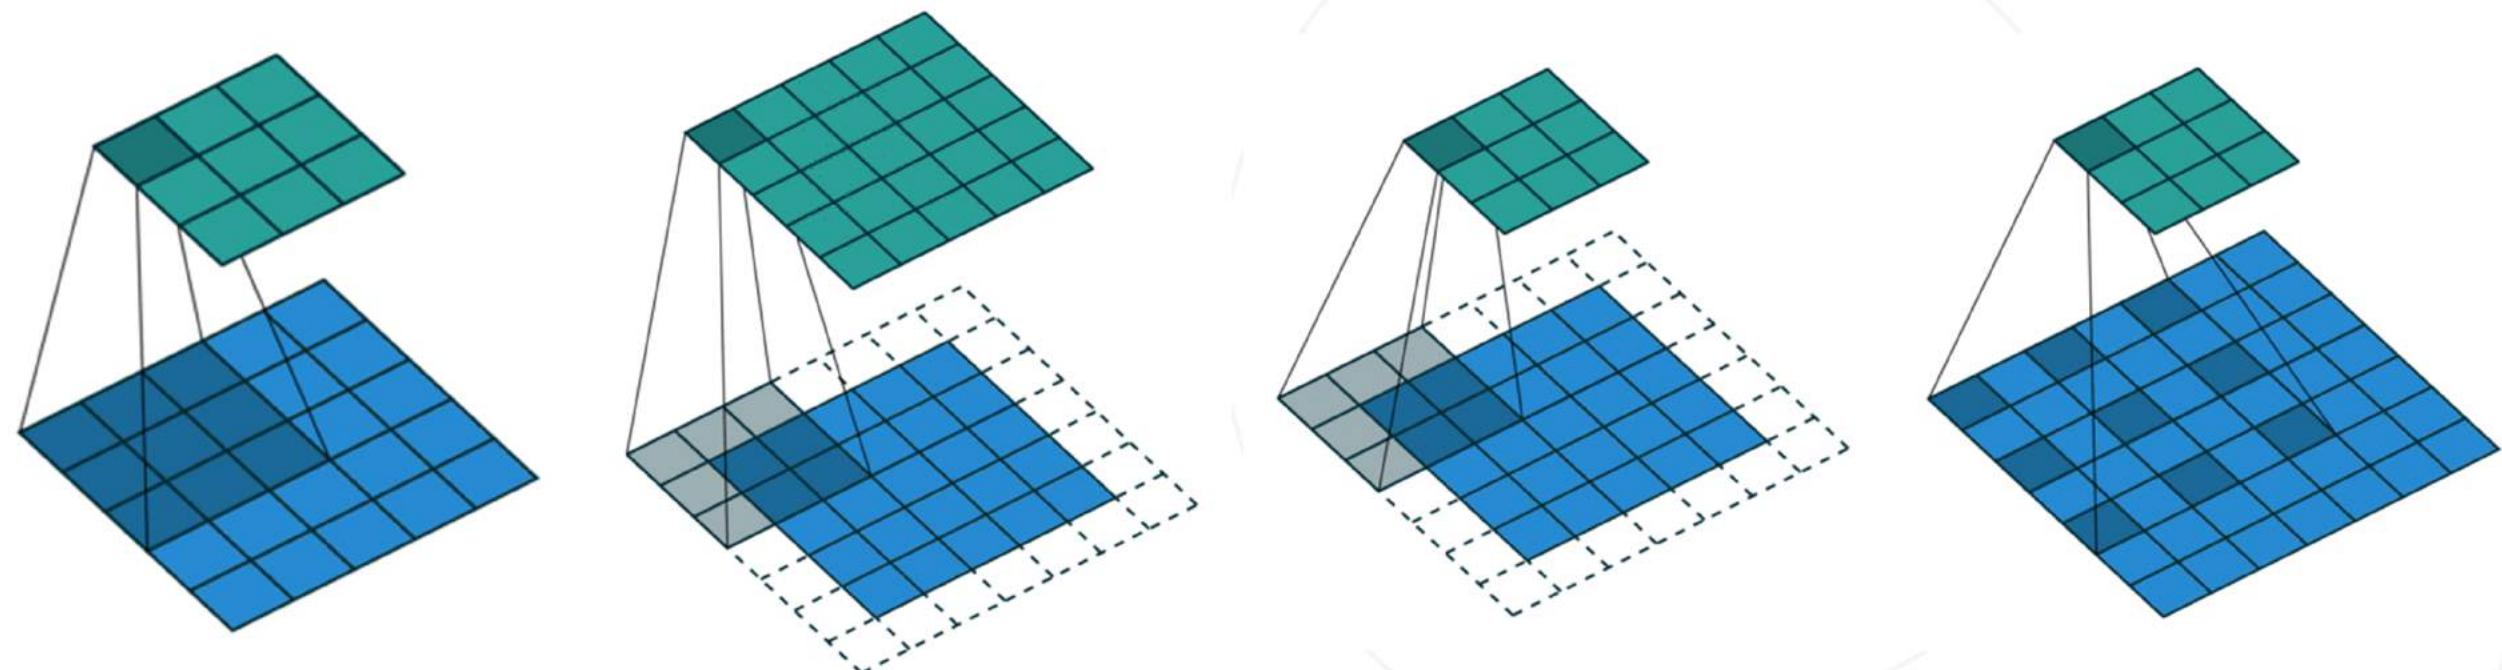


26 × 28

将卷积核中的元素按照向量化输入
和输出之间的关系排列成矩阵 W

卷积层可以增加边缘填充 (padding)、步长 (stride)、和空洞 (dilation)

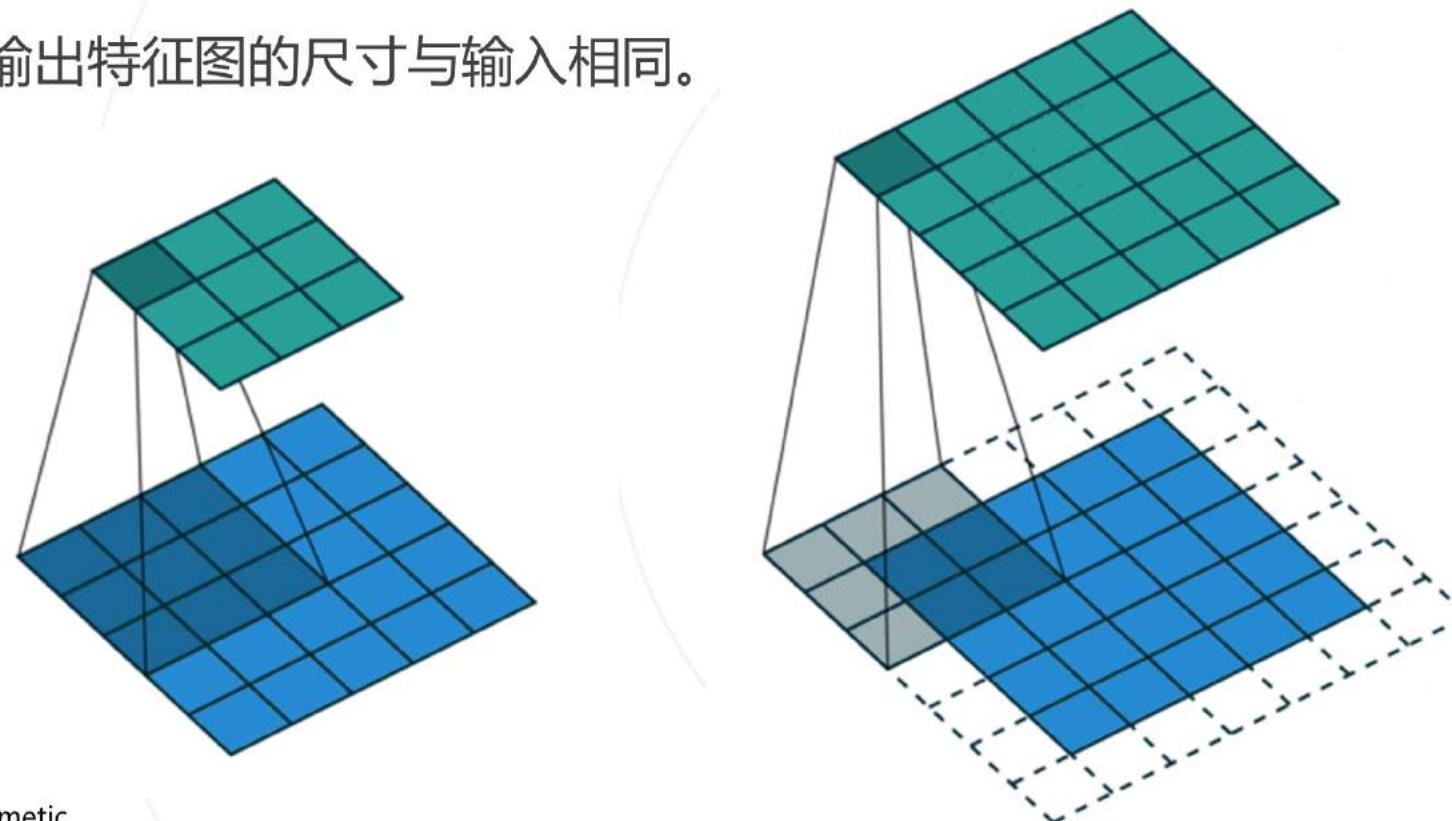
$$\mathbf{Y}[h, w, c] = \sum_{i=1}^K \sum_{j=1}^K \sum_{k=1}^C \mathbf{X}[sh + di - p, sw + dj - p, k] \mathbf{K}_c[i, j, k] + \mathbf{b}[c]$$



- 边缘填充 (padding) 在输入特征图的边界处填补 p 个像素宽度的 0 值，以扩大输入和输出特征图的空间尺寸。

$$H' = H - K + 1 + 2p$$

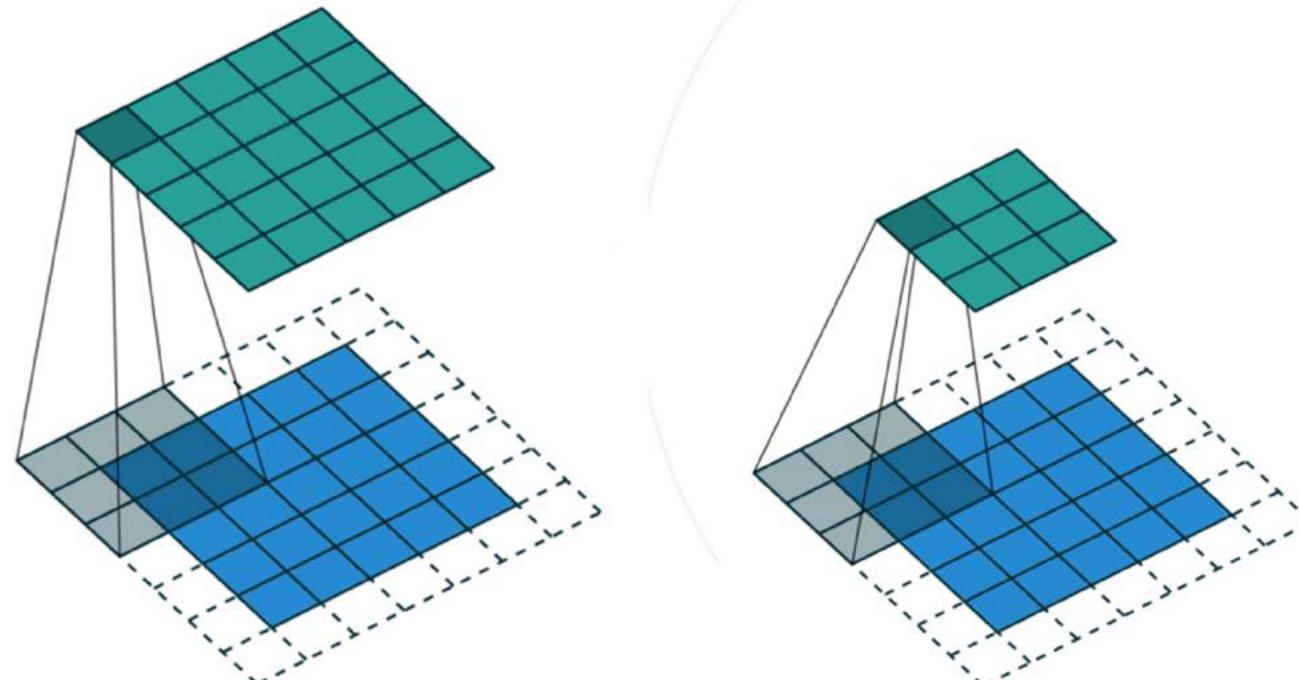
- 例：当 $p = \frac{F-1}{2}$ 时，输出特征图的尺寸与输入相同。



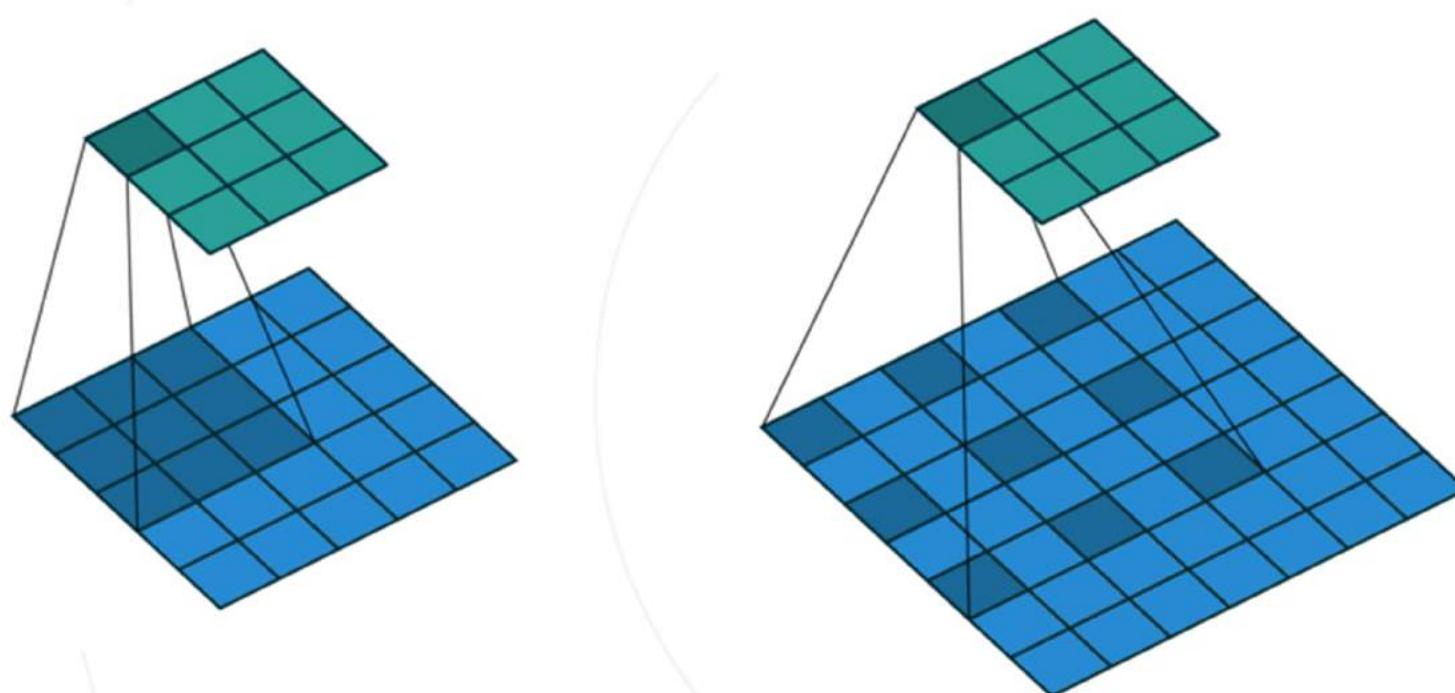
- 步长 (padding) 降低卷积计算的空间频率，实现空间降采样。

$$H' = \left\lfloor \frac{H - F + 2p}{S} \right\rfloor + 1$$

- 例： $F = 3, p = 1, S = 2$ 且输入分辨率 H 为偶数的时候，输出分辨率恰好为输入的一半。模型中广泛使用。



- 空洞卷积 (dilated convolution) 可以在不增加参数的情况下“扩大”卷积核，从而增加卷积层感受野。在语义分割模型中广泛应用。



图像分类模型设计

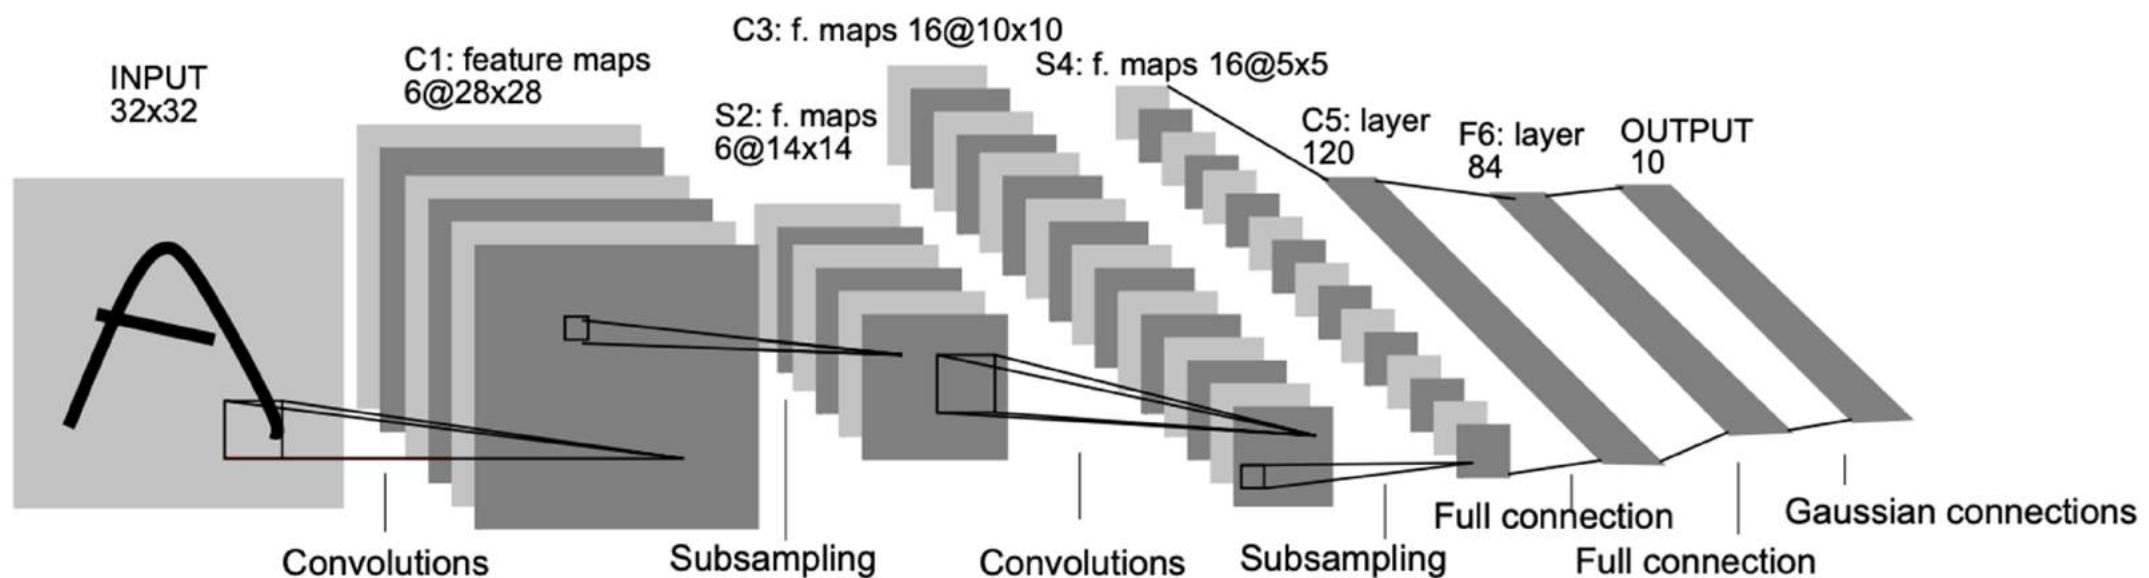
图像分类网络通常可以分为主干网络和分类器两部分



最早期的卷积神经网络之一。

LeNet-5 由 7 层网络组成，其中 2 层为卷积层，2 层为下采样层，3 层为全连接层。

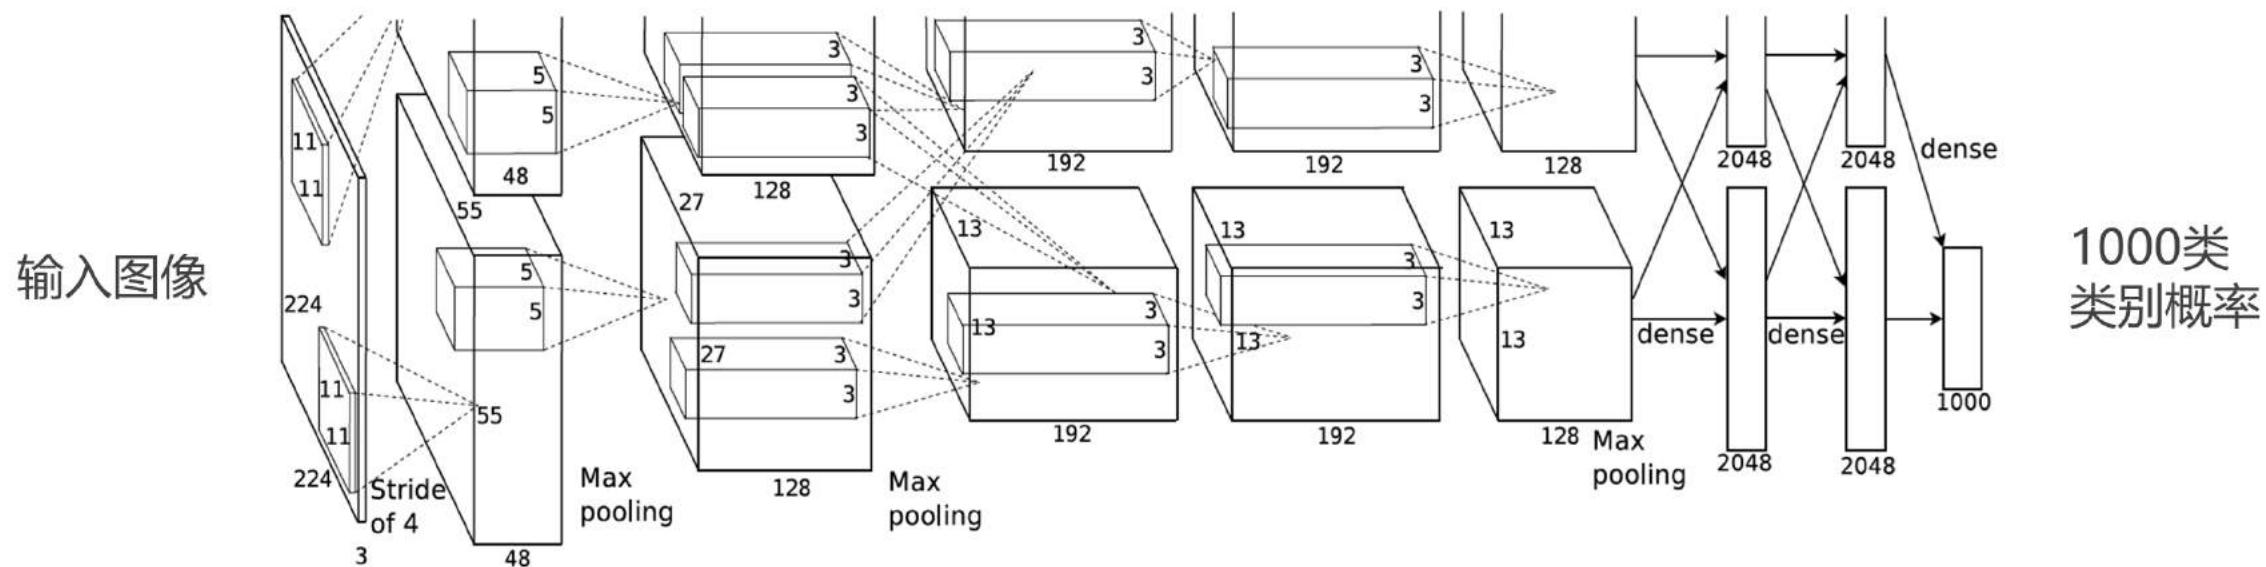
60K 个可学习参数。



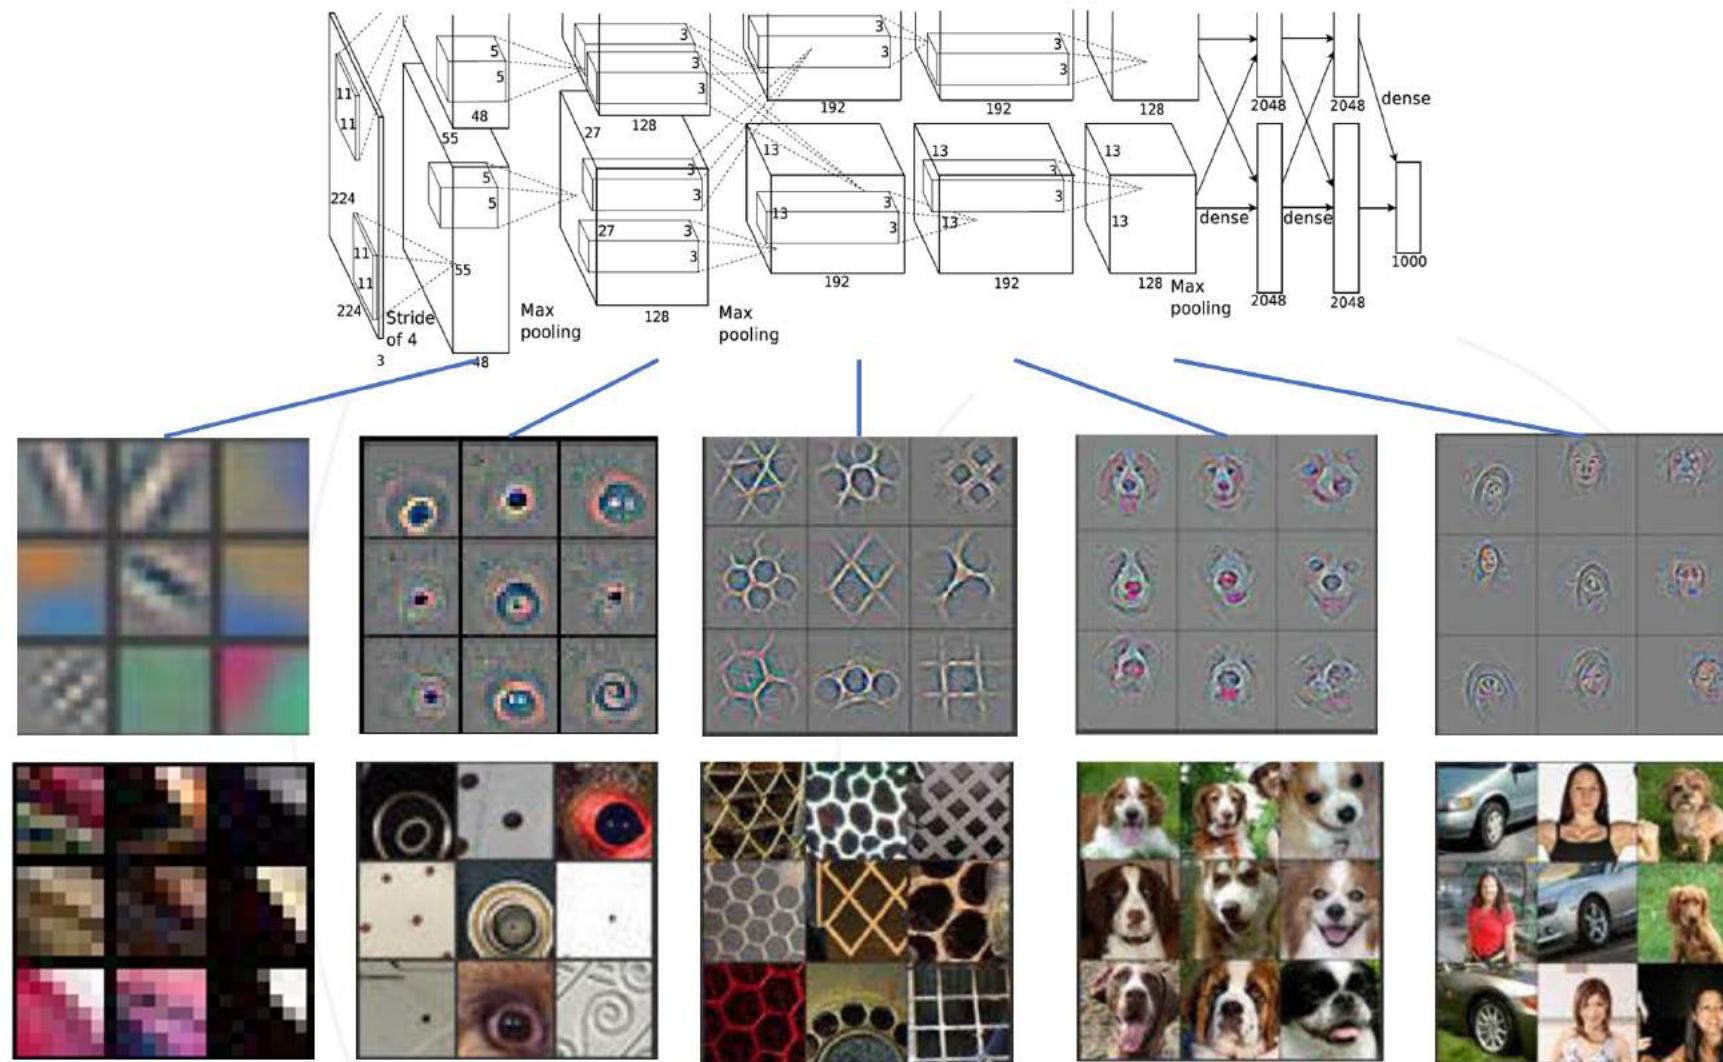
第一个成功应用于大规模图像分类的卷积神经网络模型。

8 个可学习层，5 个卷积层，3 个全连接层，共有 60M 个可学习参数。

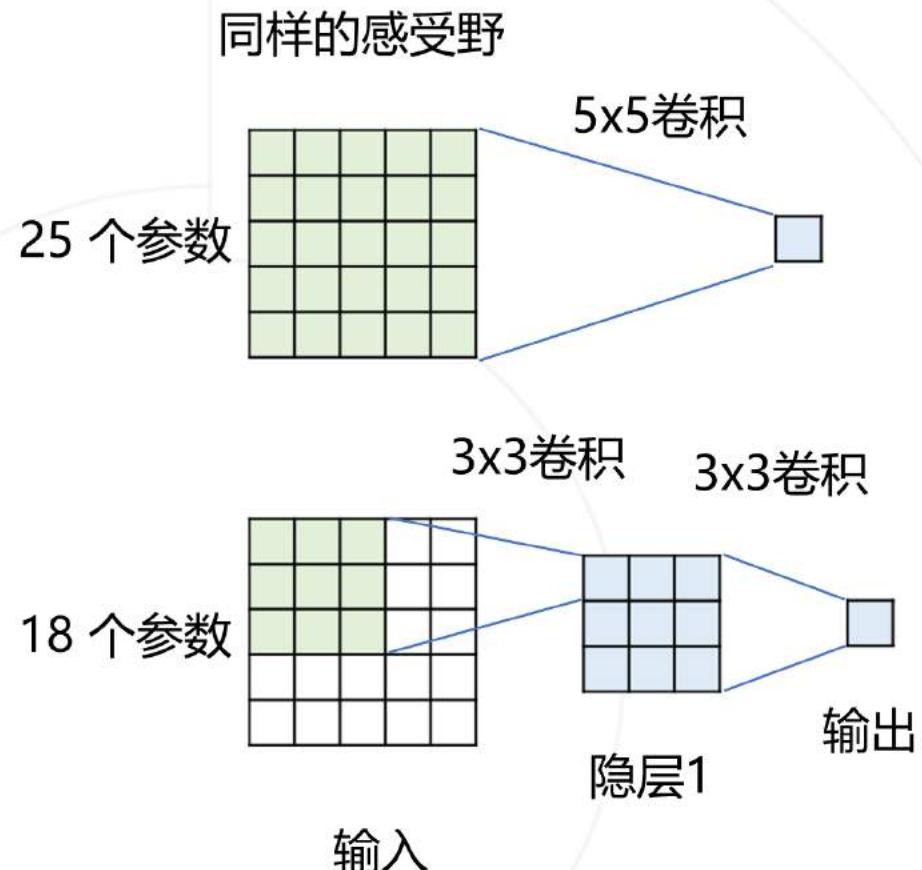
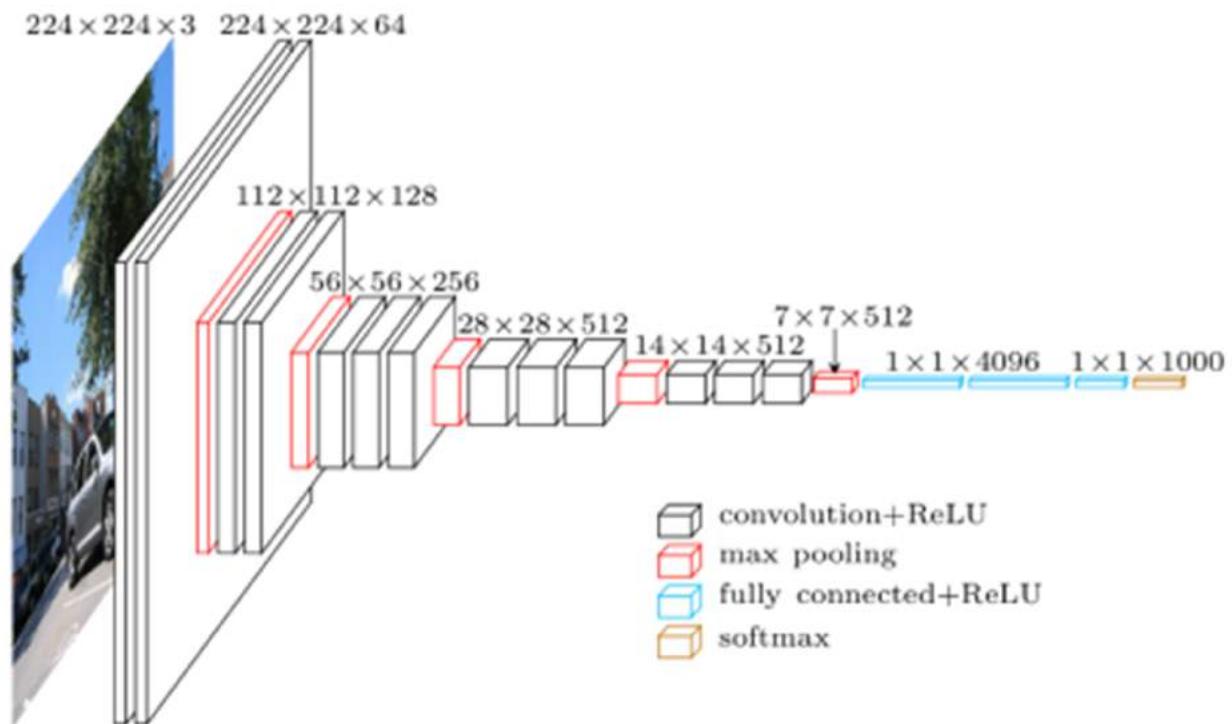
使用 2 个 NVIDIA GTX 580 GPU 训练了 1 周。



卷积网络中的多层次特征



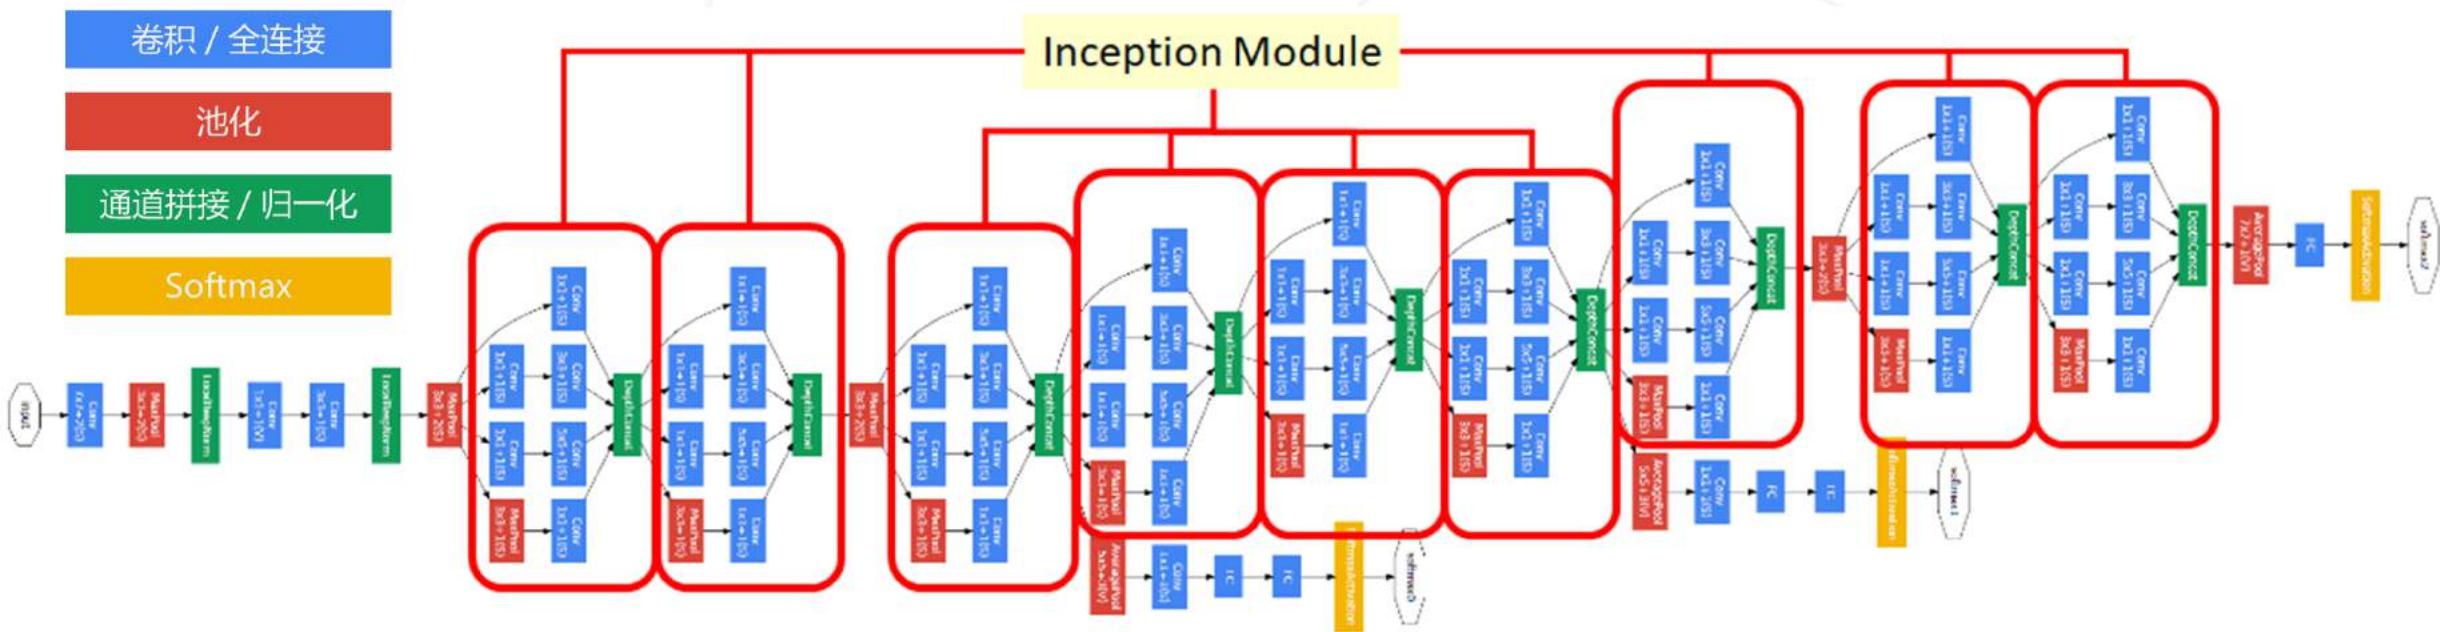
- 只使用 3×3 的卷积核
- 层数增多：16~19层
- 边界填充1像素，维持空间分辨率
- 倍增通道数的同时减半空间分辨率



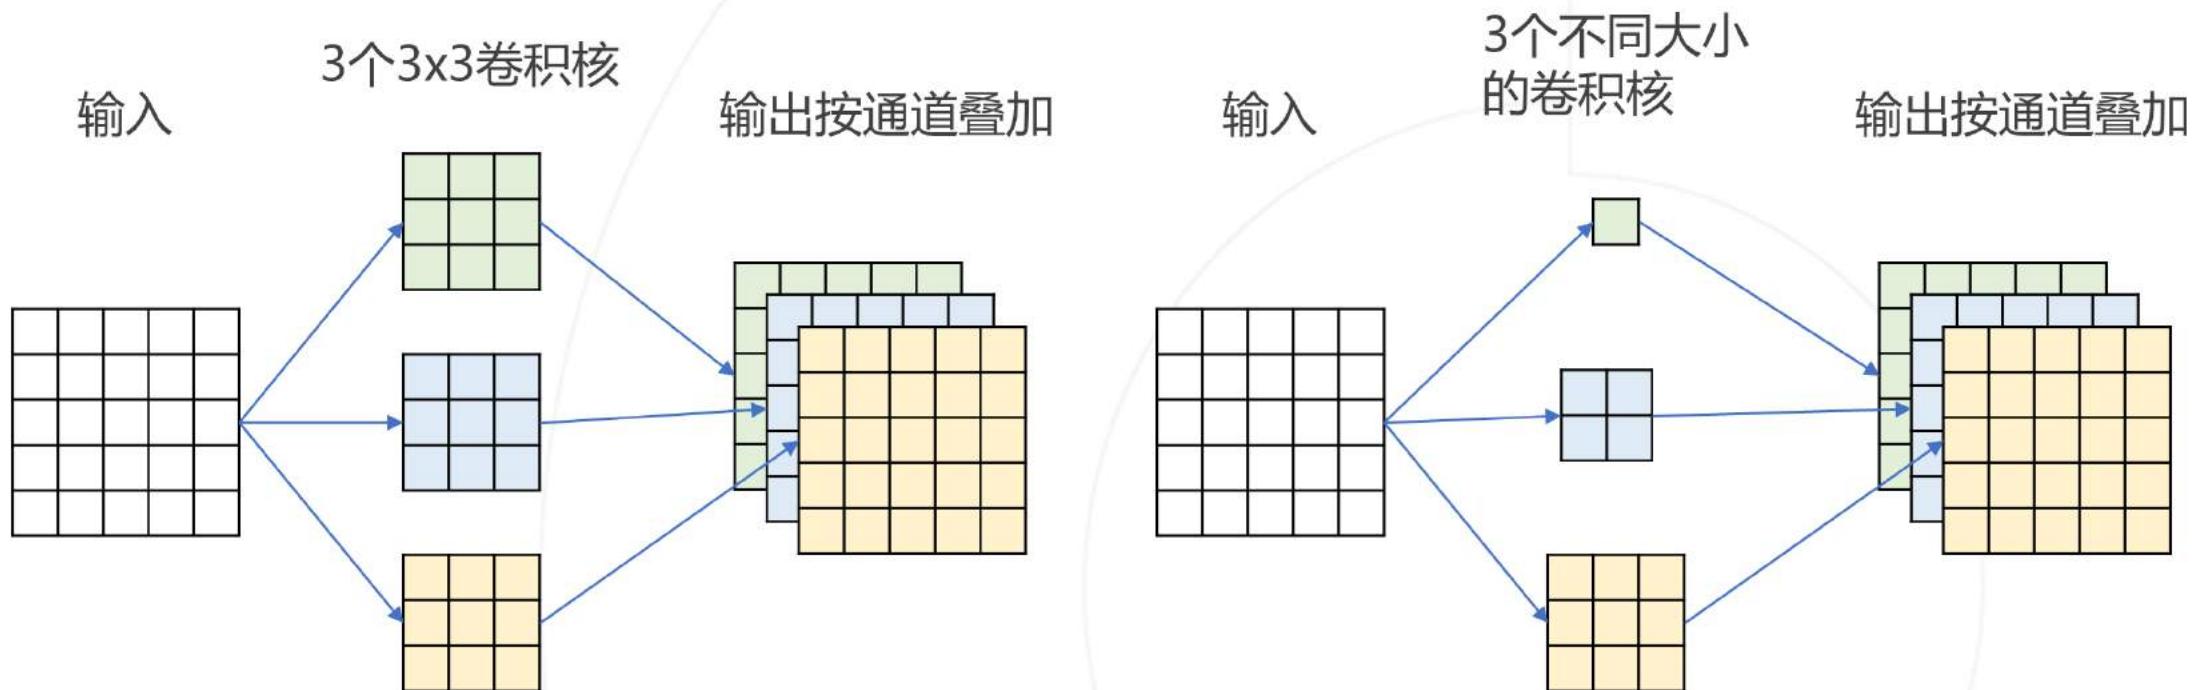
- VGG-16 有 138M 权重参数，其中超过 100M 来自全连接层。

VGG16 - Structural Details													
#	Input Image			output			Layer	Stride	Kernel	in	out	Param	
1	224	224	3	224	224	64	conv3-64	1	3	3	3	64	1792
2	224	224	64	224	224	64	conv3064	1	3	3	64	64	36928
	224	224	64	112	112	64	maxpool	2	2	2	64	64	0
3	112	112	64	112	112	128	conv3-128	1	3	3	64	128	73856
4	112	112	128	112	112	128	conv3-128	1	3	3	128	128	147584
	112	112	128	56	56	128	maxpool	2	2	2	128	128	65664
5	56	56	128	56	56	256	conv3-256	1	3	3	128	256	295168
6	56	56	256	56	56	256	conv3-256	1	3	3	256	256	590080
7	56	56	256	56	56	256	conv3-256	1	3	3	256	256	590080
	56	56	256	28	28	256	maxpool	2	2	2	256	256	0
8	28	28	256	28	28	512	conv3-512	1	3	3	256	512	1180160
9	28	28	512	28	28	512	conv3-512	1	3	3	512	512	2359808
10	28	28	512	28	28	512	conv3-512	1	3	3	512	512	2359808
	28	28	512	14	14	512	maxpool	2	2	2	512	512	0
11	14	14	512	14	14	512	conv3-512	1	3	3	512	512	2359808
12	14	14	512	14	14	512	conv3-512	1	3	3	512	512	2359808
13	14	14	512	14	14	512	conv3-512	1	3	3	512	512	2359808
	14	14	512	7	7	512	maxpool	2	2	2	512	512	0
14	1	1	25088	1	1	4096	fc		1	1	25088	4096	102764544
15	1	1	4096	1	1	4096	fc		1	1	4096	4096	16781312
16	1	1	4096	1	1	1000	fc		1	1	4096	1000	4097000
Total											138,423,208		

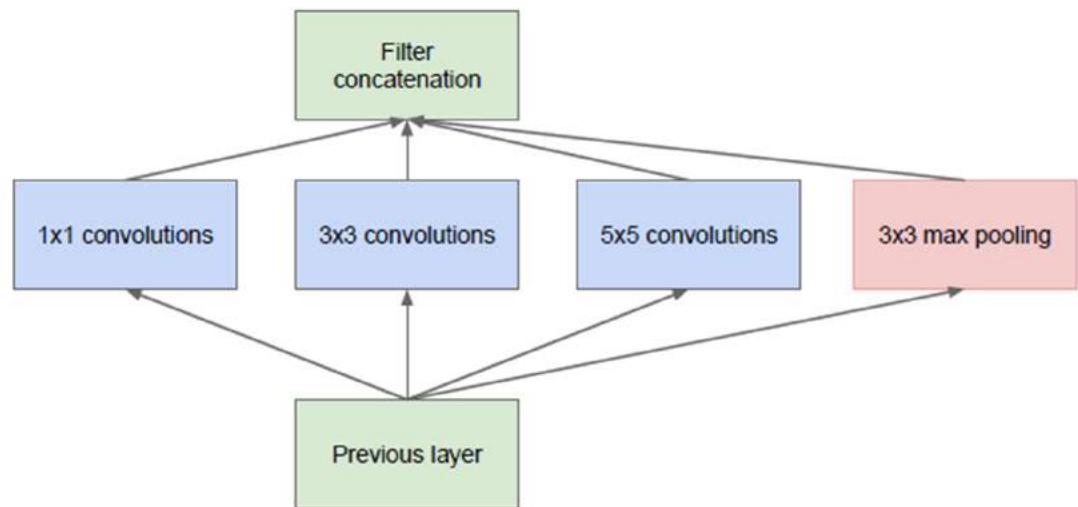
- 使用 Inception 模块，在同一层使用不同尺寸的卷积核
- 22 个可学习层，仅 7M 权重参数



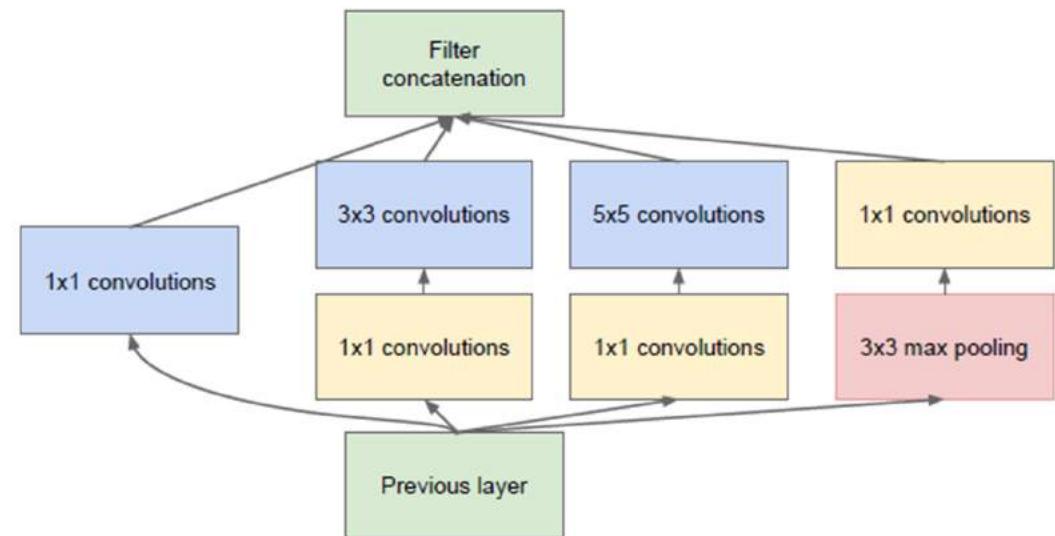
使用不同大小的卷积核



- 使用不同大小的卷积核，再将特征图沿通道拼接
- 对于 3×3 和 5×5 的卷积核，进一步使用 1×1 的卷积核压缩通道，降低计算量。

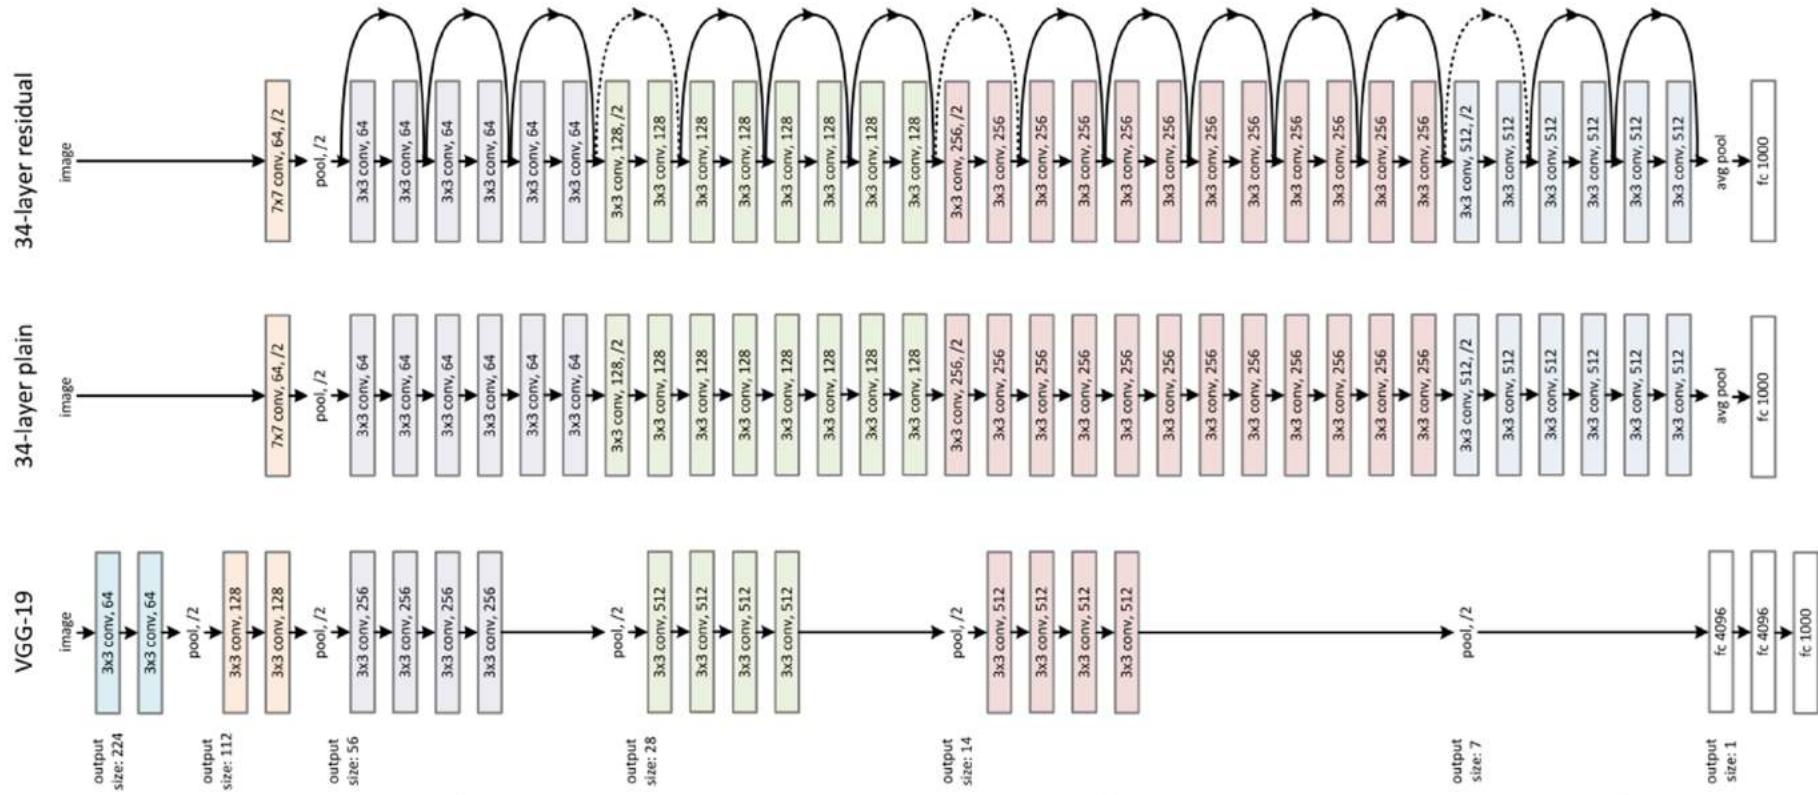


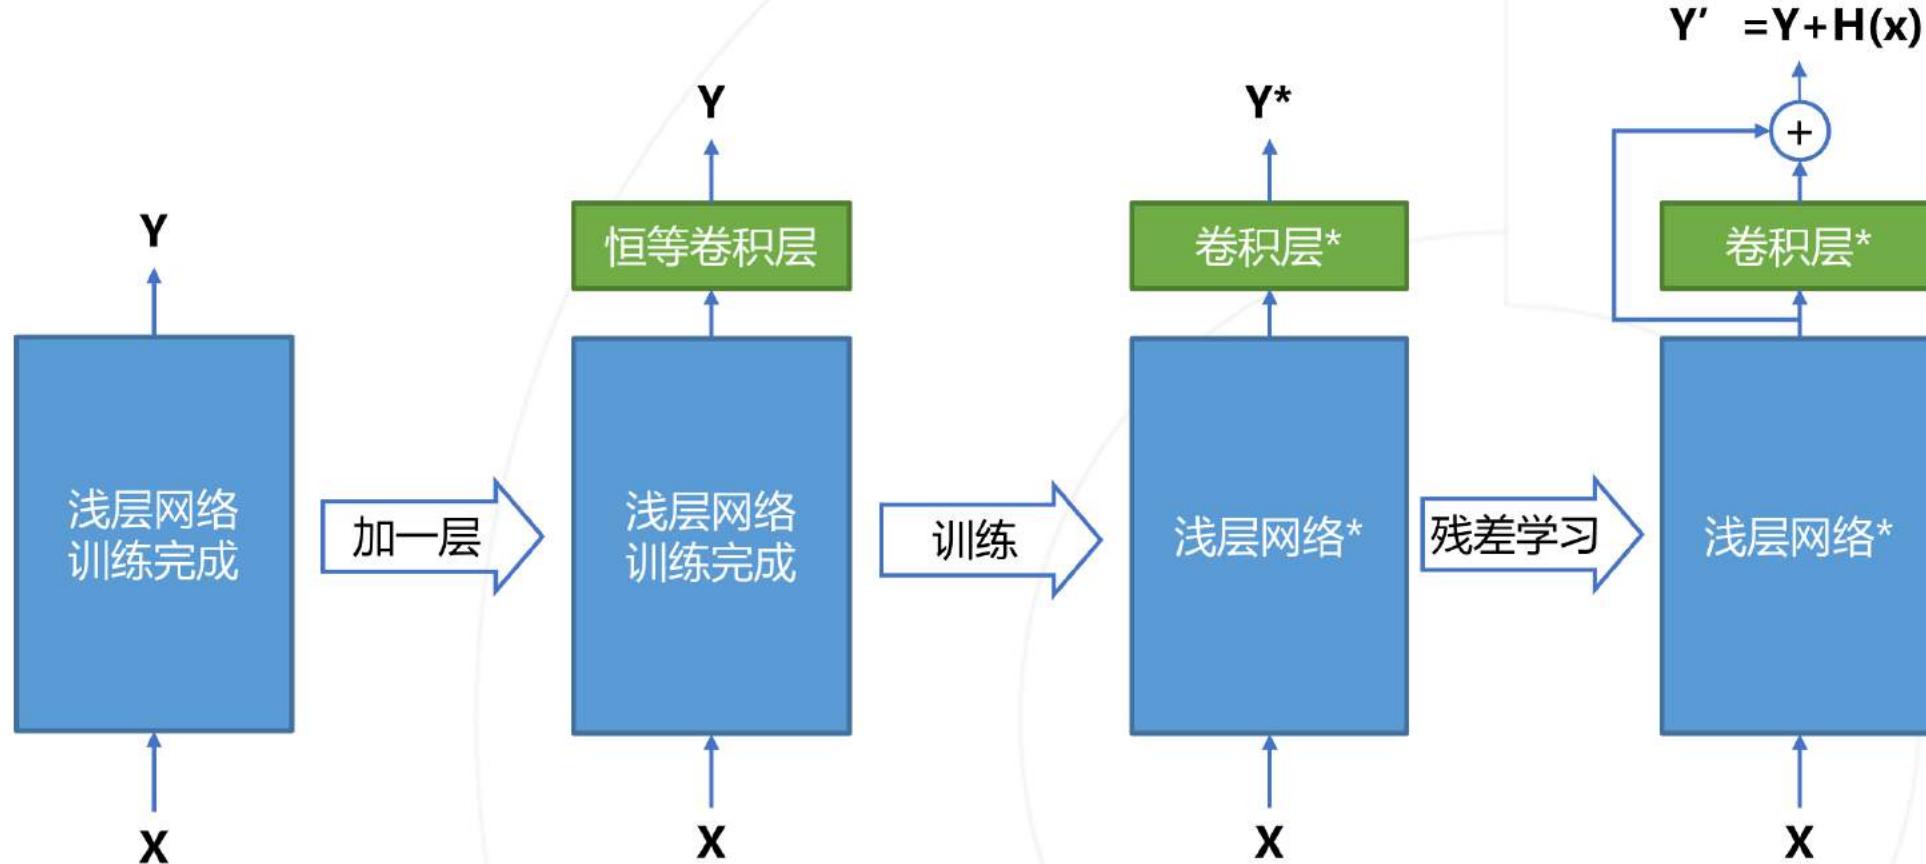
(a) Inception module, naïve version



(b) Inception module with dimensionality reduction

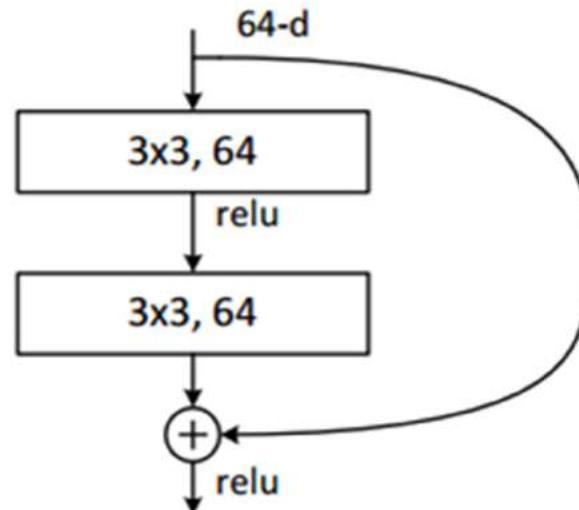
- 迄今为止影响力最大、使用最广泛的模型结构之一，获得 CVPR 2016 最佳论文奖。
 - **残差学习**：引入了跨层连接，将网络深度提高到了上百层。





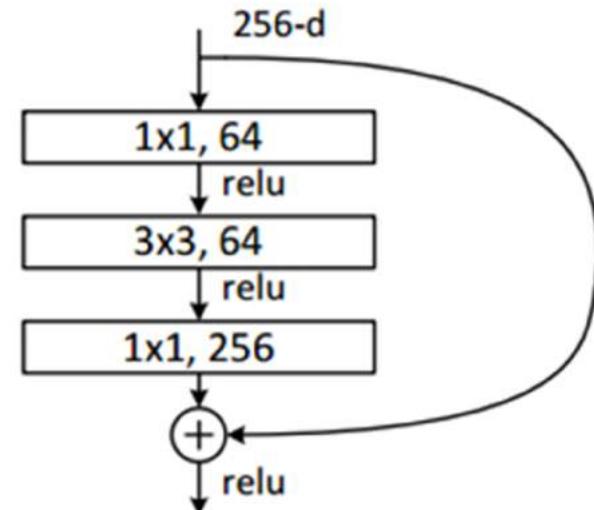
深层网络应该具有不低于浅层网络的精度

实验：精度下降 -> 退化问题



Basic block

用于 ResNet-18 和 34

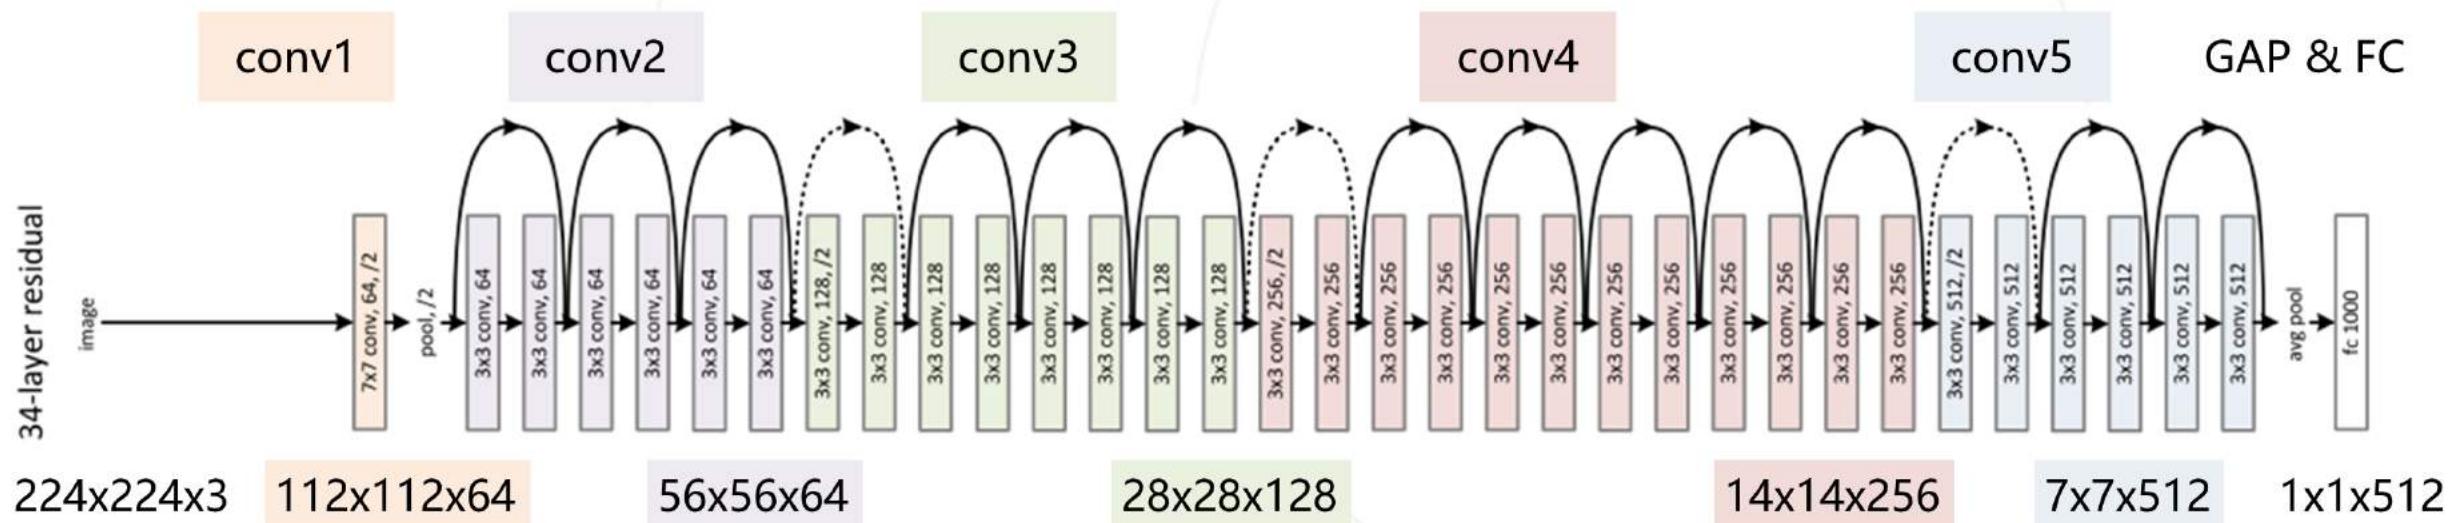


Bottleneck block

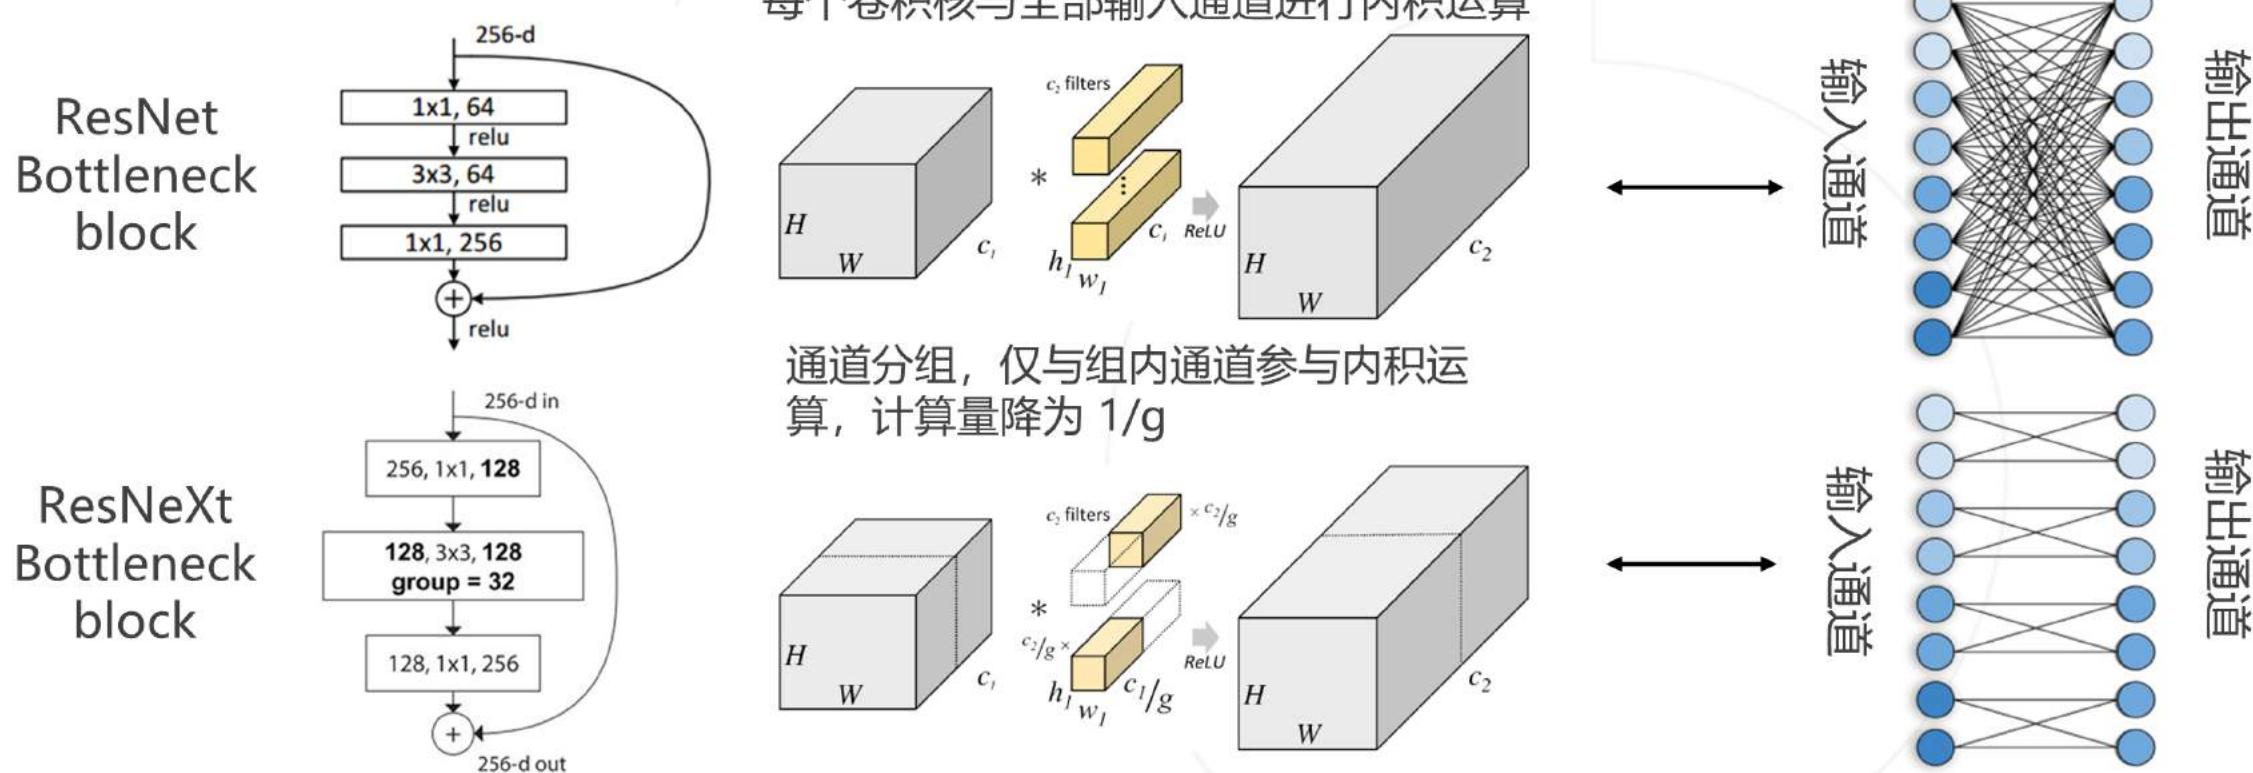
用于 ResNet-50、101 和 152

1x1 卷积用于压缩通道，降低计算开销

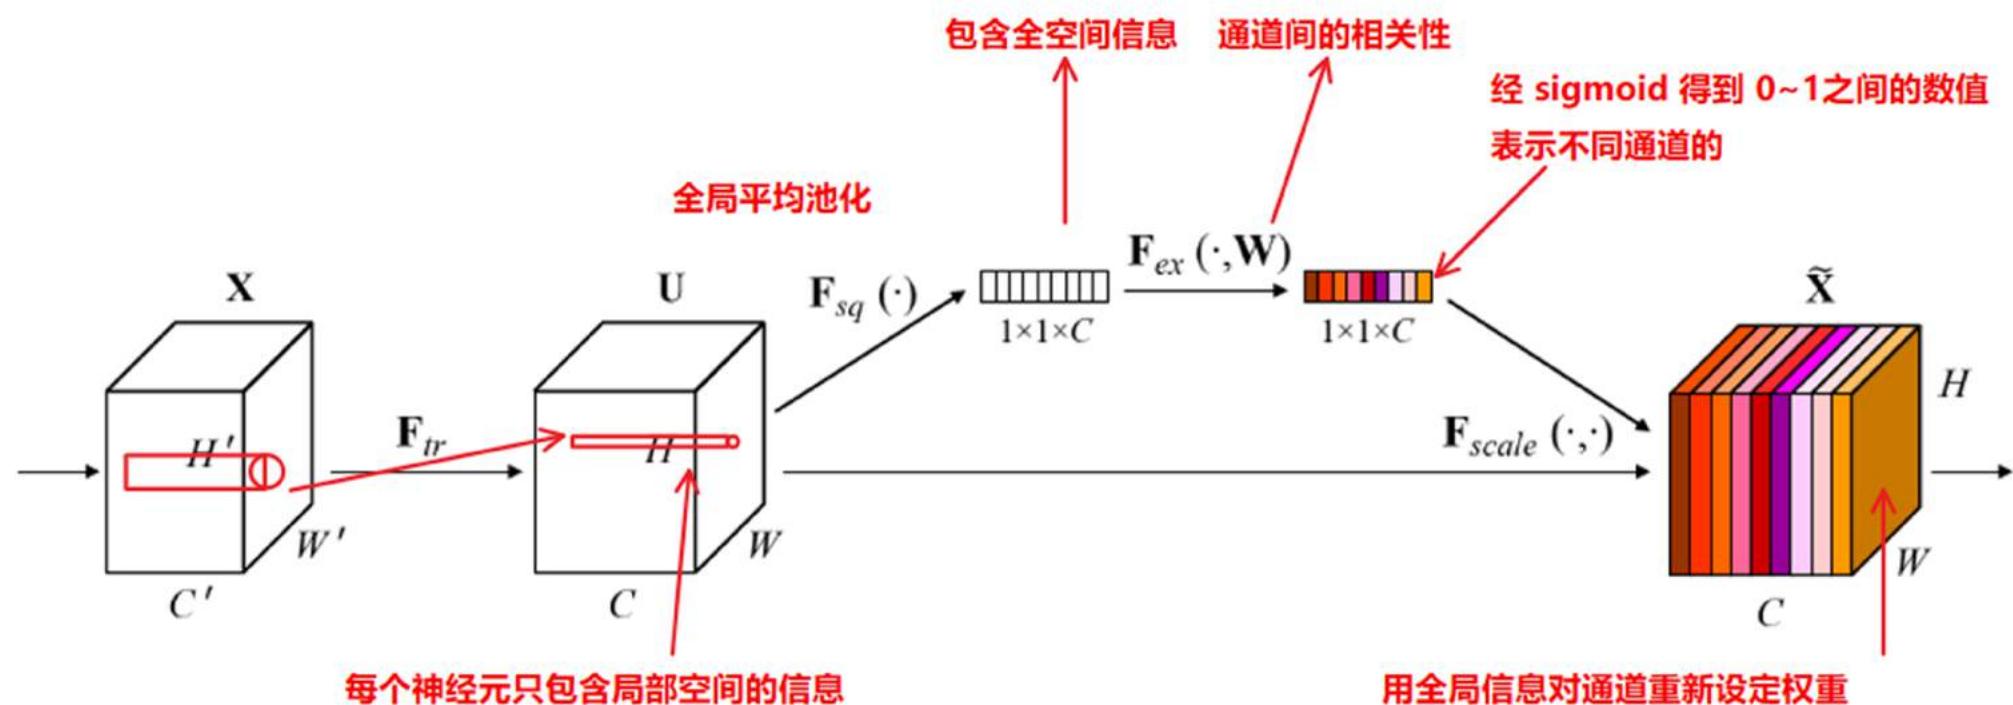
- 5 级，每级包含若干残差模块。不同残差模块个数 → 不同 ResNet 结构。
- 每级输出分辨率减半，通道倍增
- 全局平均池化压缩空间维度
- 单层全连接层产生类别概率



- ResNeXt 将 ResNet 的 Bottleneck block 中 3x3 的卷积改为分组卷积，降低模型计算量。

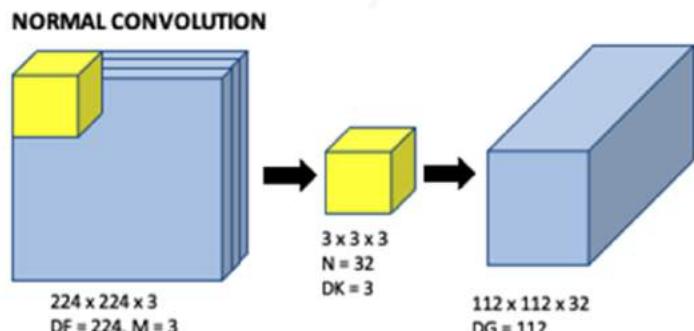


- 引入注意力机制，显式建模不同通道的重要性。
- 即插即用模块，可以插入到任意模型中：SE + ResNet = SENet

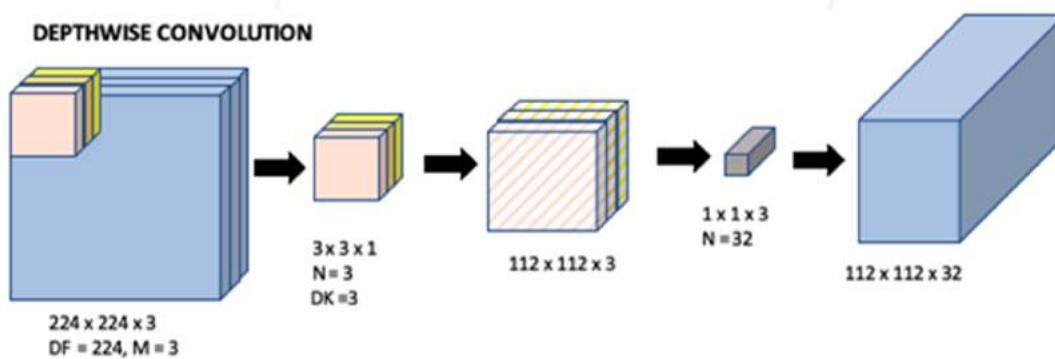


- 将常规卷积分解为逐层卷积和逐点卷积，以降低参数数量和计算量
- 全尺寸的 MobileNet 只有 4.2M 参数

常规卷积



逐层卷积
逐点卷积



参数量: $D_K^2 NM$
计算量: $D_K^2 NMD_G^2$

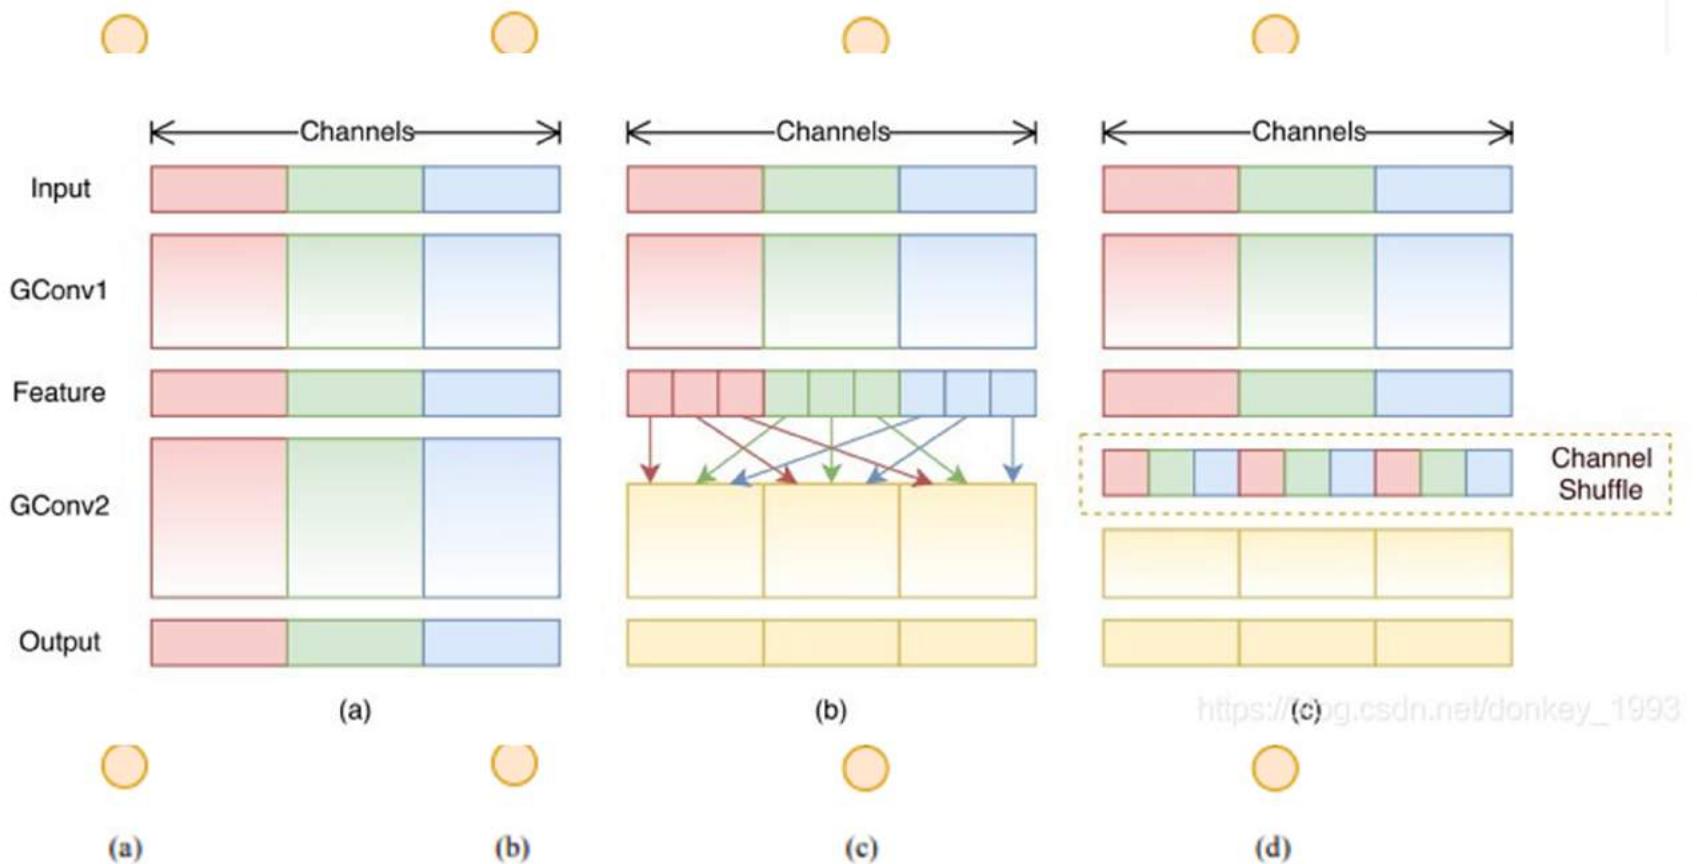
1

参数量: $D_K^2 M + MN$
计算量: $(D_K^2 M + MN)D_G^2$

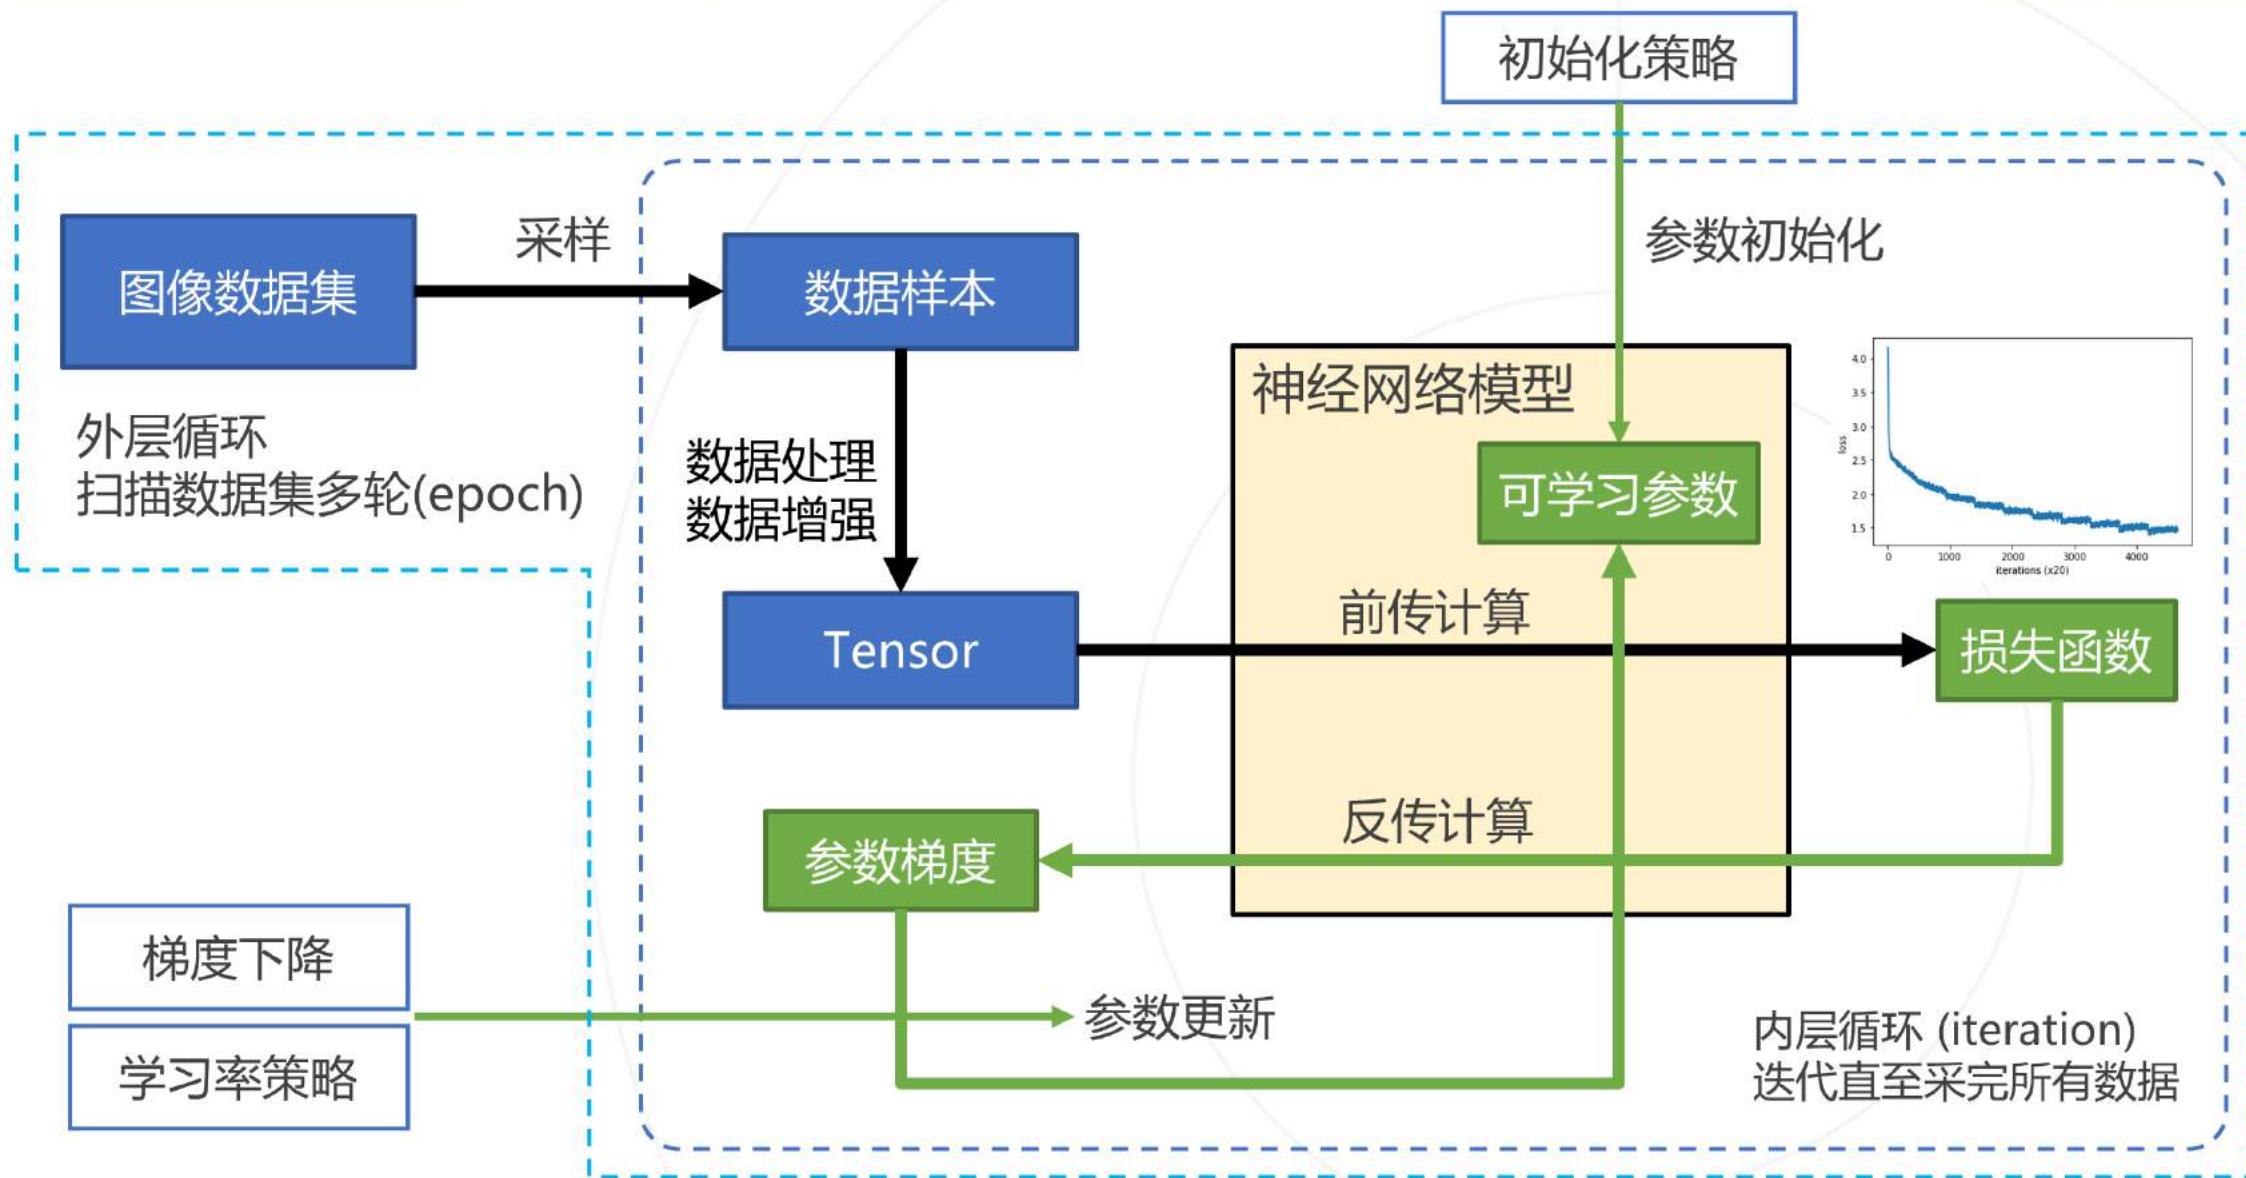
$$\frac{1}{N} + \frac{1}{D_K^2}$$

- MobileNet v2/v3 在 v1 的基础上加入了残差模块和 SE 模块

ShuffleNet (2017)



图像分类模型训练



对于预测类别概率 $P \in [0,1]^K$ 和真值 y ，定义交叉熵损失为：

$$l(P, y) = -\log P_y$$

P_y 的减函数， $P_y = 1$ 时取最小

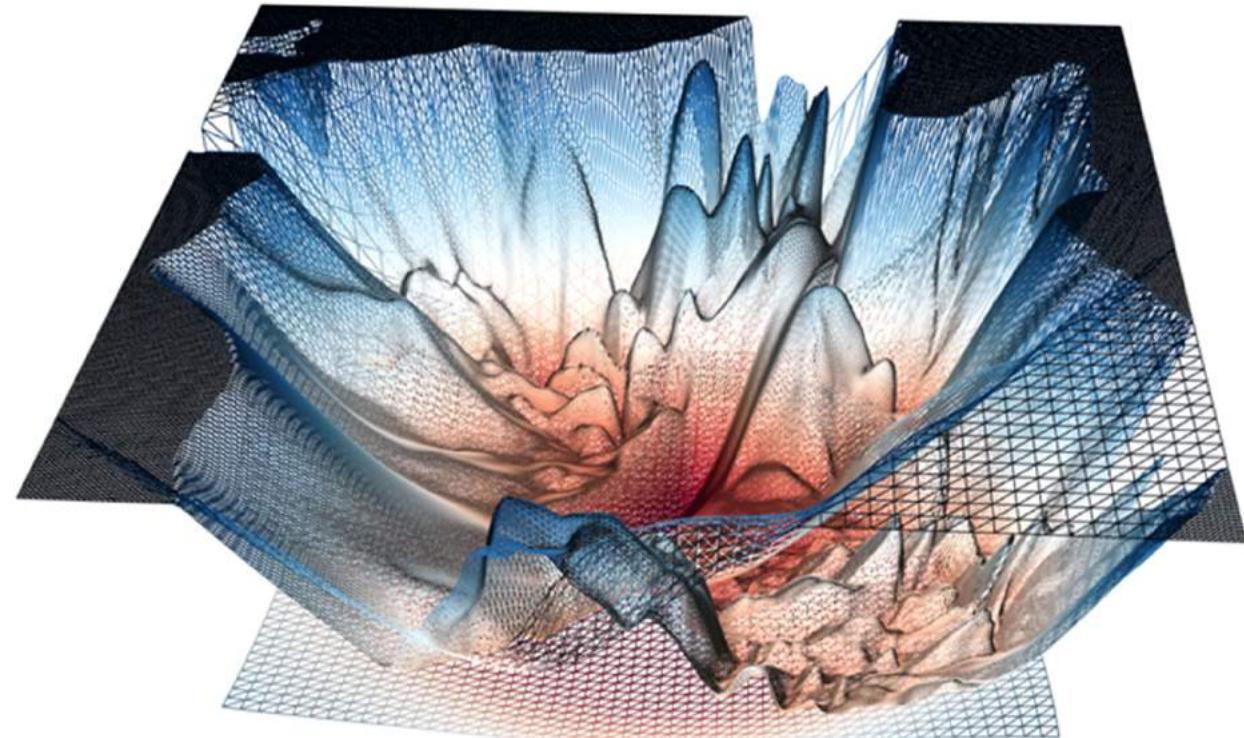
此时 $P = [0, 0, \dots, 1, \dots, 0]$ ，中只有第 y 项为 1， $l(P, y) = 0$

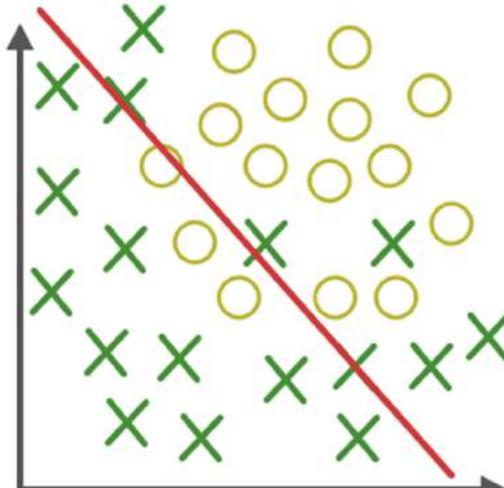
1. 数据量大、计算量大

➤ 例：在 ImageNet 数据集上训练 AlexNet , $N \approx 1\ 000\ 000$, $\dim(\Theta) \approx 60\ 000\ 000$

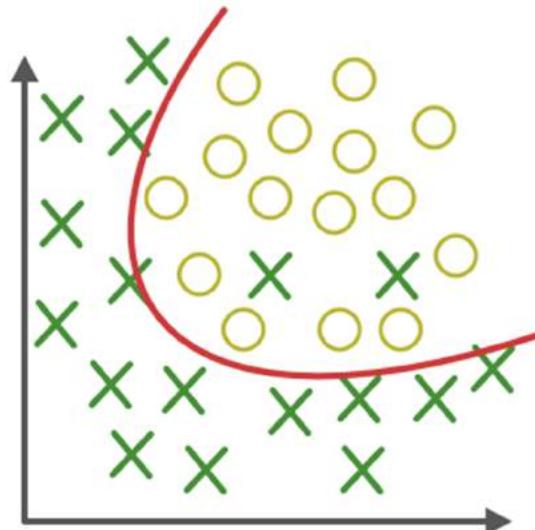
2. 损失函数高度复杂：高维、非凸

3. 模型复杂度高，容易过拟合

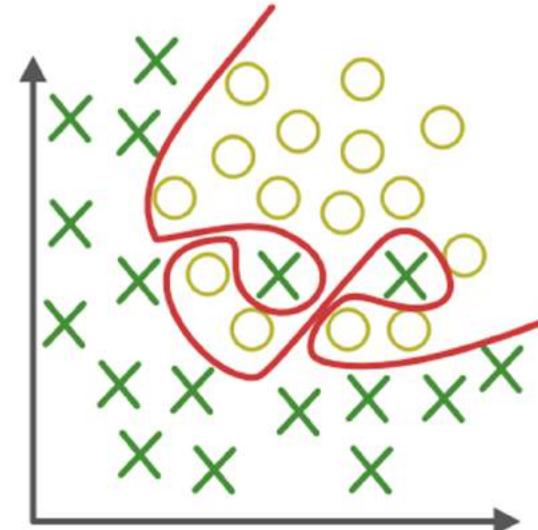




欠拟合



拟合



过拟合

没有捕捉数据中的规律
不能准确预测未来数据
模型过于简单

捕捉到数据中的规律
可以准确预测未来数据

过度拟合到数据中的噪声
不能准确预测未来数据
模型过于复杂、且数据不够

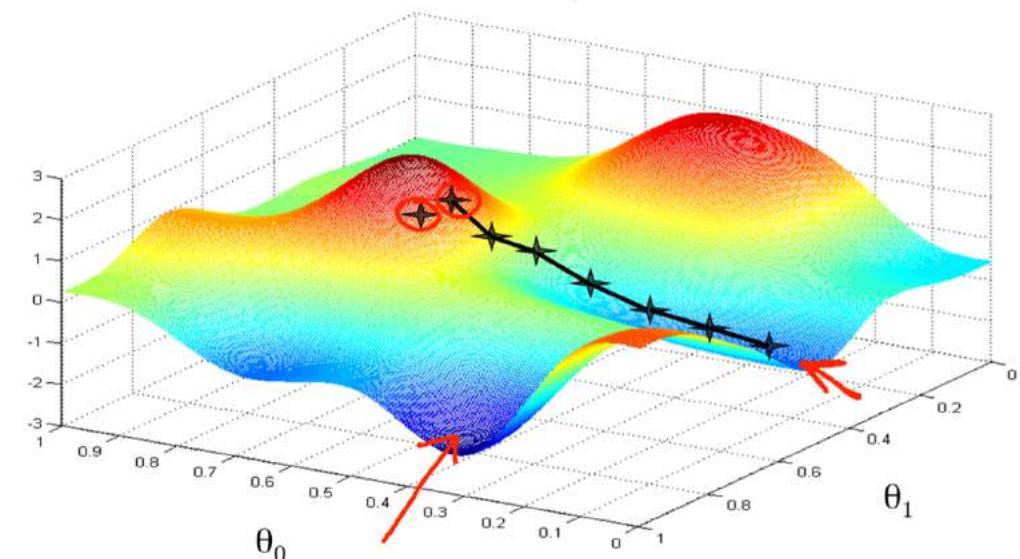
- 给定数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ ，模型 $h(x; \Theta)$ 和损失函数 $l(P, y)$ ，

$$L(\Theta | \mathcal{D}) := \frac{1}{N} \sum_{i=1}^N l(h(x_i; \Theta), y_i)$$

很大

- 随机初始化参数 $\Theta^{(0)}$
- 迭代直至收敛：
 - 前向+反向传播计算梯度 $\nabla_{\Theta} L(\Theta^{(t-1)})$
 - 参数更新 $\Theta^{(t)} = \Theta^{(t-1)} - [\eta] \nabla_{\Theta} L(\Theta^{(t-1)})$

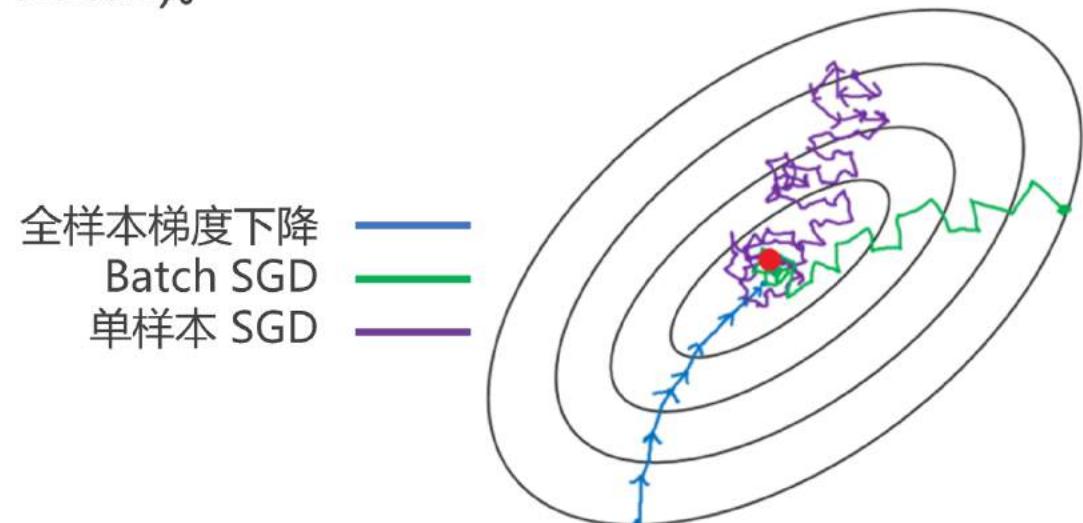
学习率



- 每次迭代随机选取指标集 $\mathcal{B}^{(t)} = \{i_1, i_2, \dots, i_B\}$ 近似计算损失函数的梯度

$$L_{\mathcal{B}}(\Theta | \mathcal{D}) = \frac{1}{B} \sum_{i=1}^B l\left(h\left(x_{i_j}; \theta\right), y_{i_j}\right) \approx \frac{1}{N} \sum_{i=1}^N l(h(x_i; \theta), y_i)$$

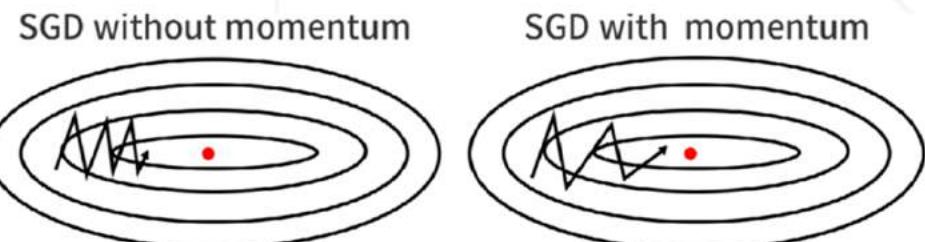
- 对应的样本子集 $D_B = \left\{x_{i_j}, y_{i_j}\right\}_{j=1}^B \subset D$ 称为批 (Mini Batch)。



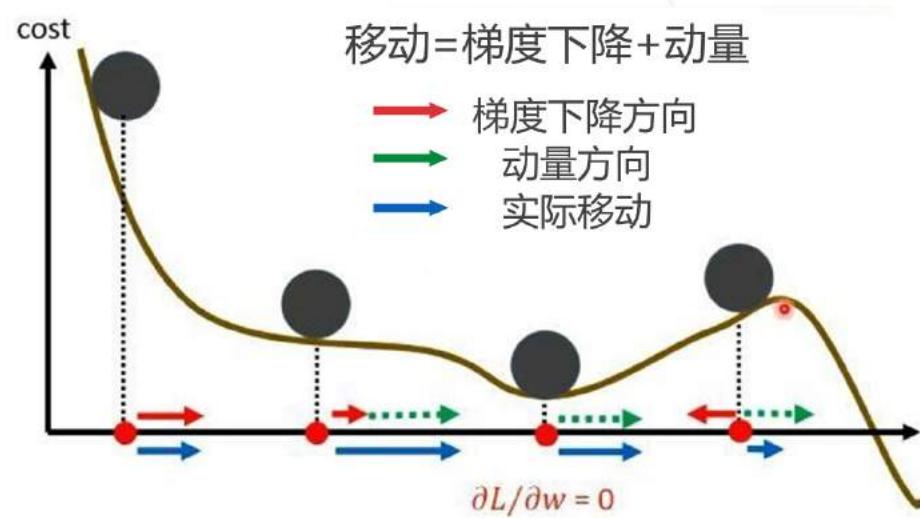
- 将前次的移动延续到本次

以往轮次的梯度的积累	当前轮次的梯度
$\Delta^{(0)} := 0$	
指数滑动平均	$\Delta^{(t)} := \alpha\Delta^{(t-1)} + [\nabla_w L^{(t)}]$
按照积累值移动	$w^{(t)} := w^{(t-1)} - \eta\Delta^{(t)}$

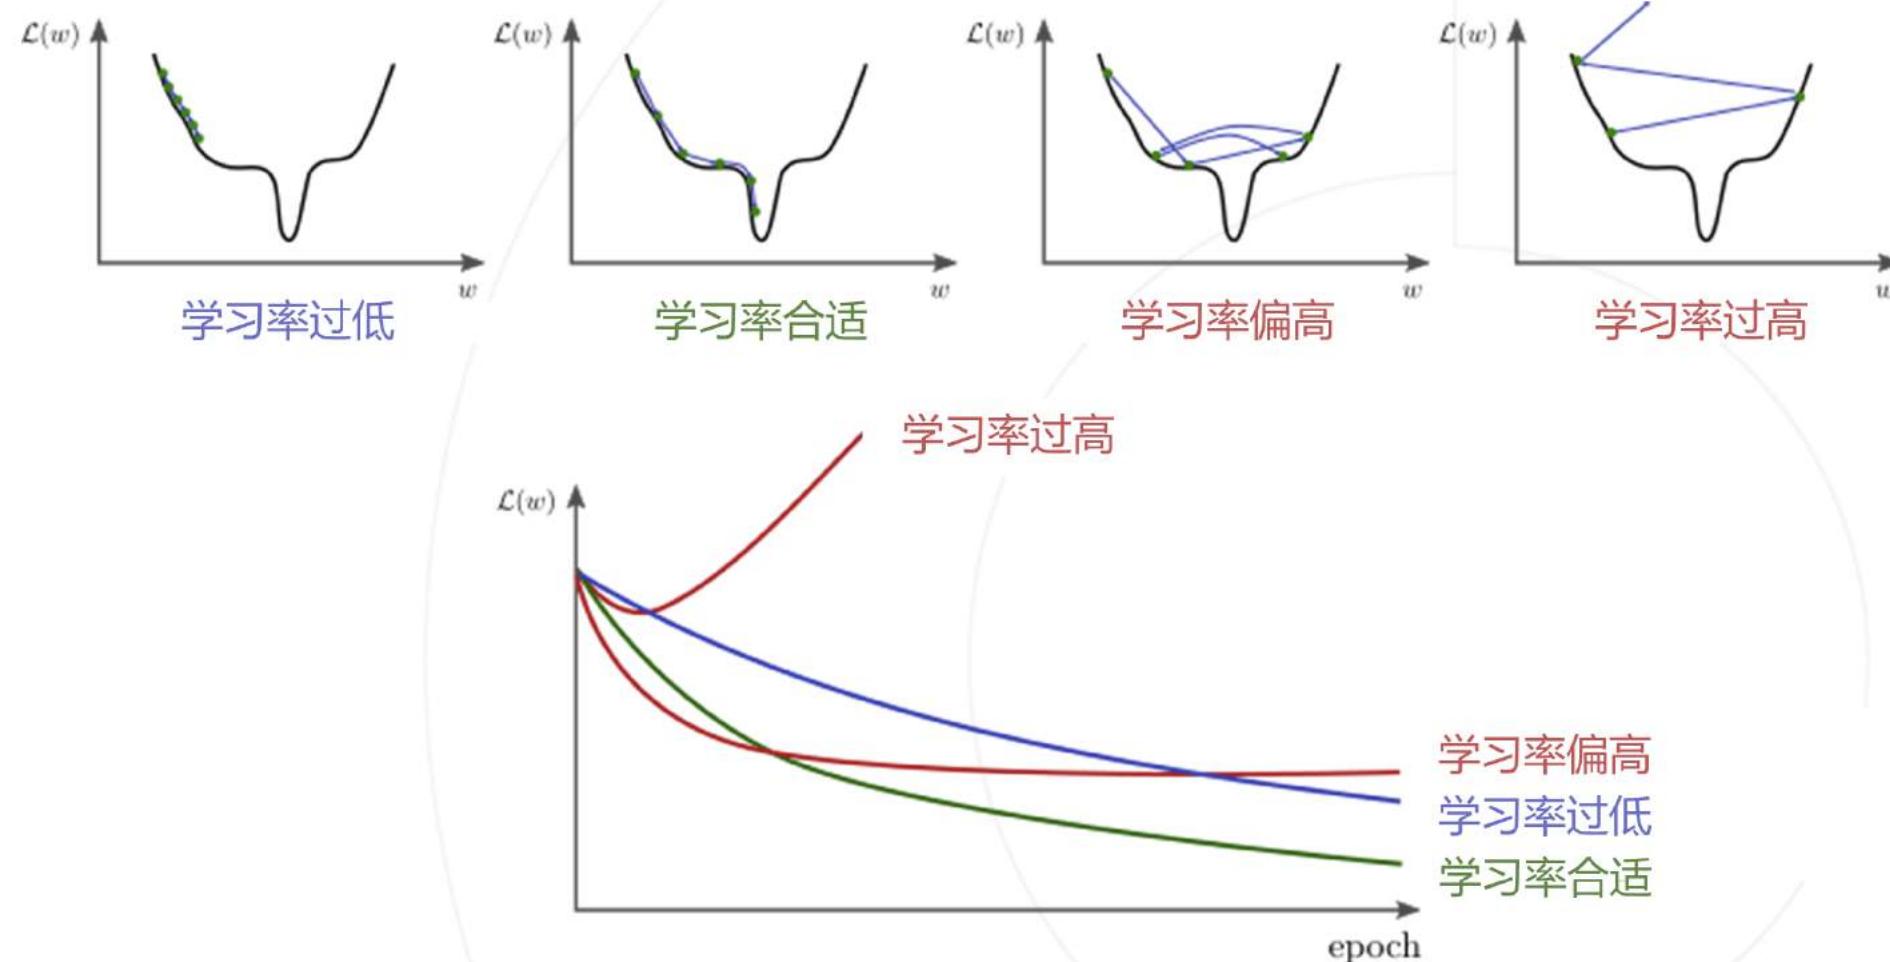
- 缓解随机梯度下降的波动



- 帮助逃离局部极小值和鞍点

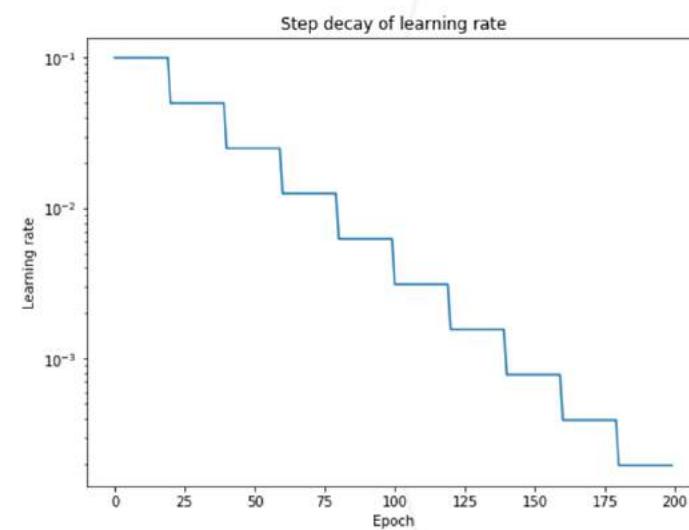


学习率对训练的影响

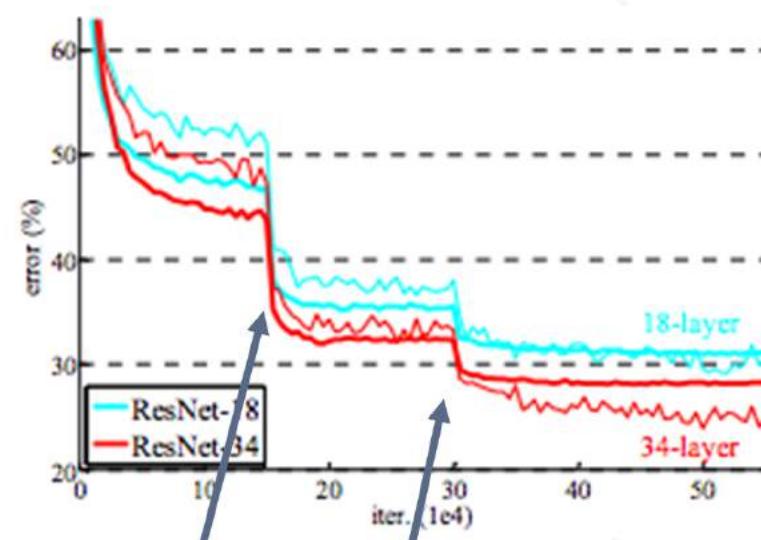


在训练初始阶段使用较大的学习率，损失函数稳定后下降学习率：

- 按步长下降
- 按比例下降 $\eta(t) = \eta_0 e^{-kt}$
- 按倒数下降 $\eta(t) = \frac{\eta_0}{\epsilon+t}$



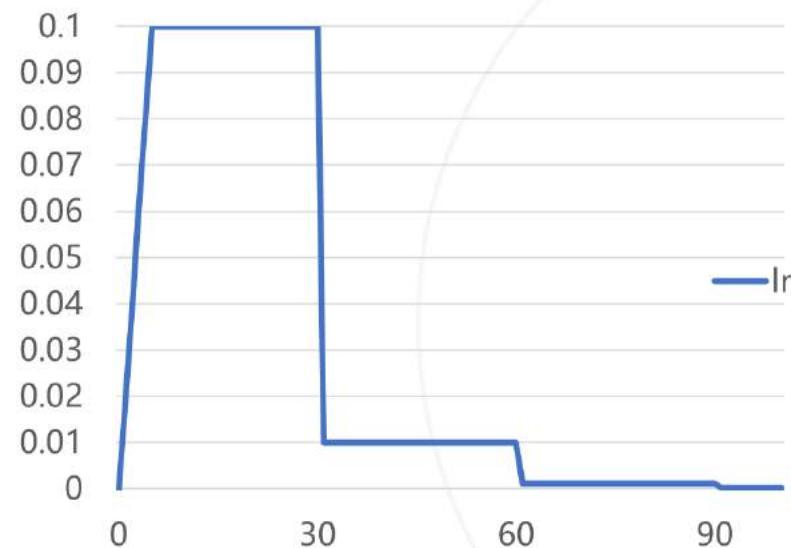
每 20 轮降低学习率至 1/3



降低学习率后损失函数继续下降

在训练前几轮学习率逐渐上升，直到预设的学习率，以稳定训练的初始阶段

- 线性上升 $\eta(t) = \frac{t}{T_0} \eta_0, t \leq T_0$



- 不同梯度需要不同的学习率
- 根据梯度的幅度自动调整学习率

Adagrad

用梯度的历史幅度
对当前梯度的幅度
进行归一化

$$G_i^{(t)} := \sum_{\tau=0}^t \left(g_i^{(\tau)} \right)^2$$

$$w_i^{(t)} := w_i^{(t-1)} - \eta \frac{g_i^{(t)}}{\sqrt{G_i^{(t)}}}$$

Adadelta

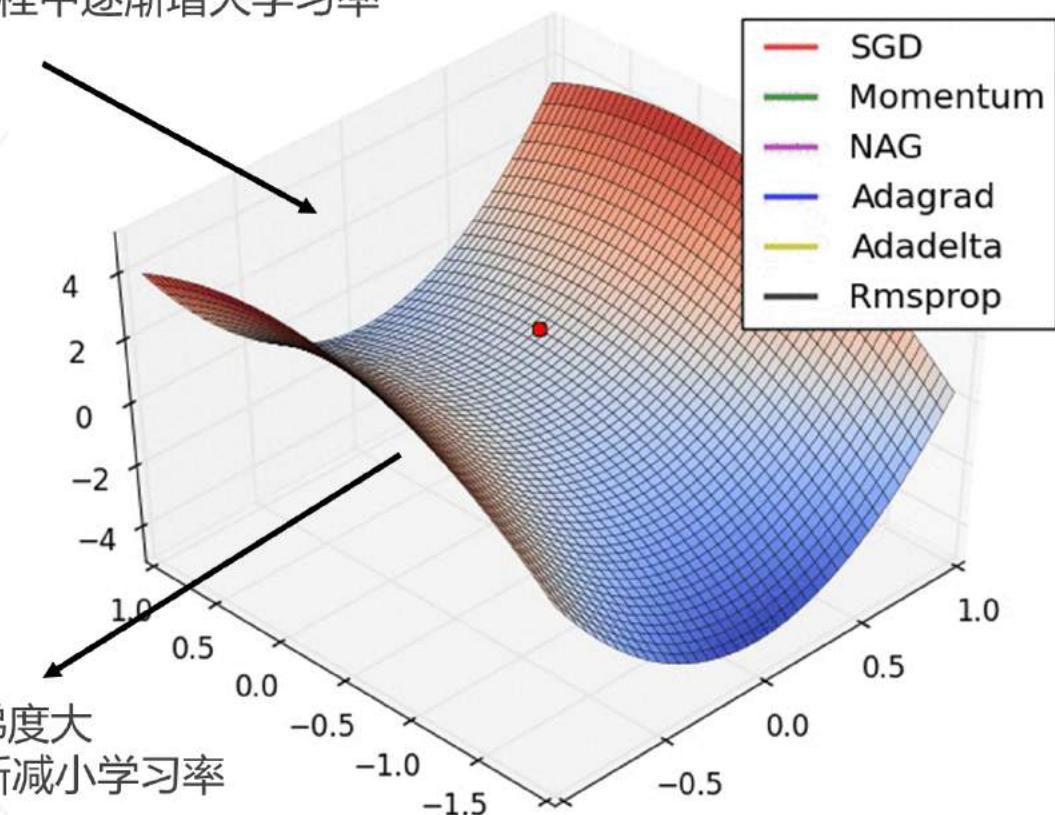
RMSProp

ADAM

.....

X 方向，初始梯度小
训练过程中逐渐增大学习率

Y 方向，初始梯度大
训练过程中逐渐减小学习率



针对卷积层和全连接层，初始化连接权重 W 和偏置 b

➤ 随机初始化

1. 朴素方法：依照均匀分布或高斯分布

$$W_{ij}, b_i \sim U(-a, a) \text{ or } W_{ij}, b_i \sim \mathcal{N}(0, \sigma^2) \quad a = \sqrt{3}\sigma \Rightarrow \text{方差相同}$$

2. Xavier 方法 (2010)：前传时维持激活值的方差，反传维持梯度的方差

$$a = \sqrt{6/(\text{fan}_{\text{in}} + \text{fan}_{\text{out}})} \text{ or } \sigma = \sqrt{2/(\text{fan}_{\text{in}} + \text{fan}_{\text{out}})}$$

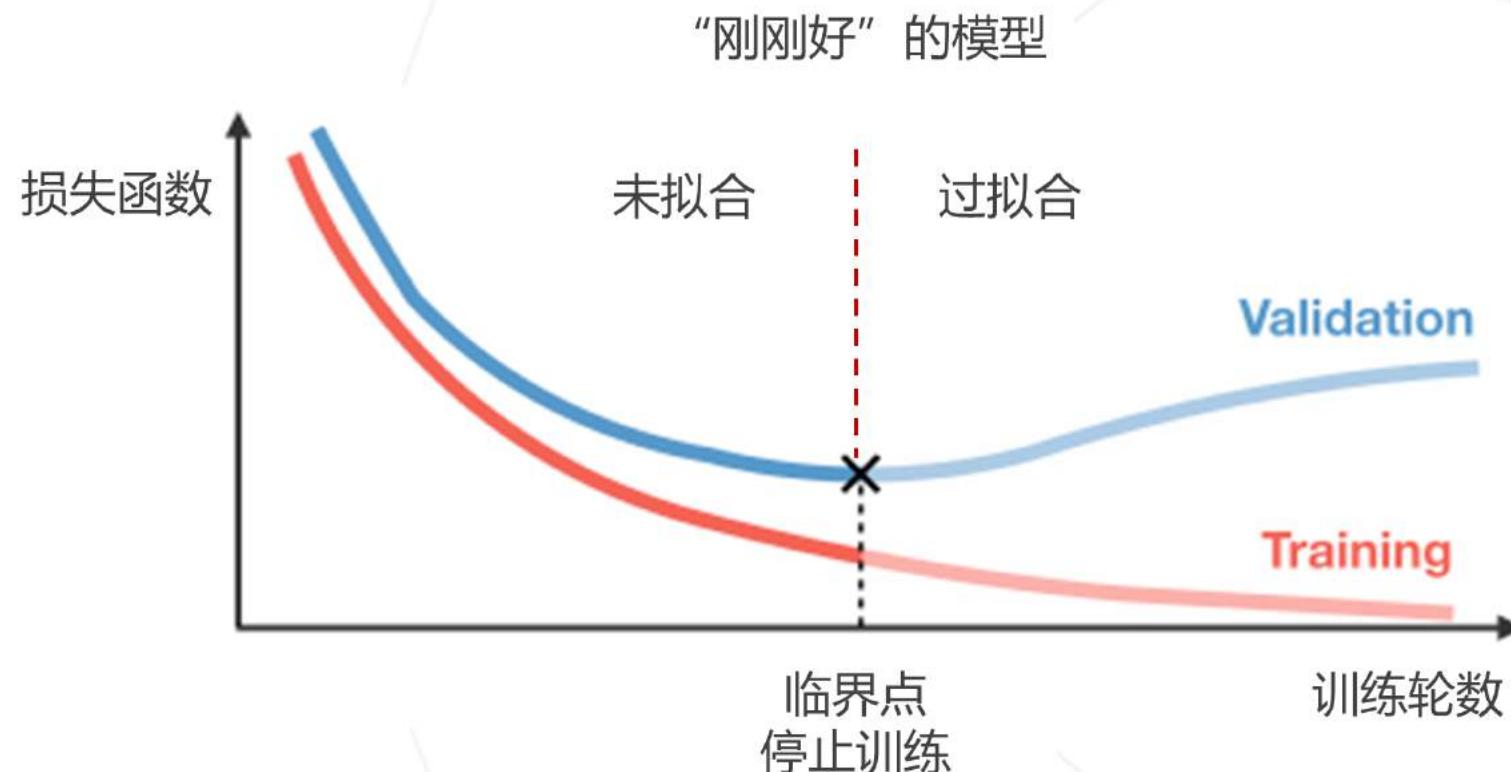
3. Kaiming 方法 (2015)：同上，但针对 ReLU 激活函数

$$a = \sqrt{6/n} \text{ or } \sigma = \sqrt{2/n} , \text{ here } n = \text{fan}_{\text{in}} \text{ or } \text{fan}_{\text{out}}$$

- 用训练好的模型（通常基于ImageNet数据集）进行权重初始化
 - 替换预训练模型的分类头，进行微调训练 (finetune)

将训练数据集划分为训练集和验证集，在训练集上训练，周期性在验证集上测试。

当验证集的 loss 不降反升时，停止训练，防止过拟合。



- 在损失函数中引入正则化项，以鼓励训练出相对简单的模型：

$$R(\Theta) = L(\Theta | \mathcal{D}) + \frac{1}{2} \lambda \|\Theta\|_2^2$$

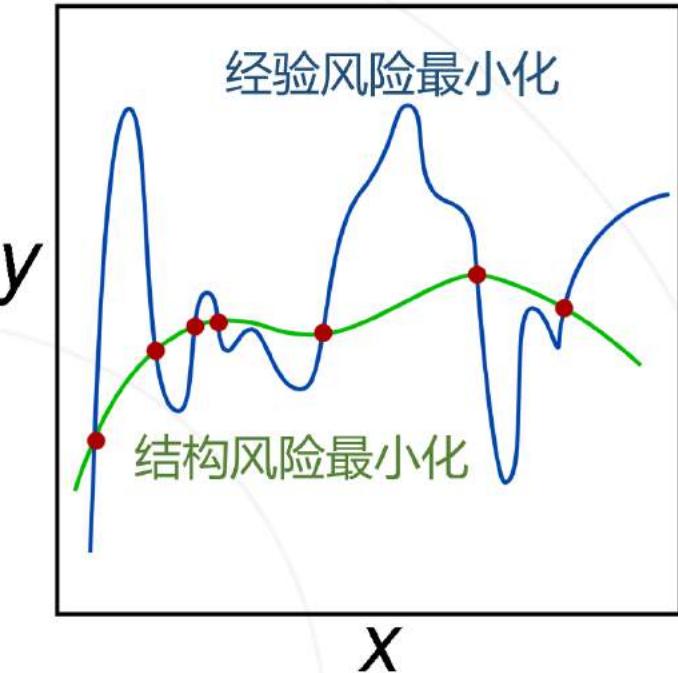
- 结构风险的梯度：

$$\nabla_{\Theta} R = \nabla_{\Theta} L + \lambda \Theta$$

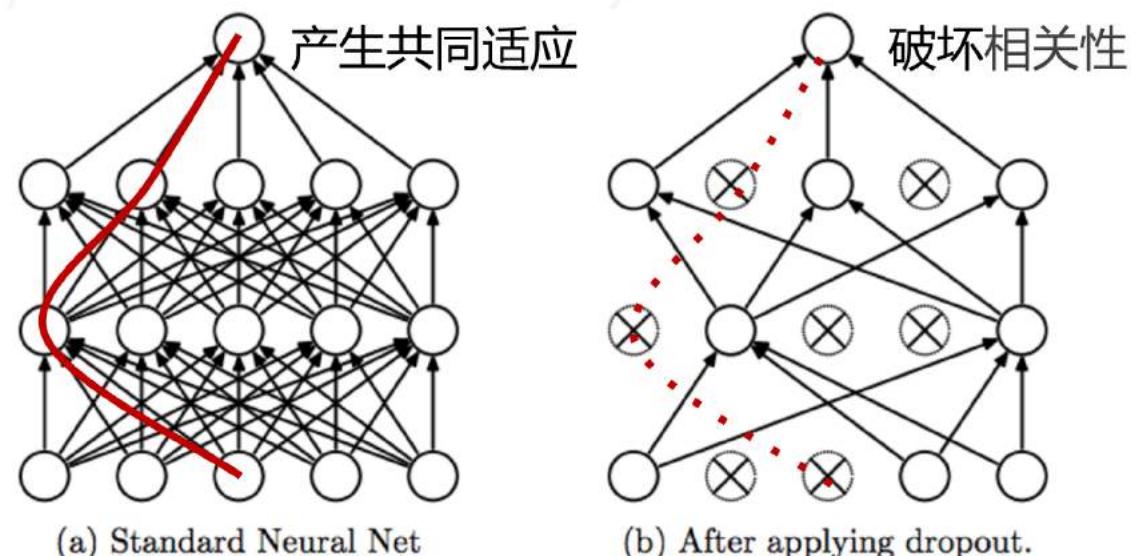
- 梯度更新策略：

$$\begin{aligned}
 \Theta^{(t)} &= \Theta^{(t-1)} - \eta \nabla_{\Theta} R(\Theta^{(t-1)}) \\
 &= \Theta^{(t-1)} - \eta \nabla_{\Theta} L(\Theta^{(t-1)}) - \lambda \eta \Theta^{(t-1)} \\
 &= \boxed{(1 - \lambda \eta)} \Theta^{(t-1)} - \boxed{\eta \nabla_{\Theta} L(\Theta^{(t-1)})}
 \end{aligned}$$

权重衰减 常规梯度下降

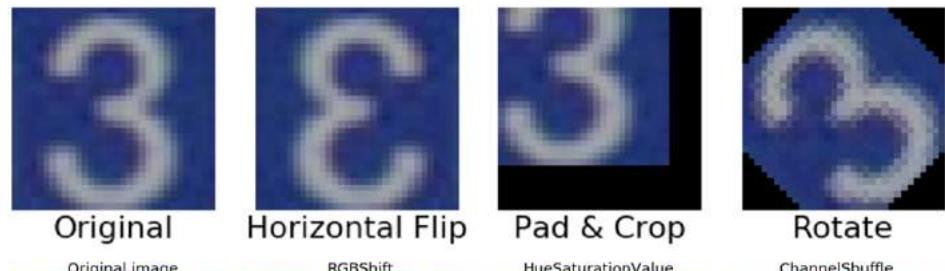


- 神经网络在训练时会出现共适应现象 (co-adaption), 神经元之间产生高度关联, 导致过拟合
- 训练时随机丢弃一些连接, 破坏神经元之间的关联, 鼓励学习独立的特征
- 推理时使用全部连接
- 常用于全连接层



- 泛化性好的模型 \leftarrow 大量多样化的数据
- 数据的采集标注是有成本的
- 数据增广**
- 利用简单的随机变换，从一张图片扩充出多张图片

几何变换



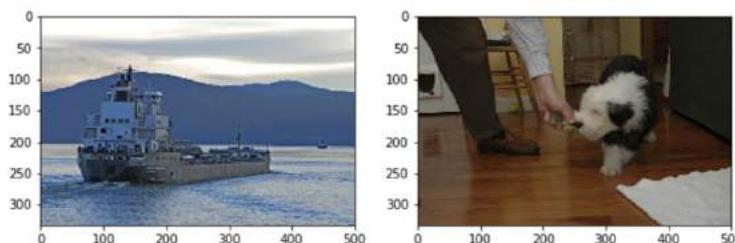
色彩变换



随机遮挡



将数据样本的线性组合作为数据进行训练，让网络看到更多的“数据”。

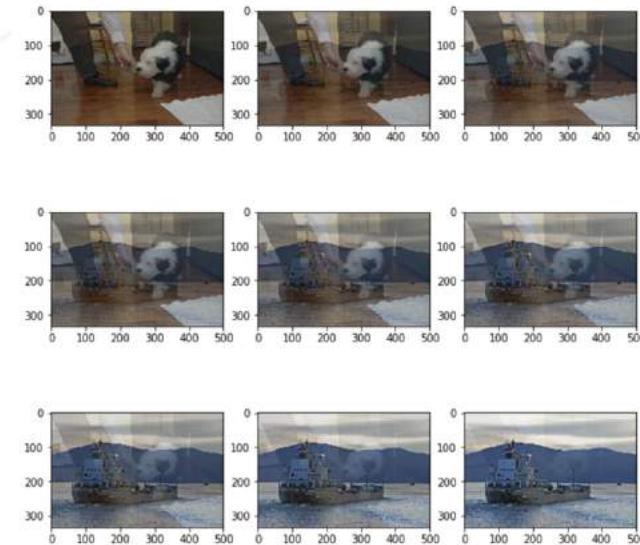


$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j$$



λ 取值从 0.1 到 0.9.



- 在一个 Batch 中，对神经元响应进行归一化，使每层的输出有相对稳定的数值分布。从而降低网络的学习难度，提高训练的稳定性，并允许使用更大的学习率。

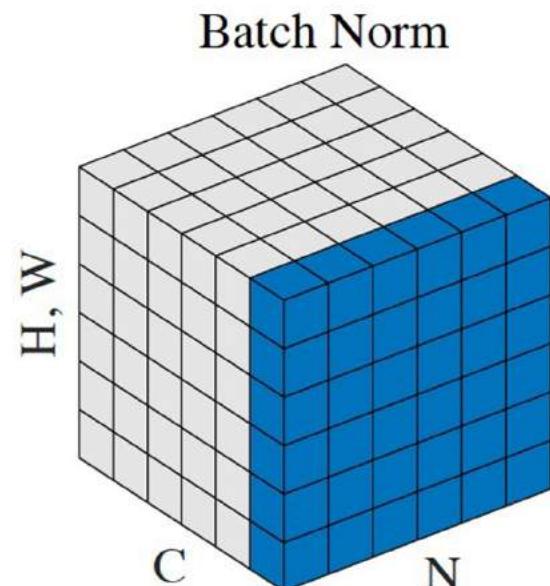
m 为 batch size

$$\mu = \frac{1}{m} \sum_{i=1}^m x_i, \quad \sigma^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu)^2$$

$$\hat{x}_i = \frac{x_i - \mu}{\sigma + \epsilon}, \quad y_i = \gamma \hat{x}_i + \beta$$

- 在归一化之后进行仿射变换扩大数值范围，方向和幅度的分解。
- 推理时没有 batch → 使用统计量的平均值。

- BN 一般用于卷积层：将同一通道内、不同空间位置、来自不同样本的所有响应值归为一组进行归一化
- 应用 BN 的卷积层一般不需要bias



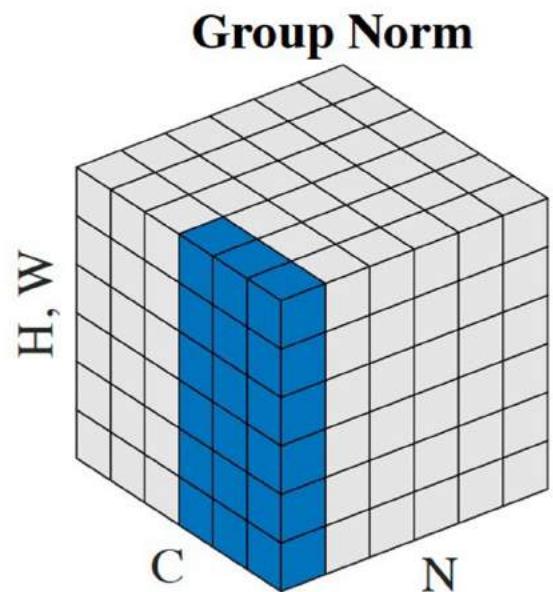
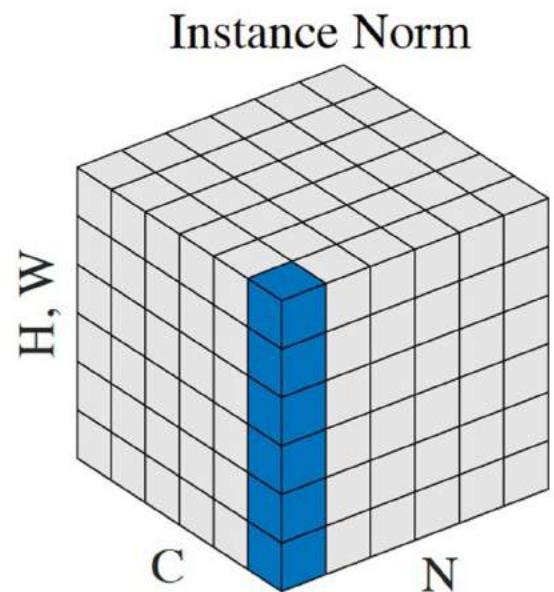
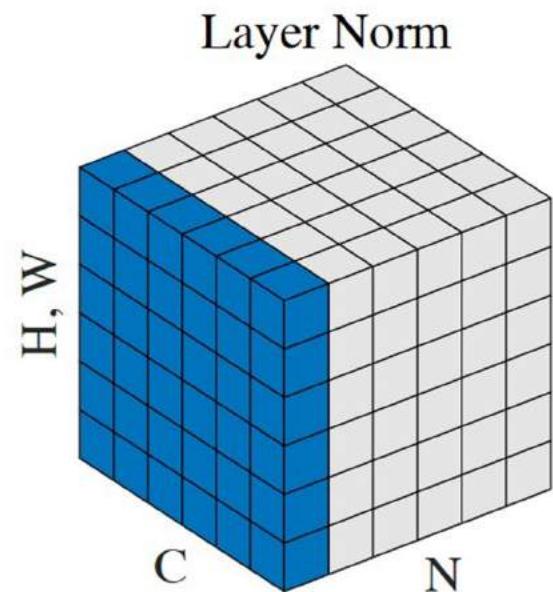
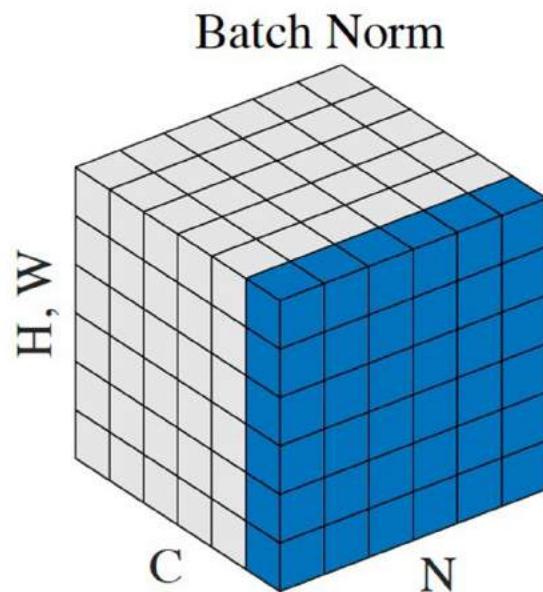
$$\mu_{\mathcal{B}}[c] = \frac{1}{m \times H \times W} \sum_{i=1}^m \sum_{h=1}^H \sum_{w=1}^W \mathbf{Z}_i[h, w, c]$$

$$\sigma_{\mathcal{B}}^2[c] = \frac{1}{m \times H \times W} \sum_{i=1}^m \sum_{h=1}^H \sum_{w=1}^W (\mathbf{Z}_i[h, w, c] - \mu_{\mathcal{B}}[c])^2$$

$$\hat{\mathbf{Z}}_i[h, w, c] = \frac{\mathbf{Z}_i[h, w, c] - \mu_{\mathcal{B}}[c]}{\sigma_{\mathcal{B}}[c]}$$

$$\mathbf{Y}_i[h, w, c] = \gamma[c] \cdot \hat{\mathbf{Z}}_i[h, w, c] + \beta[c]$$

z 前层输出
 i 样本序号
 h,w 空间坐标
 c 通道序号



- 随机梯度下降为主，各种经验策略辅助
- 损失函数高度不规则，非凸
 - 权重初始化：kaiming init，预训练模型
 - 优化器改进：动量 SGD、自适应梯度算法
 - 学习率策略：学习率退火、学习率升温
- 防止过拟合
 - 数据增广、早停、Dropout
 - Batch Normalization：稳定特征数据分布，降低训练难度

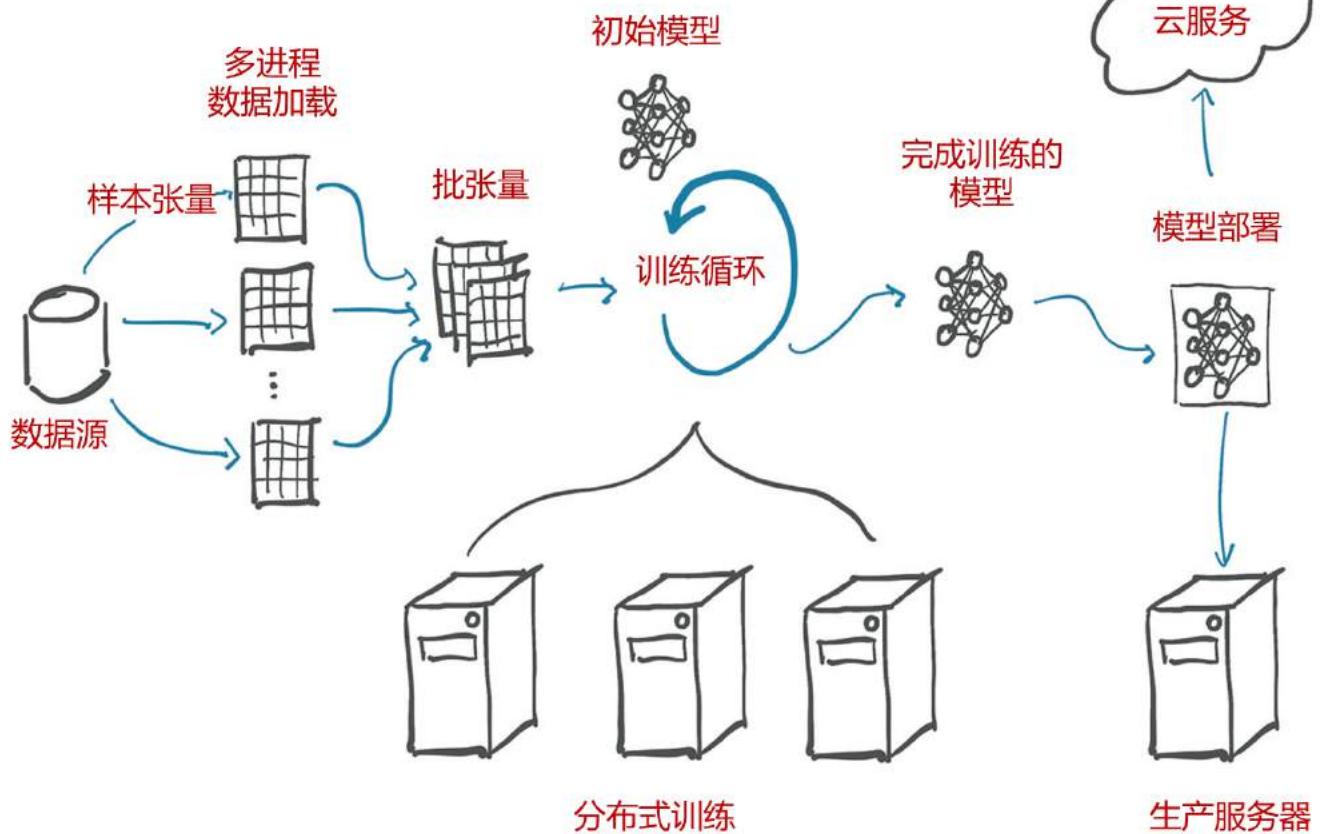
PyTorch 简介

PYTORCH

PyTorch 是由 Facebook 开发的开源深度学习框架。

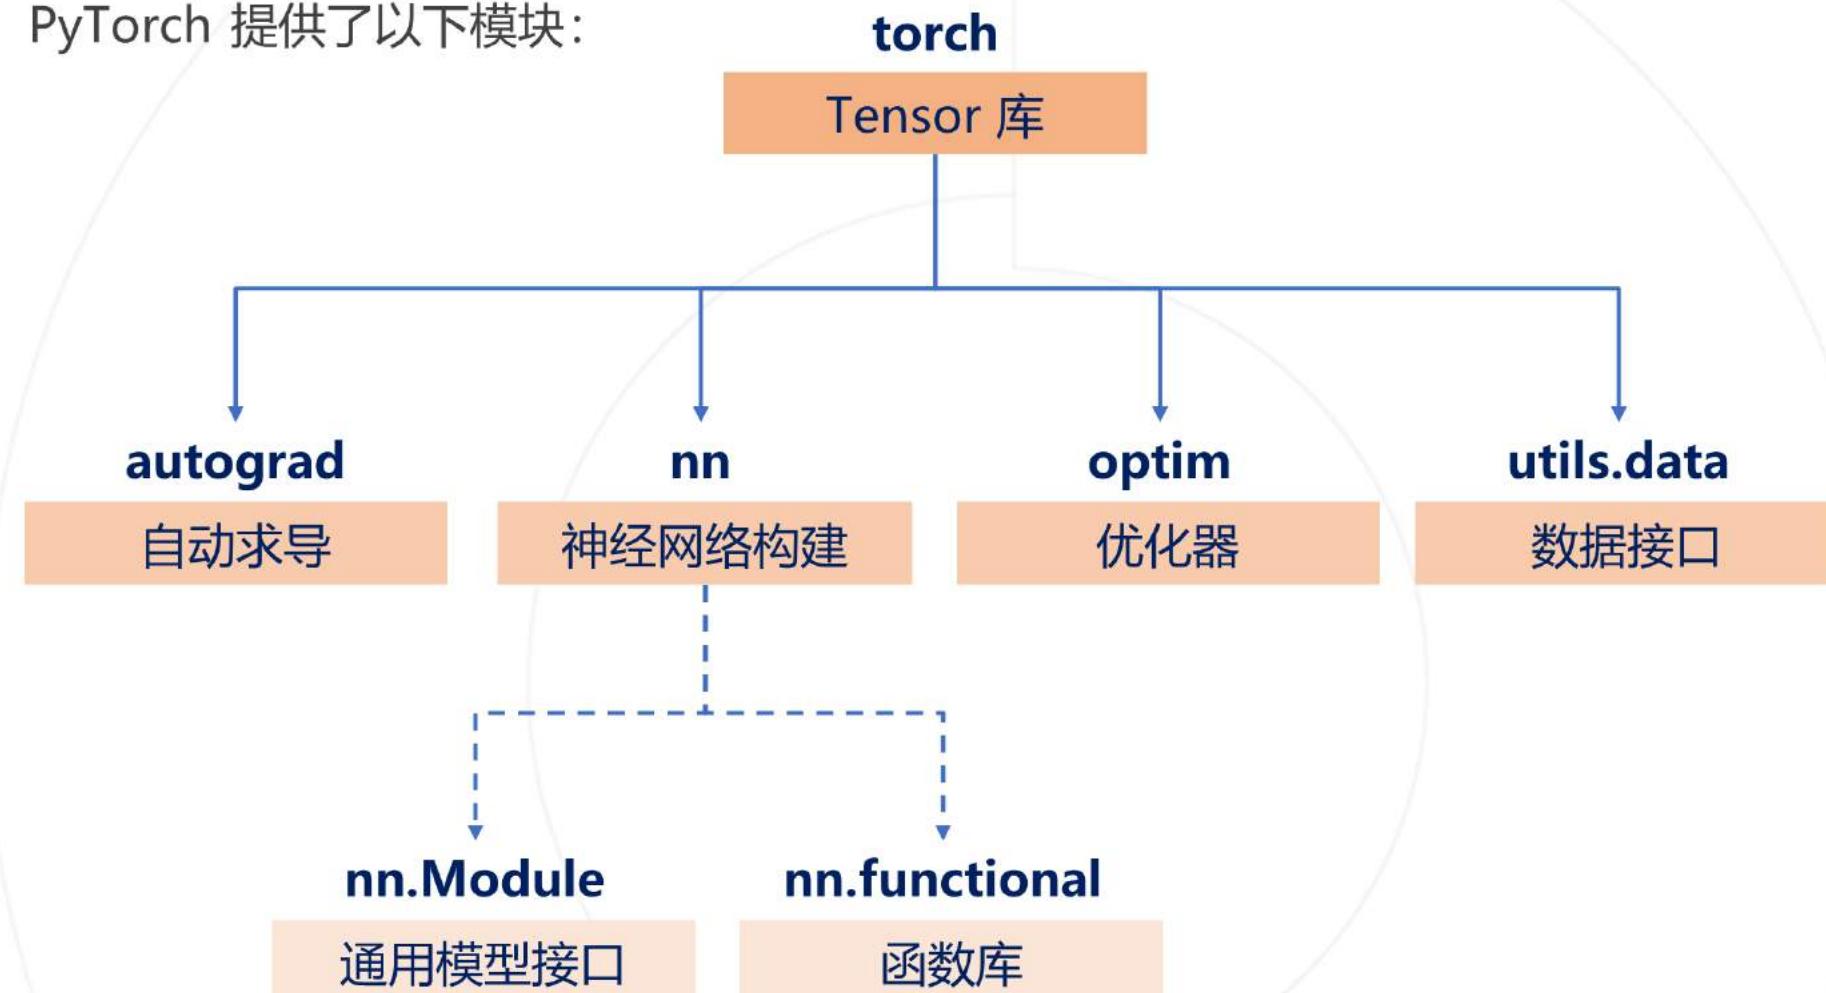
PyTorch 提供了完整的工具链用于构建、训练和部署深度学习模型。

<https://pytorch.org/>



使用 PyTorch 进行模型生产的流程

针对深度学习模型构建与训练，PyTorch 提供了以下模块：

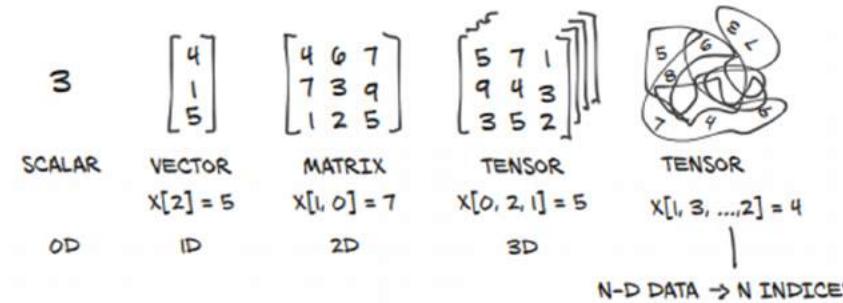


torch 库

多维数组的数据结构
Tensor

多维数组的运算

多计算后端支持

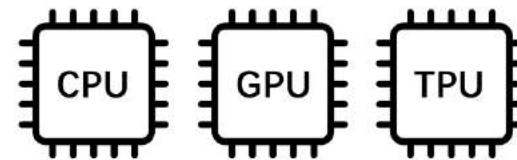


Two 2x2 tensors are added element-wise:

$$\begin{array}{|c|c|} \hline \text{data} & \text{ones} \\ \hline 1 & 2 \\ \hline 3 & 4 \\ \hline \end{array} + \begin{array}{|c|c|} \hline \text{data} & \text{ones} \\ \hline 1 & 1 \\ \hline 1 & 1 \\ \hline \end{array} = \begin{array}{|c|c|} \hline 2 & 3 \\ \hline 4 & 5 \\ \hline \end{array}$$

Two 2x2 tensors are added row-wise:

$$\begin{array}{|c|c|} \hline \text{data} & \text{ones_row} \\ \hline 1 & 2 \\ \hline 3 & 4 \\ \hline 5 & 6 \\ \hline \end{array} + \begin{array}{|c|c|} \hline \text{data} & \text{ones_row} \\ \hline 1 & 1 \\ \hline 1 & 1 \\ \hline \end{array} = \begin{array}{|c|c|} \hline 2 & 3 \\ \hline 4 & 5 \\ \hline 6 & 7 \\ \hline \end{array}$$



自动求导 torch.autograd

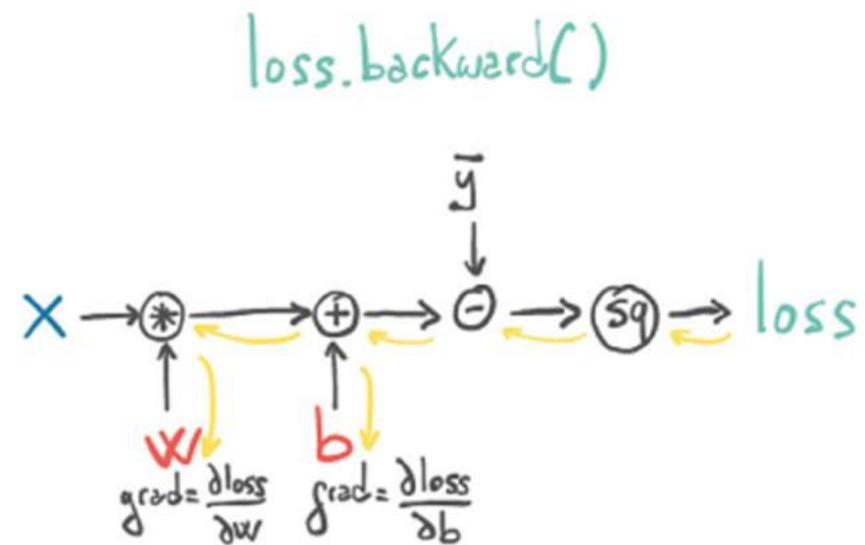
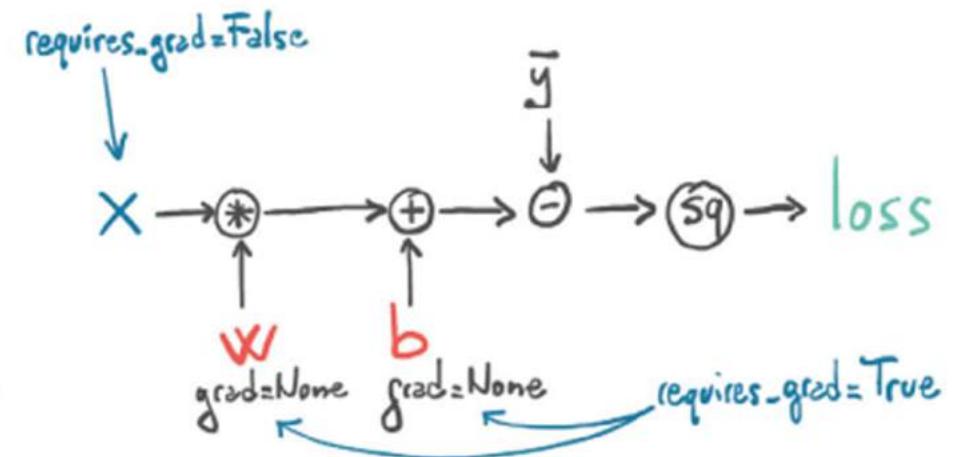
例：梯度下降求解线性回归：

$$L = \frac{1}{2} \sum_{i=1}^N (y_i - (w^T x_i + b))^2$$

借助 PyTorch 自动求导：

```
loss = 0.5 * (Y - X.T @ w - b) ** 2  
loss = loss.sum()  
loss.backward()
```

loss 对 w 和 b 的导数存储在 w.grad 和 b.grad 中



nn.functional 提供了构建神经网络所需的计算函数：

- 线性函数
- 卷积
- 池化
- 非线性激活
- 归一化
-

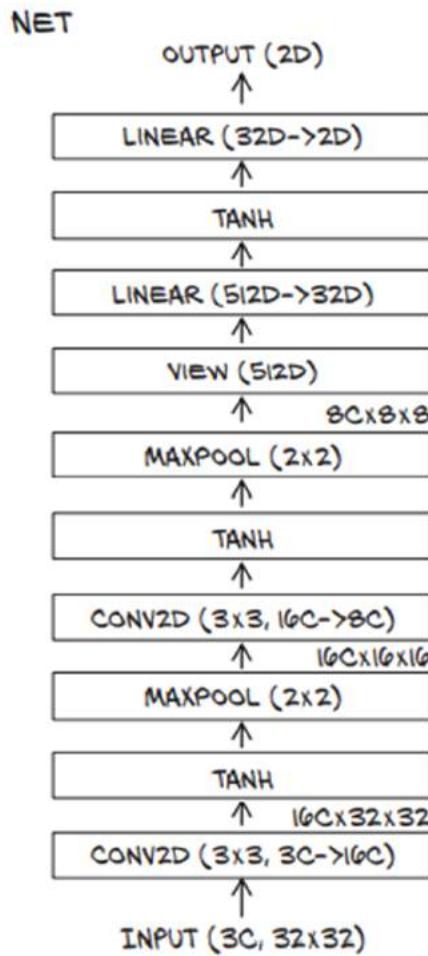
```
import torch
import torch.nn.functional as F

# ReLU non-linear activation
x = torch.randn(3, 3)
y = F.relu(x)

# Max Pooling
x = torch.randn(1, 1, 4, 4)
y = F.max_pool2d(x, kernel_size=2, stride=2)

# Convolution
img = torch.randn(1, 3, 8, 12)
weight = torch.randn(6, 3, 3, 3)
bias = torch.randn(6)
out = F.conv2d(img, weight, bias, padding=1)
```

torch.nn.Module 定义了神经网络模型的抽象接口



```

class Net(nn.Module):
    def __init__(self):
        super(Net, self).__init__()
        self.conv1 = nn.Conv2d(3, 16, kernel_size=3, padding=1)
        self.tanh1 = nn.Tanh()
        self.pool1 = nn.MaxPool2d(kernel_size=(2,2))
        self.conv2 = nn.Conv2d(16, 8, kernel_size=3, padding=1)
        self.tanh2 = nn.Tanh()
        self.pool2 = nn.MaxPool2d(kernel_size=(2,2))
        self.fc1 = nn.Linear(8*8*8, 32)
        self.tanh3 = nn.Tanh()
        self.fc2 = nn.Linear(32, 2)

    def forward(self, x):
        out = self.pool1(self.tanh1(self.conv1(x)))
        out = self.pool2(self.tanh2(self.conv2(out)))
        out = out.view(-1, 8*8*8)
        out = self.tanh3(self.fc1(out))
        out = self.fc2(out)
        return out
  
```

可调用对象 Callable object
`net = Net()`
`pred = net(img_batch)`

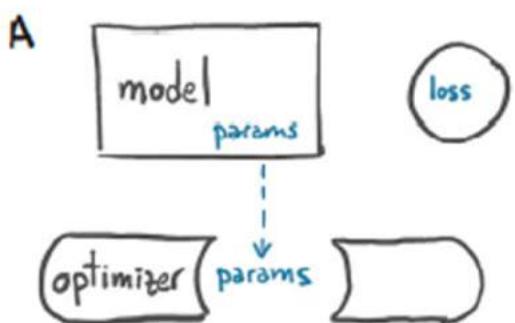
优化器 torch.optim

torch.optim 支持常用的优化算法

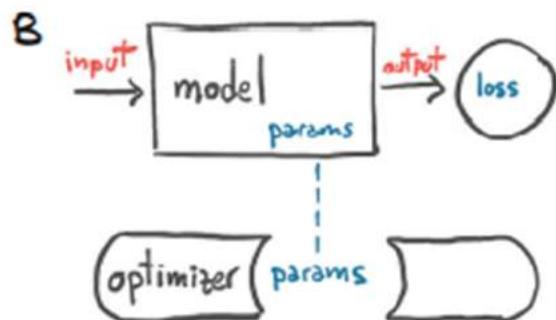
- SGD
- Adam
- RMSprop
-

以及常用的学习率策略

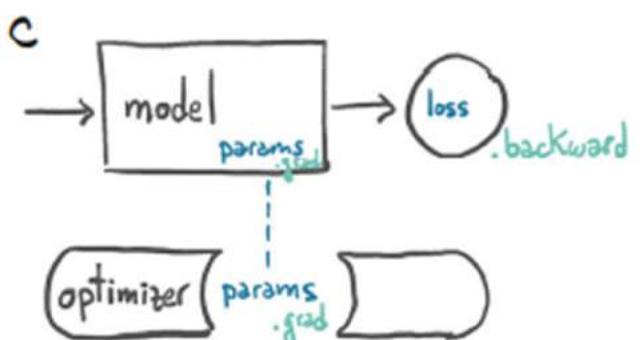
- 步长衰减
- 指数衰减
- 学习率循环
-



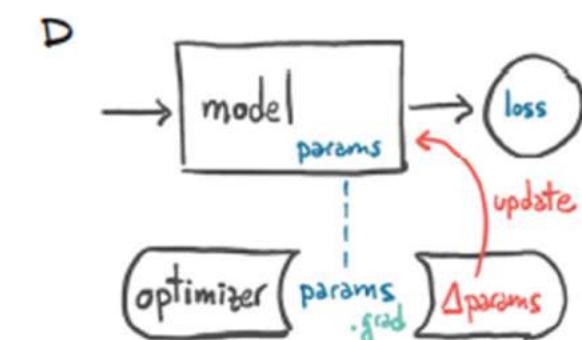
```
param = net.parameters()  
opt = SGD(param, lr = 0.1)
```



```
pred = net(img_batch)  
loss = loss_fn(pred, label)
```



```
loss.backward()
```

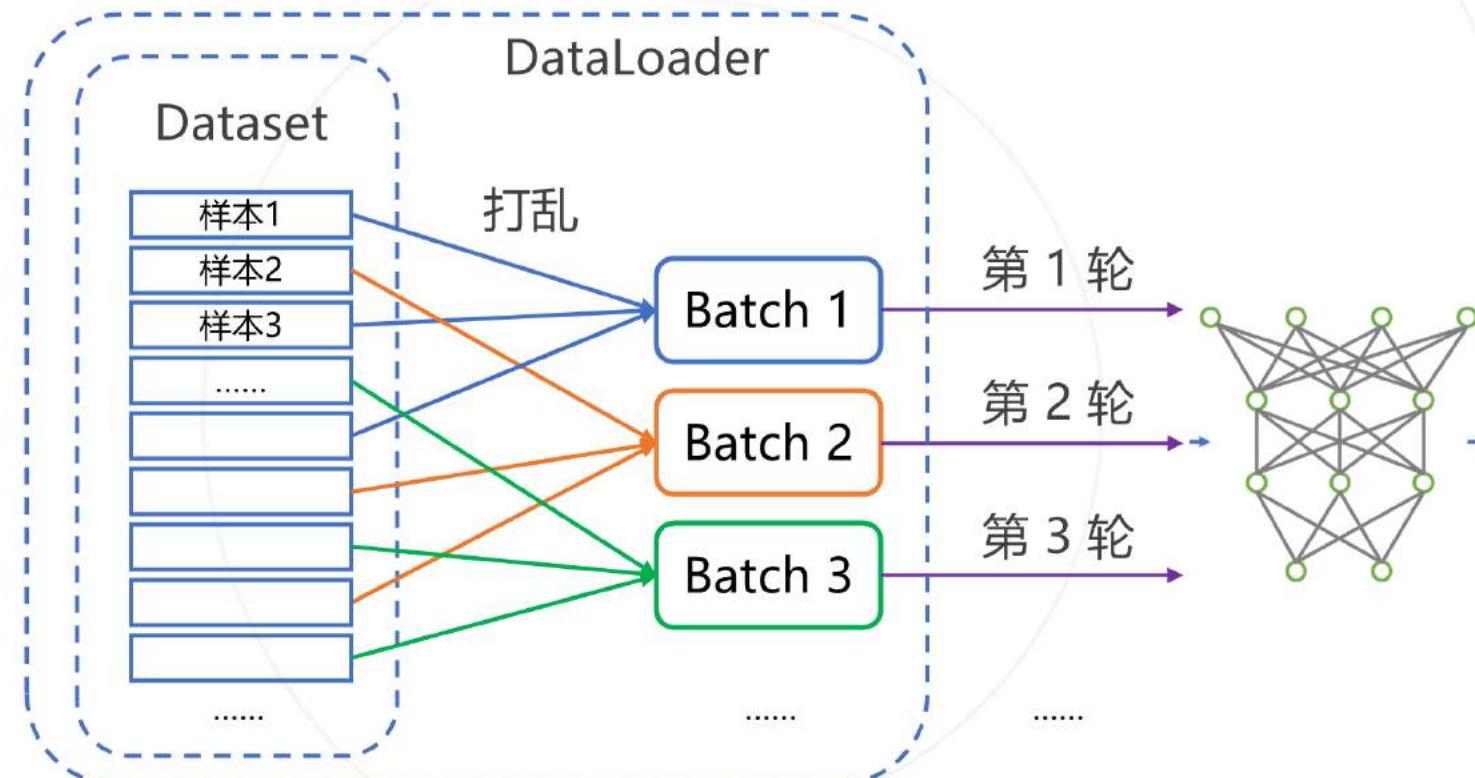


```
opt.step()
```

torch.utils.data 统一方便的数据集模型 Dataset

以及支持多线程预读的数据加载器 DataLoader。

```
for i, data_batch in enumerate(dataloader):
    # process data_batch
    data, label = data_batch
    out = model(data)
    loss = loss_fn(out, label)
    loss.backward()
    opt.step()
```



MMClassification

MMClassification

丰富的模型

VGG VGG-BN	ResNet ResNet V1D	ResNeXt ShuffleNet	SE-ResNet ShuffleNet V2 MobileNet V2	ResNeSt	ViT
2014	2015	2017	2018	2020	2021

丰富的数据集支持

CIFAR10
ImageNet
.....

丰富的训练
技巧与策略

数据增强策略
优化器和学习率 策略

<https://github.com/open-mmlab/mmclassification>

open-mmlab / mmclassification

Watch 23 Star 577 Fork 163

Code Issues 30 Pull requests 11 Actions Projects Wiki Security ...

master Go to file Add file Code About

HIT-cwh [Bug]Fix label smooth bug (#203) ...	✓ 4 hours ago	⌚ 242
.github	[Fix] Update pip install mmcv command in ci (#1...)	15 days ago
configs	[Bug]Fix label smooth bug (#203)	4 hours ago
demo	Visualize results on image demo (#58)	6 months ago
docs	Add simplify option in pytorch2onnx.py and Upd...	4 days ago
mmcls	[Bug]Fix label smooth bug (#203)	4 hours ago
requirements	bump version to 0.10.0 (#194)	12 days ago
resources	Add README	9 months ago

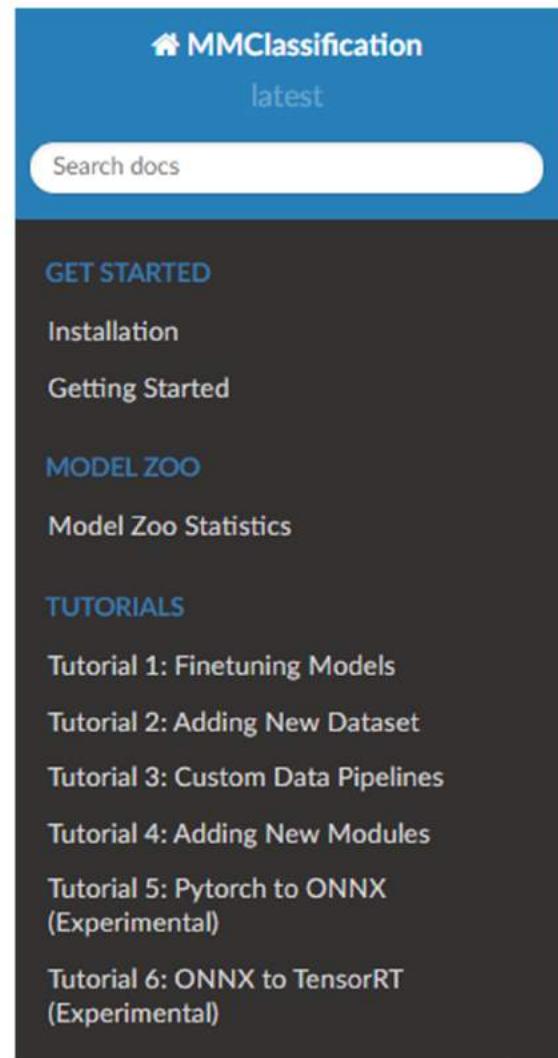
文档链接

[mmclassification.readthedoc...](#)

pytorch imagenet
image-classification resnet
resnext mobilenet
shufflenet senet regnet

Readme
Apache-2.0 License

<https://mmclassification.readthedocs.io/en/latest/>



Docs » Welcome to MMClassification's documentation!

[Edit on GitHub](#)

Welcome to MMClassification's documentation!

Get Started

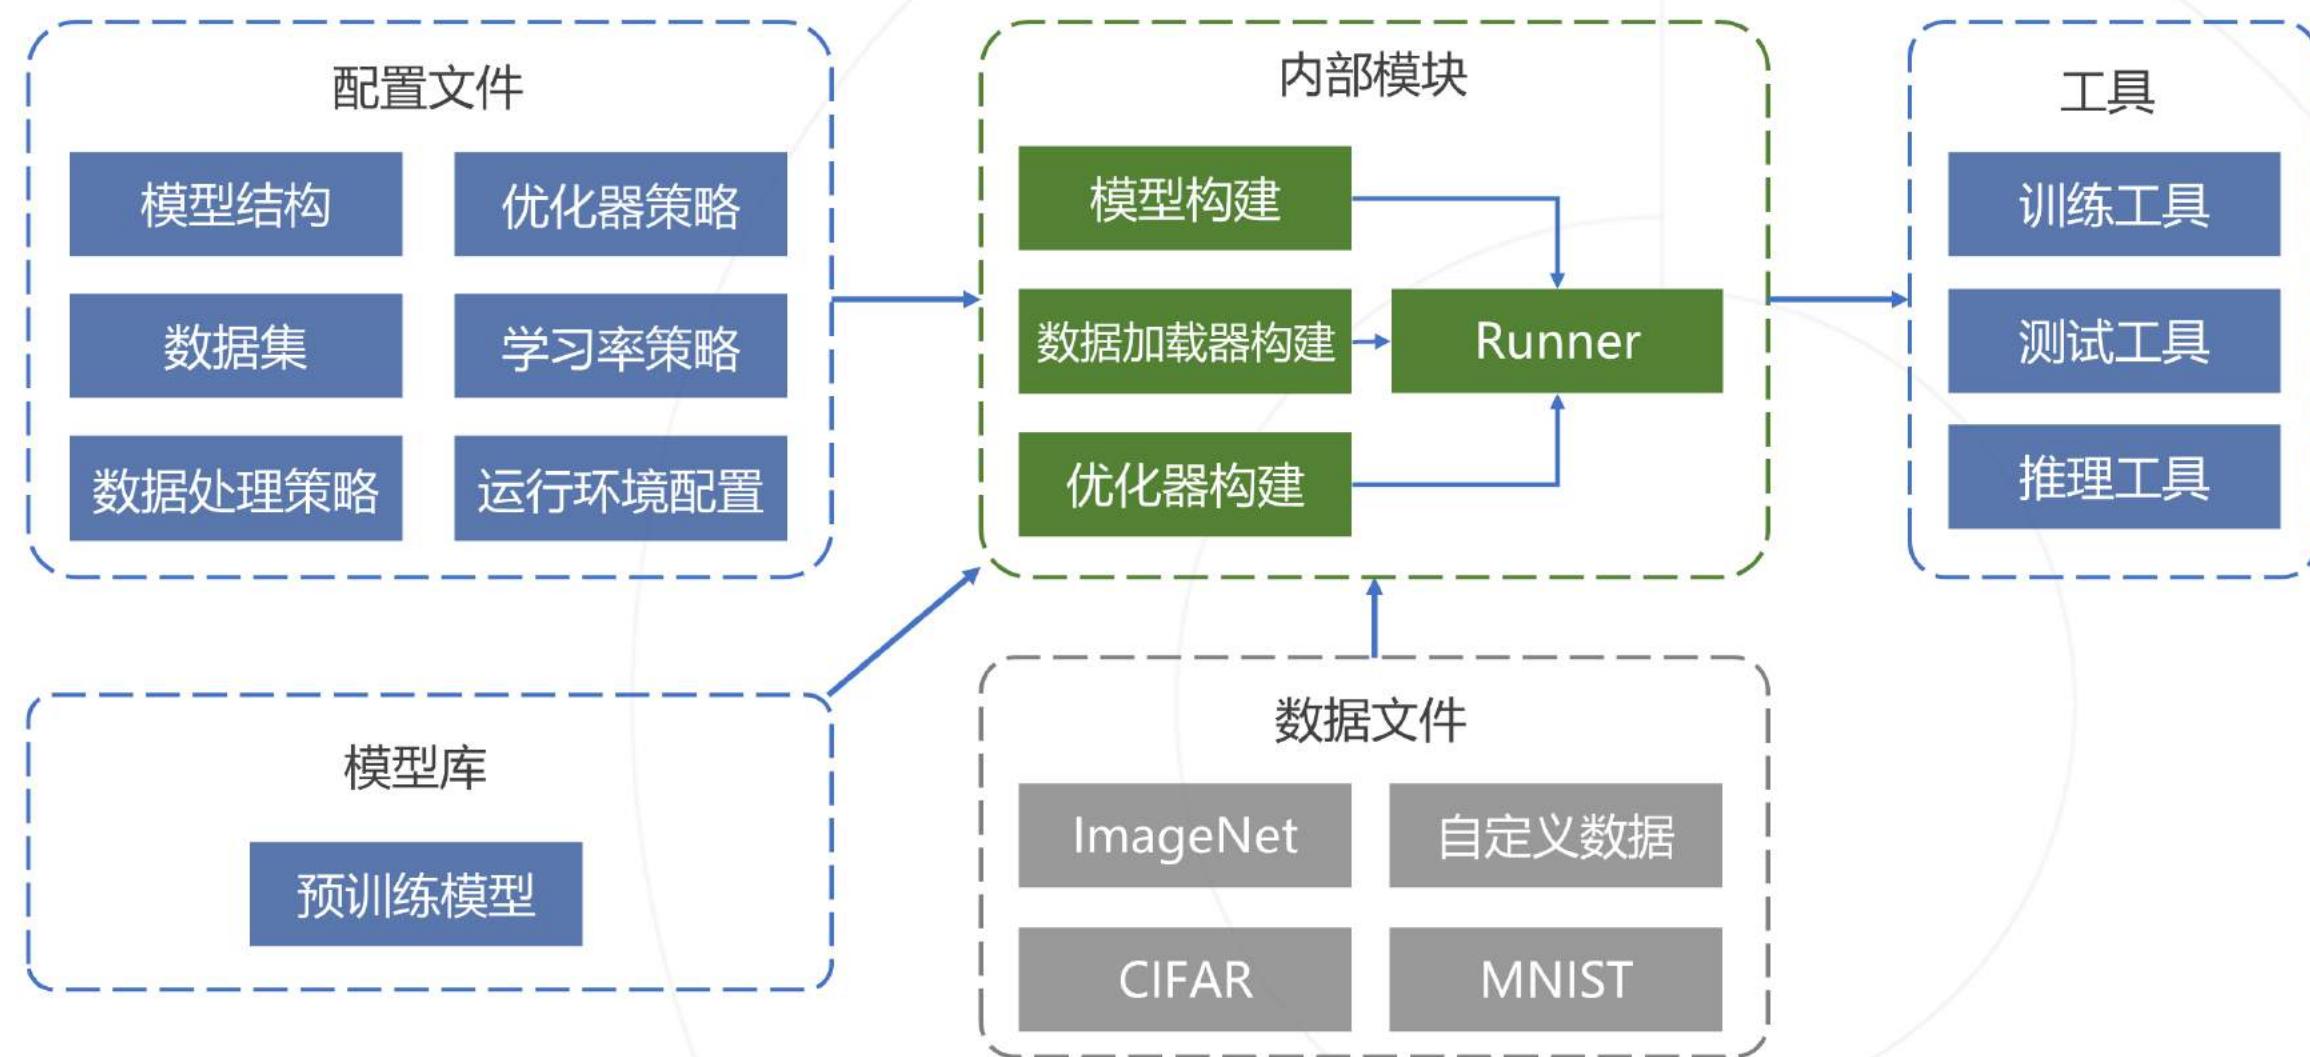
- Installation
 - Requirements
 - Install MMClassification
 - Using multiple MMClassification versions
- Getting Started
 - Prepare datasets
 - Inference with pretrained models
 - Train a model
 - Useful tools
 - Tutorials

安装文档

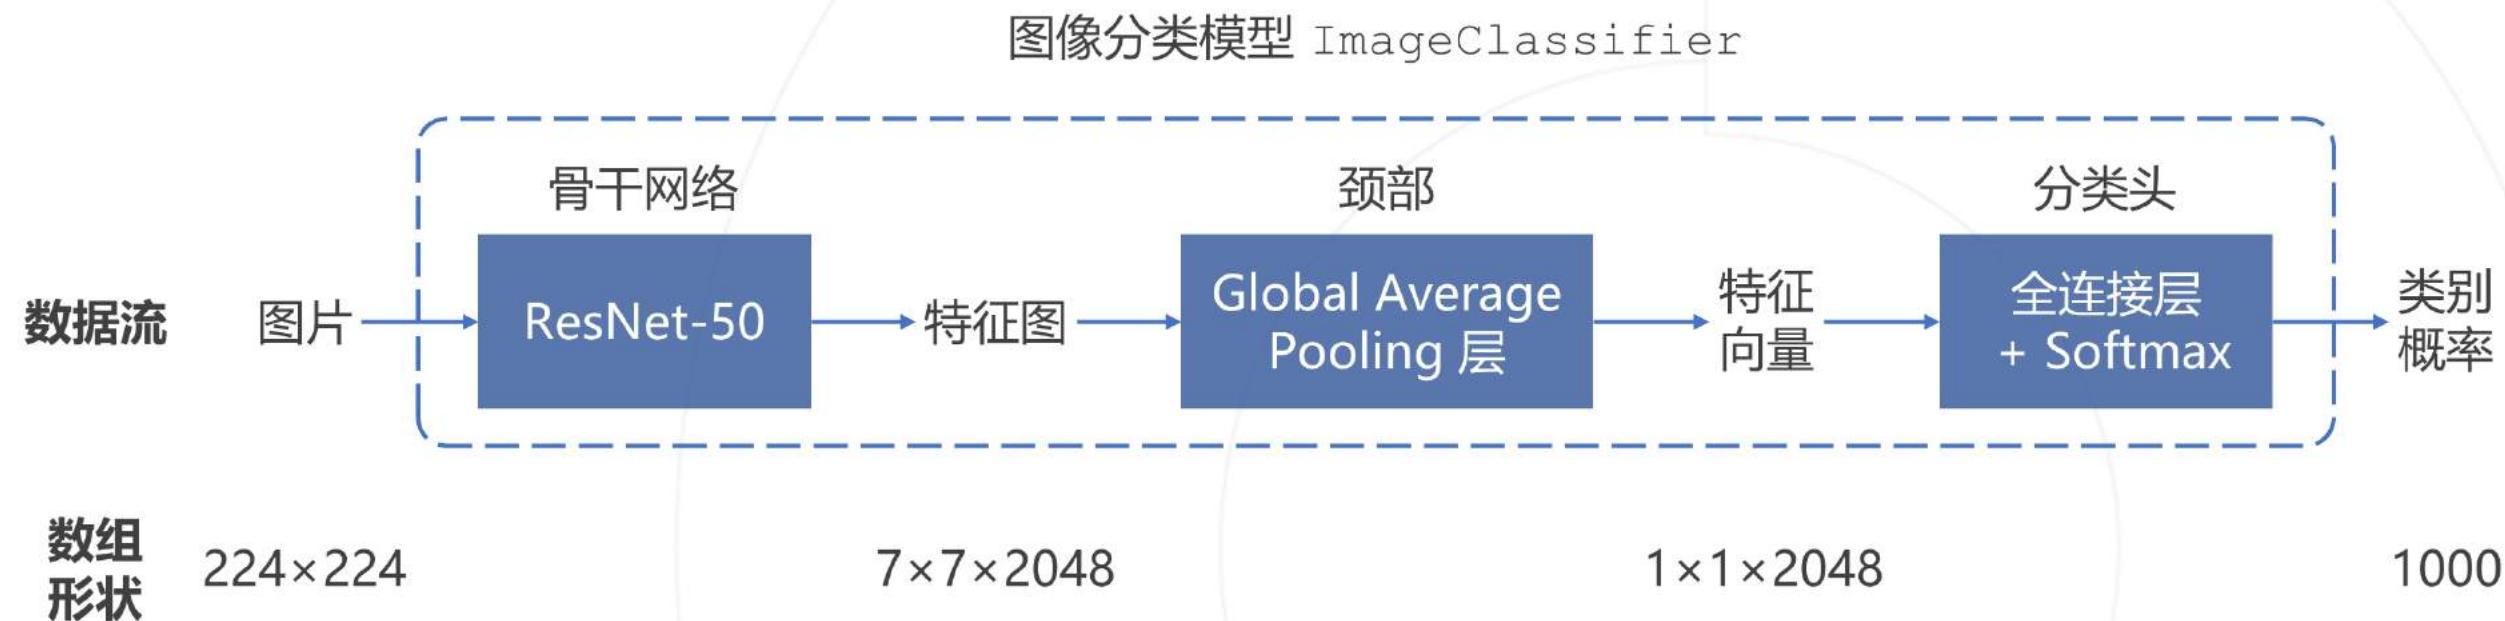
Model zoo

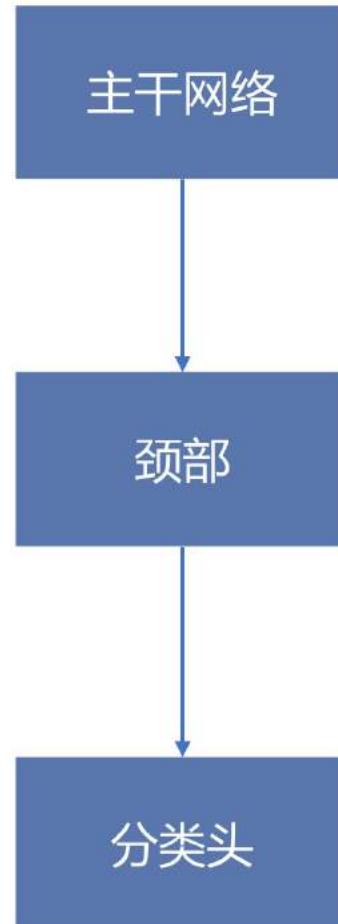
- Model Zoo Statistics

模型库



也适用于其他 OpenMMLab 工具包





主干网络
ResNet 50 模型
使用全部4组卷积层
并输出最后一个卷积层的特征
使用v1b结构变体
全局平均池化 **颈部**
分类头
单层线性分类头
目标类别1000类
输入特征维度2048
使用交叉熵损失函数

模型

```
model = dict(  
    type='ImageClassifier',  
    backbone=dict(  
        type='ResNet',  
        depth=50,  
        num_stages=4,  
        out_indices=(3, ),  
        style='pytorch'),  
    neck=dict(type='GlobalAveragePooling'),  
    head=dict(  
        type='LinearClsHead',  
        num_classes=1000,  
        in_channels=2048,  
        loss=dict(type='CrossEntropyLoss',  
            loss_weight=1.0)),  
)
```

DataLoader

Dataset

数据

设置 batch size

设置数据加载进程数

定义训练数据子集

ImageNet数据集类型

指定数据文件的路径

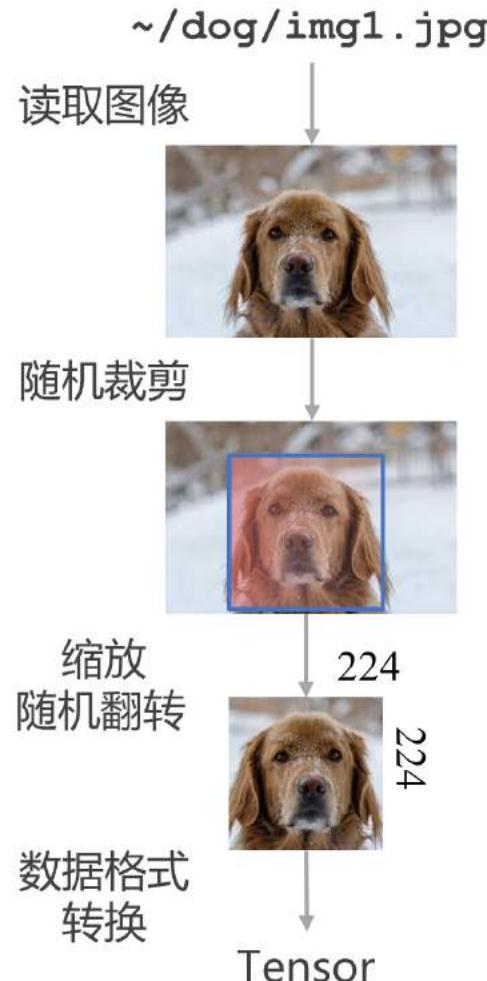
指定数据加载流水线

类似的方式

定义验证子集

和测试子集

```
data = dict(  
    samples_per_gpu=32,  
    workers_per_gpu=2,  
    train=dict(  
        type='ImageNet',  
        data_prefix='data/imagenet/train',  
        pipeline=[train_pipeline]),  
    val=dict(  
        # similar to train  
    ),  
    test=dict(  
        # similar to val  
    ),  
)
```



像素归一化的均值
和标准差

定义数据加载流水线

从文件中读取图像

随机裁剪与缩放

随机水平翻转

像素值归一化

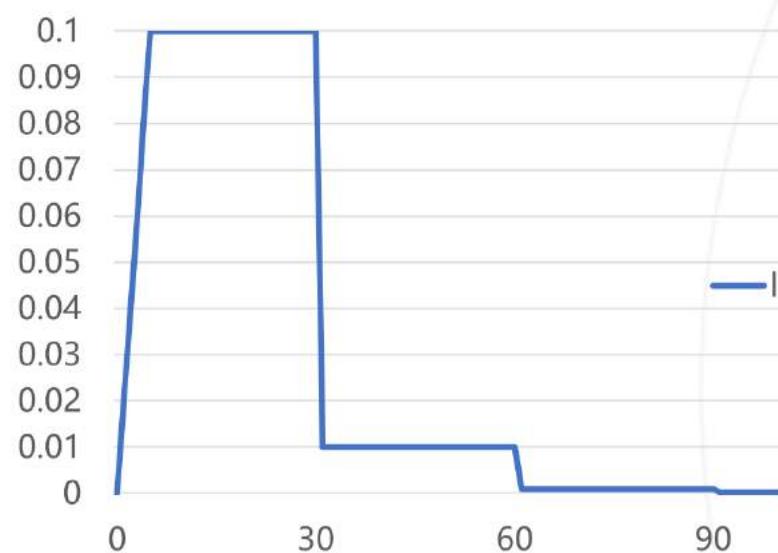
将数据转换为
PyTorch Tensor

```

img_norm_cfg = dict(
    mean=[123.675, 116.28, 103.53], std=[58.395,
    57.12, 57.375], to_rgb=True)
  
```

```

train_pipeline = [
    dict(type='LoadImageFromFile'),
    dict(type='RandomResizedCrop', size=224),
    dict(type='RandomFlip', flip_prob=0.5,
        direction='horizontal'),
    dict(type='Normalize', **img_norm_cfg),
    dict(type='ImageToTensor', keys=['img']),
    dict(type='ToTensor', keys=['gt_label']),
    dict(type='Collect', keys=['img', 'gt_label'])
]
  
```



优化器配置

使用 SGD 优化器

初始学习率 = 0.1

动量 = 0.9

权重衰减 = 0.0001

学习率策略

使用步长下降策略

在特定周期降低学习率至 1/10

使用线性 warmup 策略

5个周期的 warmup

运行器 Runner 设置

基于轮数的运行器

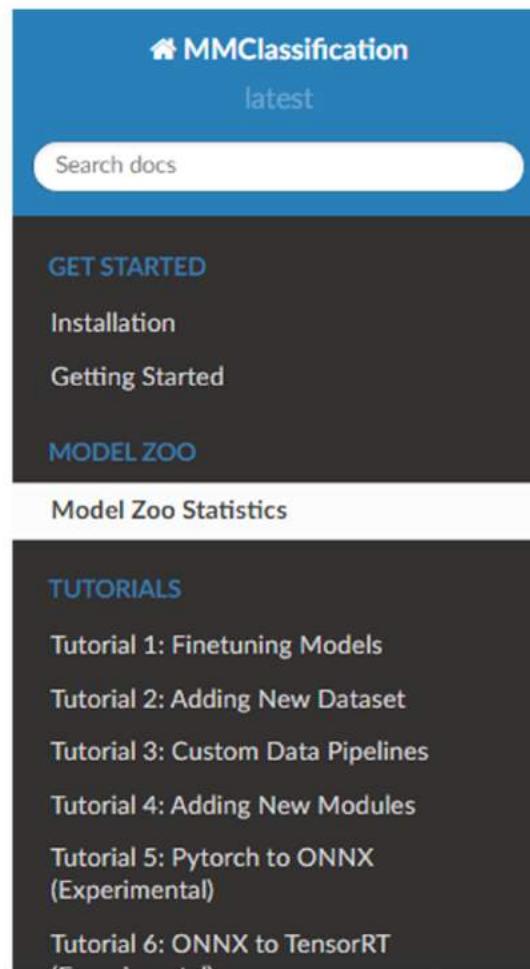
最多训练 100 轮

```
optimizer = dict(  
    type='SGD',  
    lr=0.1,  
    momentum=0.9,  
    weight_decay=0.0001)
```

```
lr_config = dict(  
    policy='step',  
    step=[30, 60, 90],  
    by_epoch=True,  
    warmup='Linear',  
    warmup_iters=5  
)
```

```
runner = dict(  
    type='EpochBasedRunner',  
    max_epochs=100  
)
```

https://mmclassification.readthedocs.io/en/latest/modelzoo_statistics.html



Docs » Model Zoo Statistics

[Edit on GitHub](#)

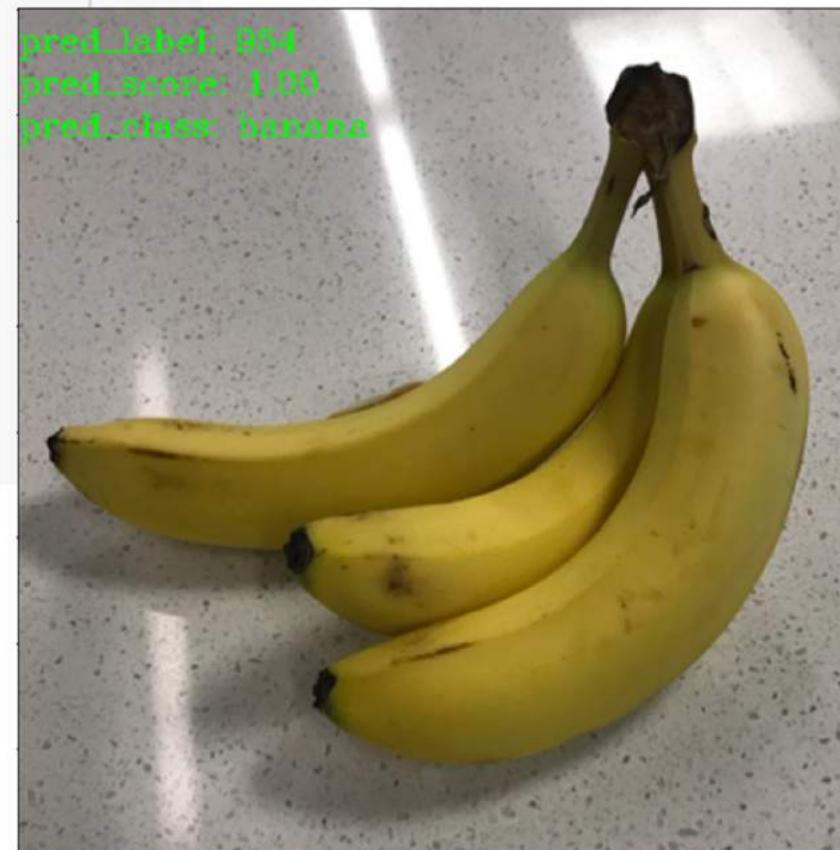
Model Zoo Statistics

- Number of papers: 8
 - ALGORITHM: 7
 - OTHERS: 1
- Number of checkpoints: 31
 - [OTHERS] Mixed Precision Training (1 ckpts)
 - [ALGORITHM] MobileNetV2: Inverted Residuals and Linear Bottlenecks (1 ckpts)
 - [ALGORITHM] Deep Residual Learning for Image Recognition (13 ckpts)
 - [ALGORITHM] Aggregated Residual Transformations for Deep Neural Networks (4 ckpts)
 - [ALGORITHM] Squeeze-and-Excitation Networks (2 ckpts)
 - [ALGORITHM] ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices (1 ckpts)
 - [ALGORITHM] Shufflenet v2: Practical guidelines for efficient cnn architecture design (1 ckpts)
 - [ALGORITHM] Very Deep Convolutional Networks for Large-Scale Image Recognition (8 ckpts)

```
from mmcls.apis import inference_model, init_model, show_result_pyplot

# Specify the path to config file and checkpoint file
config_file = 'configs/mobilenet_v2/mobilenet_v2_b32x8_imagenet.py'
checkpoint_file = 'checkpoints/mobilenet_v2_batch256_imagenet_20200708-3b2dc3af.pth'
# Specify the device. You may also use cpu by `device='cpu'`.
device = 'cuda:0'
# Build the model from a config file and a checkpoint file
model = init_model(config_file, checkpoint_file, device=device)
# Test a single image
img = 'demo/banana.png'
result = inference_model(model, img)
# Show the results
show_result_pyplot(model, img, result)
```

```
{'pred_class': 'banana',
 'pred_label': 954,
 'pred_score': 0.9999284744262695}
```



单张图像推理

```
python demo/image_demo.py ${IMAGE_FILE} ${CONFIG_FILE} ${CHECKPOINT_FILE}
```

整个数据集推理

- 单机单卡

```
python tools/inference.py ${CONFIG_FILE} ${CHECKPOINT_FILE} [--out ${RESULT_FILE}]
```

- 分布式推理

```
./tools/dist_inference.sh ${CONFIG_FILE} ${CHECKPOINT_FILE} ${GPU_NUM} [--out ${RESULT_FILE}]
```

举例：

假设预训练模型已经存放至checkpoints文件夹，基于ResNet50推理ImageNet的验证集的示例如下：

```
python tools/inference.py configs/imagenet/resnet50_batch256.py checkpoints/xxx.pth
```

单卡训练

```
python tools/train.py ${CONFIG_FILE} [optional arguments]
```

分布式训练

```
./tools/dist_train.sh ${CONFIG_FILE} ${GPU_NUM} [optional arguments]
```

支持任务调度器 Slurm

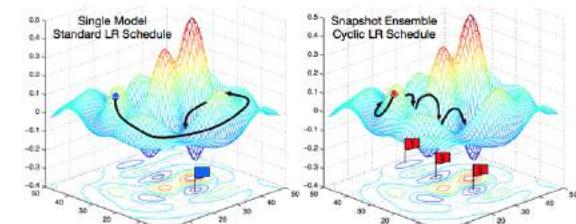
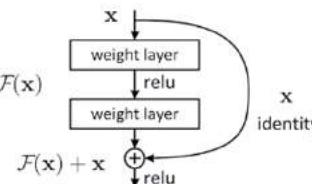
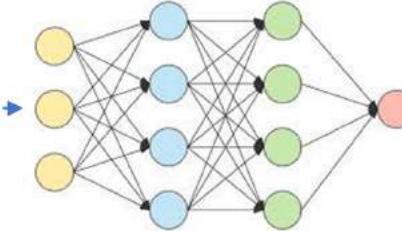
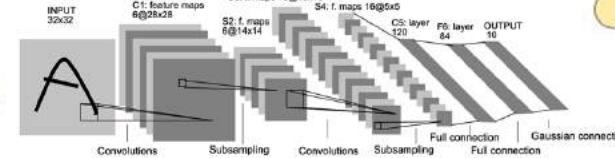
在通过slurm管理的集群上训练，可以使用slurm_train.sh脚本：

```
[GPUS=${GPUS}] ./tools/slurm_train.sh ${PARTITION} ${JOB_NAME} ${CONFIG_FILE} ${WORK_DIR}
```

- 机器学习视角下的图像分类
- 多层感知机
- 卷积神经网络
- 图像分类模型设计**
- 图像分类模型训练**
- PyTorch 介绍
- MMClassification 图像分类框架**

$$\mathcal{H} = \{h(x; \theta) \mid \theta \in \Theta\}$$

$$h^* = \underset{h \in \mathcal{H}}{\operatorname{argmin}} \mathcal{L}(h | \mathcal{D})$$



PYTORCH

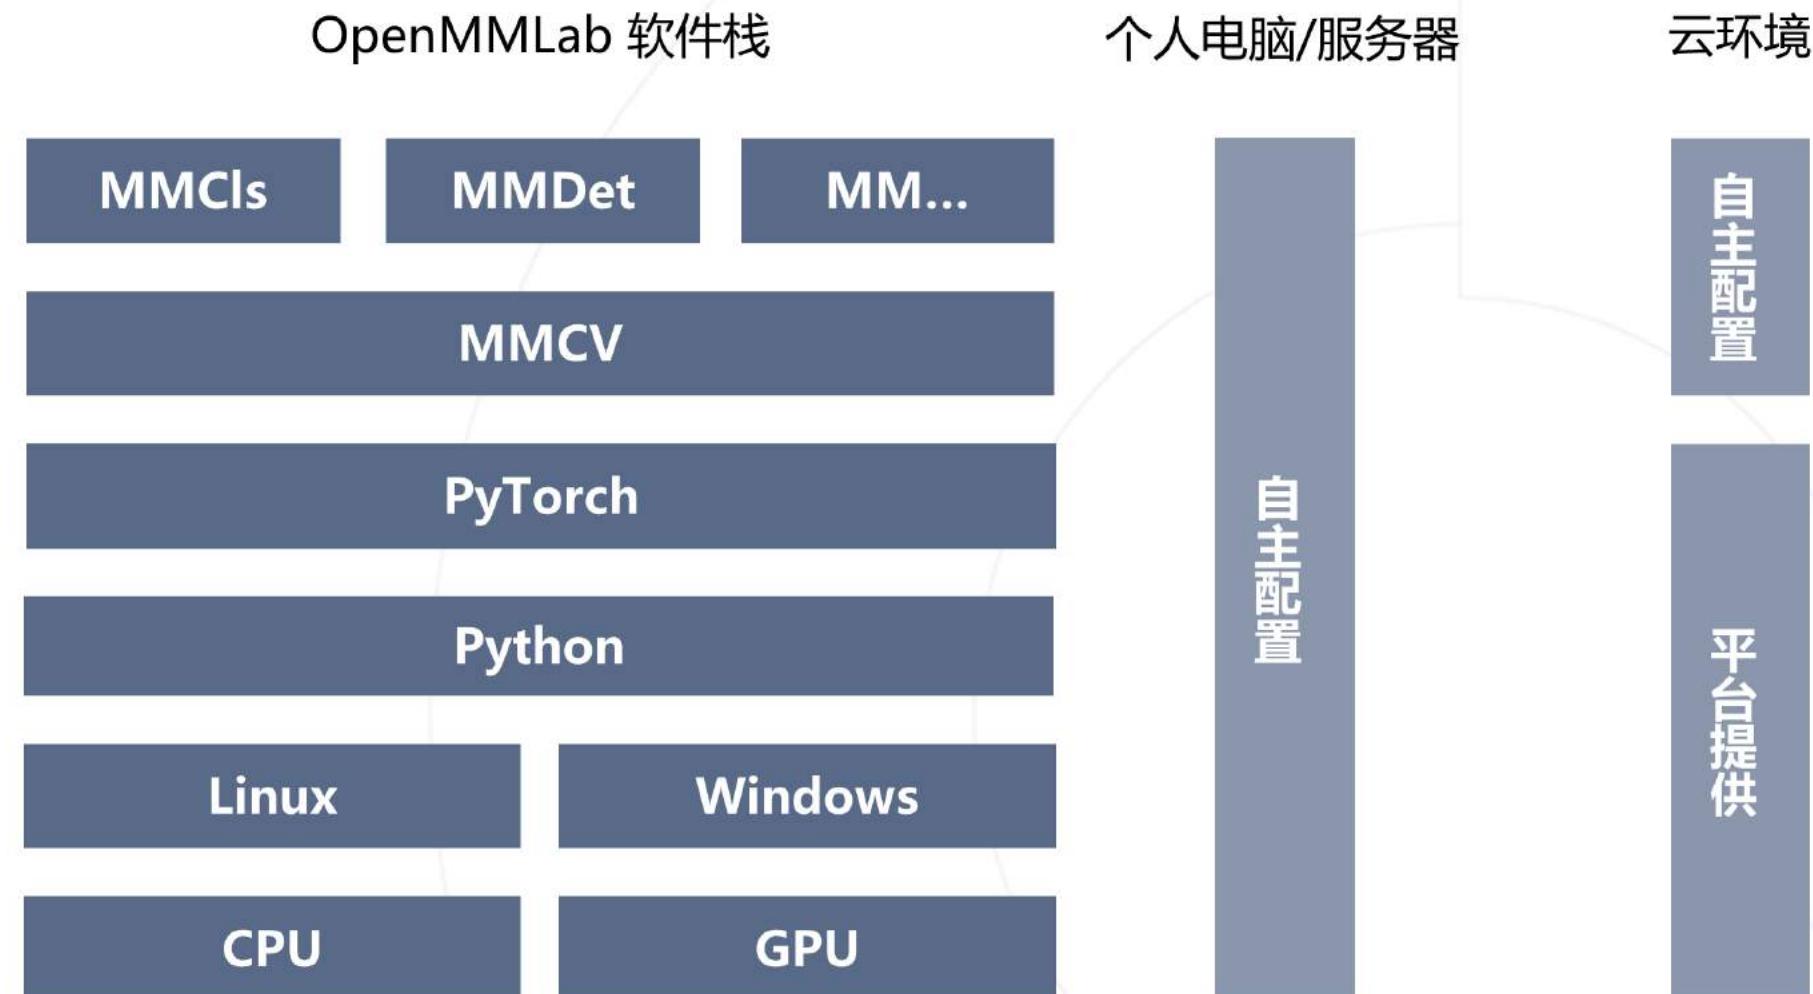
MMClassification

谢谢大家

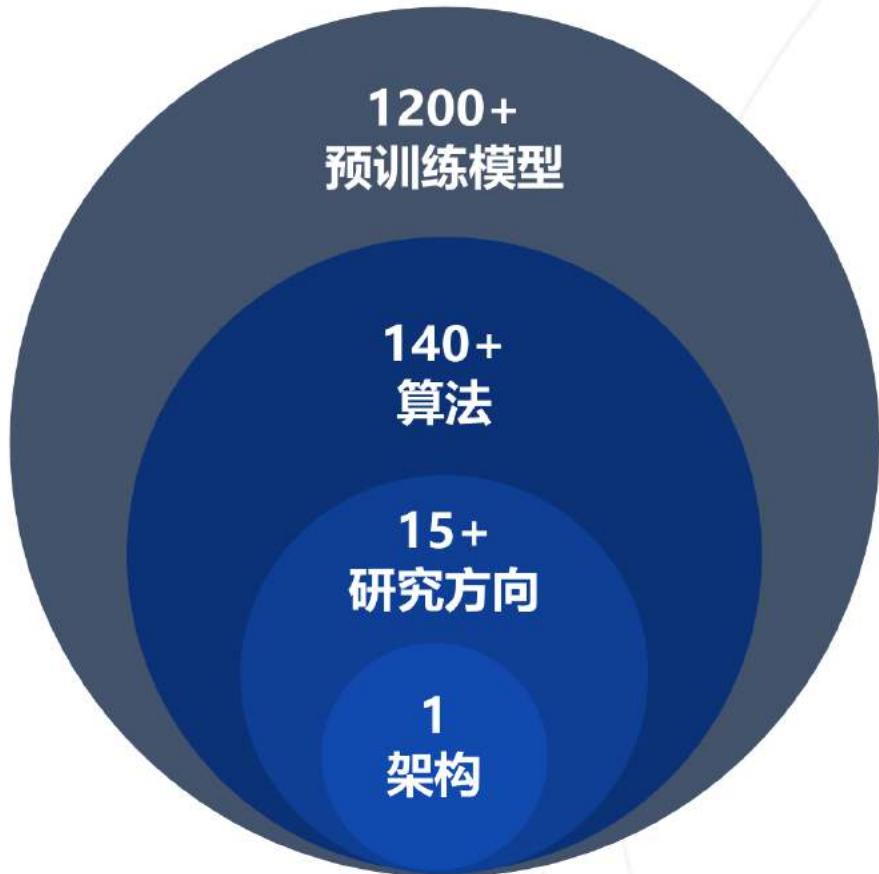
通用视觉框架OpenMMLab 实践2 MMClassification

王若晖
2021年4月

- MMClassification 运行环境搭建
- 使用预训练模型完成图像分类
- 训练自己的图像分类模型



- MMClassification 运行环境搭建
 - Python 和 PyTorch 环境配置（或使用云平台提供的环境）
 - MMCV 安装
 - MMClassification 安装
- 使用预训练模型完成图像分类
 - 配置文件
 - 预训练模型
 - Python API
- 训练自己的图像分类模型
 - 修改配置文件
 - 使用预训练模型



1 架构

- 所有项目基于一致架构开发

15+ 研究方向

- 涵盖多个研究热点方向，算法覆盖完善

140+ 算法

- 包括 140+ 先进算法，性能领先

1200+ 预训练模型

- 拥有超过 1200 个预训练模型，真正实现开箱即用

更多内容可参见 GitHub 上的代码文档以及教程。
如有问题欢迎加入我们的QQ群进行提问。



谢谢大家

MMClassification

MMClassification

丰富的模型

VGG VGG-BN	ResNet ResNet V1D	ResNeXt ShuffleNet	SE-ResNet ShuffleNet V2 MobileNet V2	ResNeSt	ViT
2014	2015	2017	2018	2020	2021

丰富的数据集支持

CIFAR10
ImageNet
.....

丰富的训练
技巧与策略

数据增强策略
优化器和学习率 策略

<https://github.com/open-mmlab/mmclassification>

open-mmlab / mmclassification

Watch 23 Star 577 Fork 163

Code Issues 30 Pull requests 11 Actions Projects Wiki Security ...

master Go to file Add file Code About

	HIT-cwh [Bug]Fix label smooth bug (#203) ...	✓ 4 hours ago	⌚ 242
	.github [Fix] Update pip install mmcv command in ci (#1...)	15 days ago	
	configs [Bug]Fix label smooth bug (#203)	4 hours ago	
	demo Visualize results on image demo (#58)	6 months ago	
	docs Add simplify option in pytorch2onnx.py and Upd...	4 days ago	
	mmcls [Bug]Fix label smooth bug (#203)	4 hours ago	
	requirements bump version to 0.10.0 (#194)	12 days ago	
	resources Add README	9 months ago	

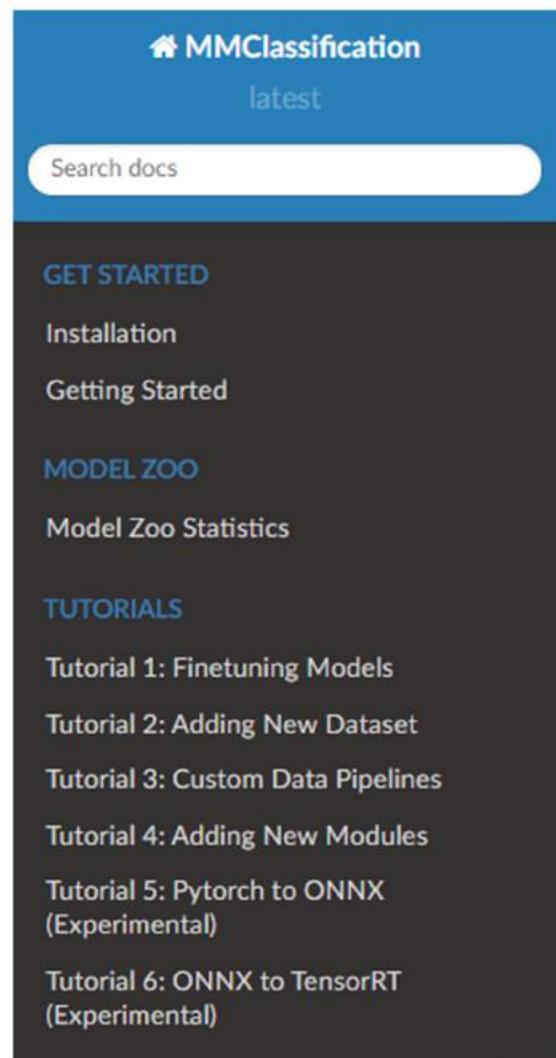
文档链接

[mmclassification.readthedoc...](#)

pytorch imagenet
image-classification resnet
resnext mobilenet
shufflenet senet regnet

Readme
Apache-2.0 License

<https://mmclassification.readthedocs.io/en/latest/>



Docs » Welcome to MMClassification's documentation!

[Edit on GitHub](#)

Welcome to MMClassification's documentation!

Get Started

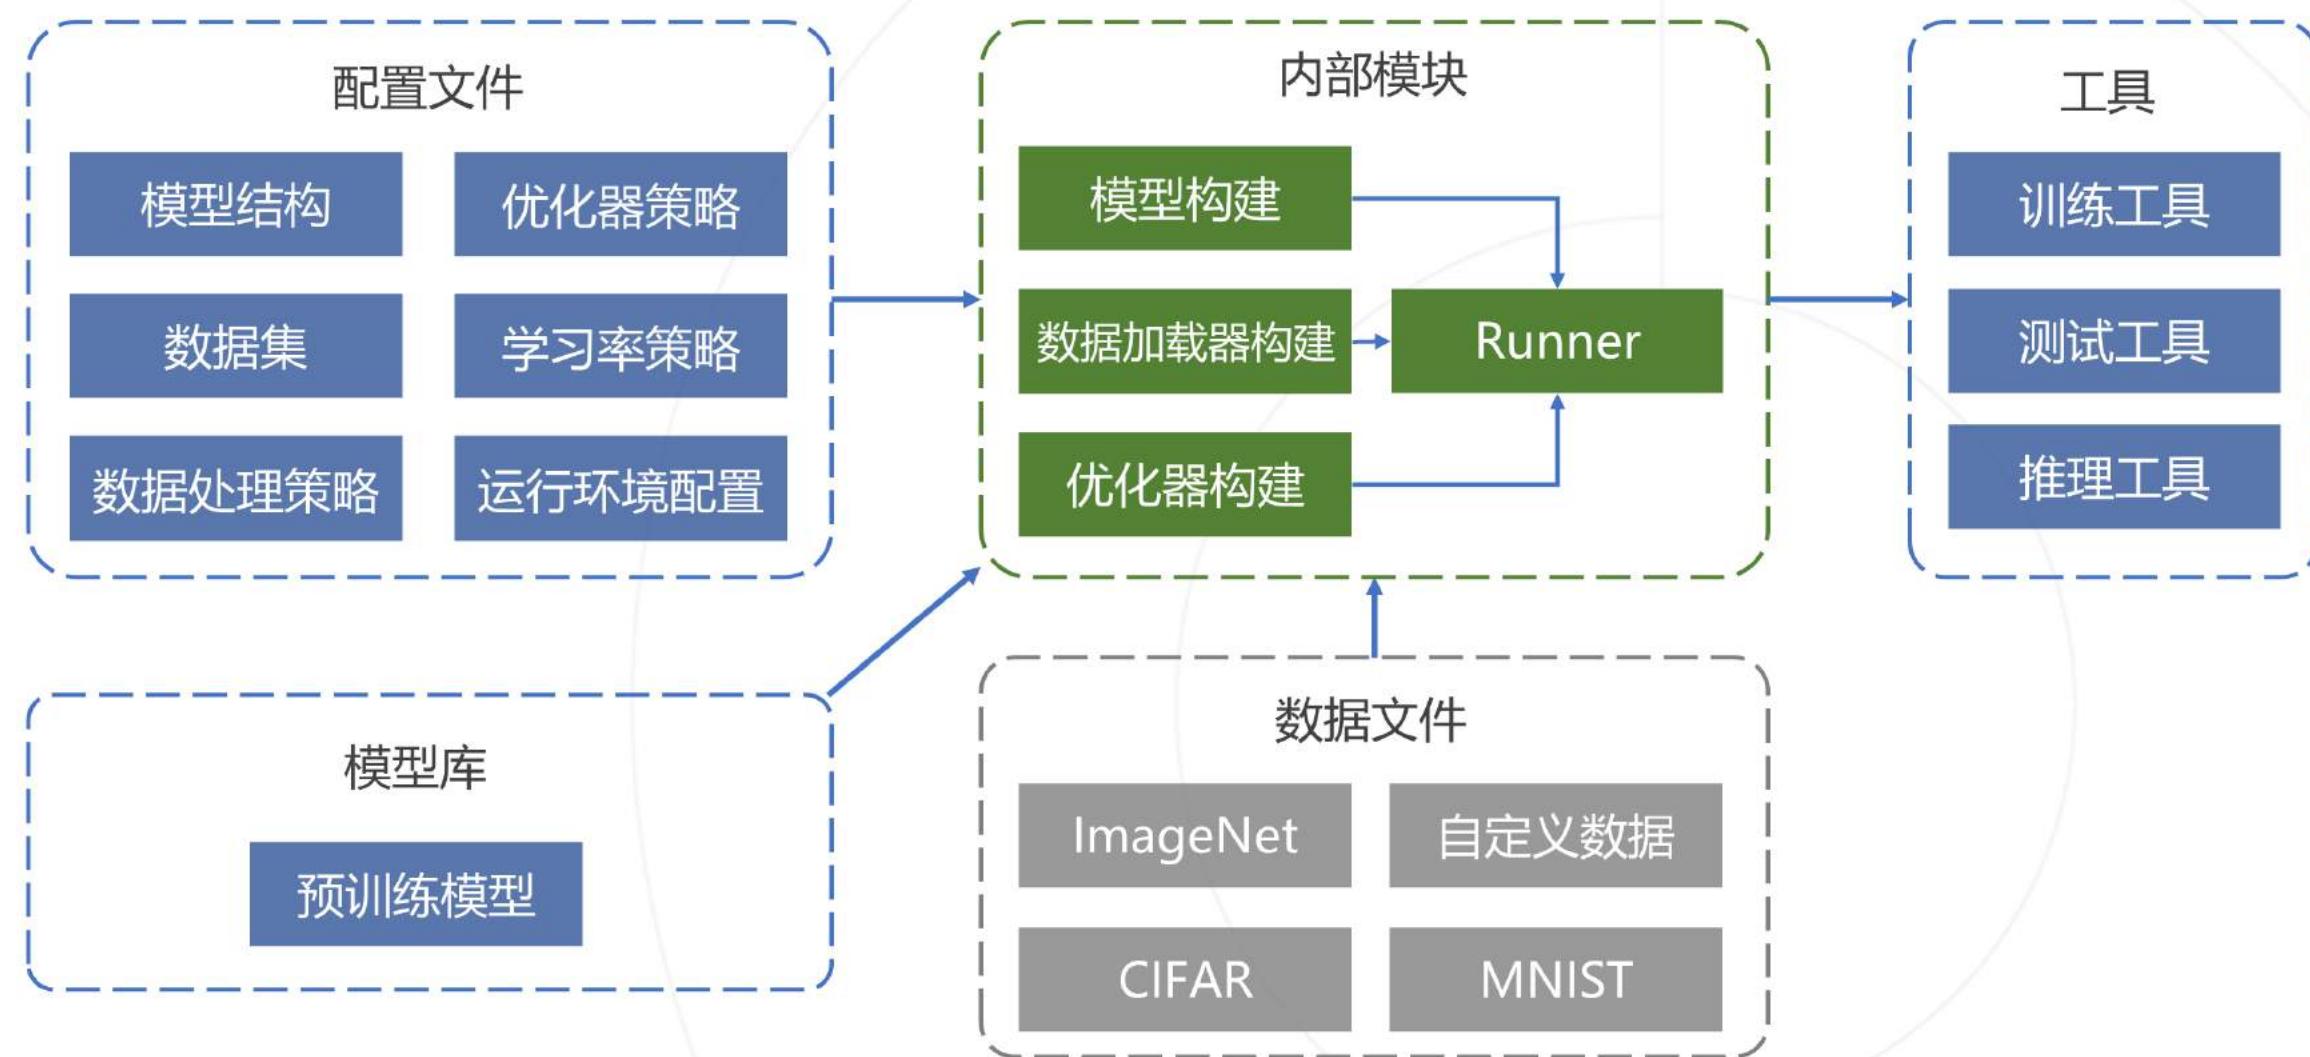
- Installation
 - Requirements
 - Install MMClassification
 - Using multiple MMClassification versions
- Getting Started
 - Prepare datasets
 - Inference with pretrained models
 - Train a model
 - Useful tools
 - Tutorials

安装文档

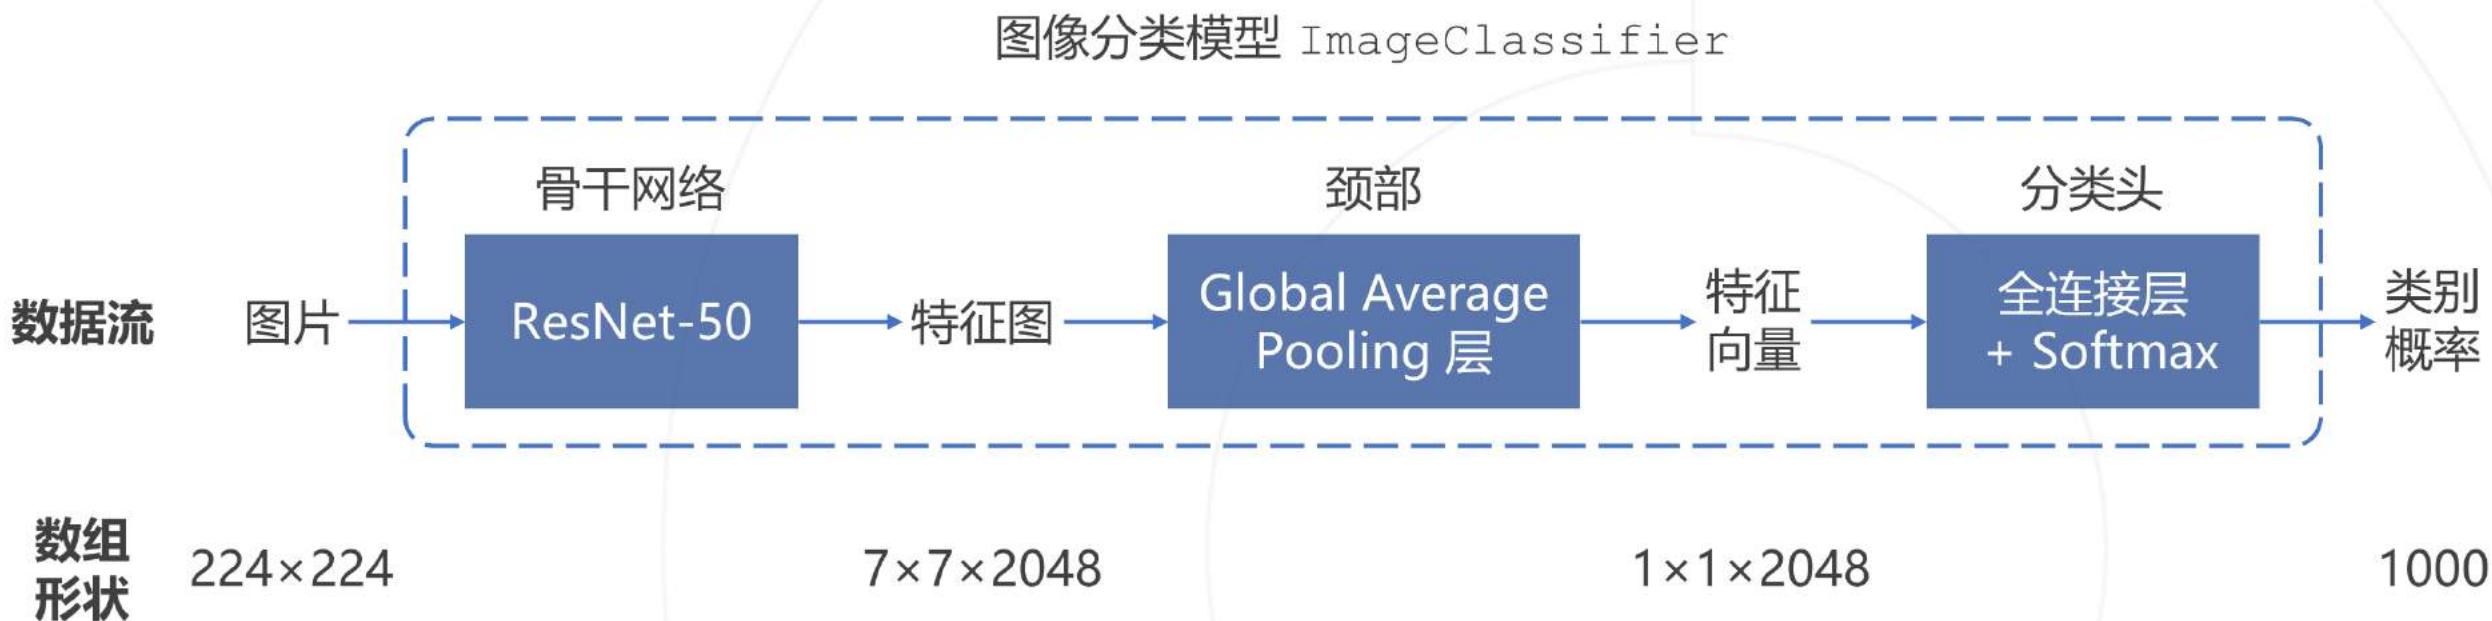
Model zoo

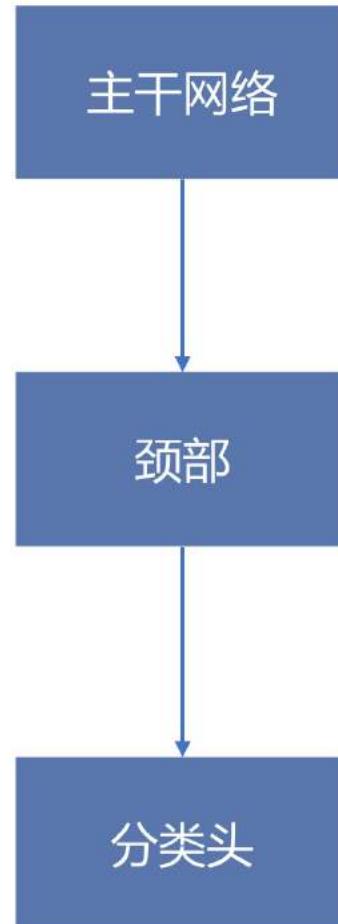
- Model Zoo Statistics

模型库



也适用于其他 OpenMMLab 工具包





主干网络
ResNet 50 模型
使用全部4组卷积层
并输出最后一个卷积层的特征
使用v1b结构变体
全局平均池化 **颈部**
分类头
单层线性分类头
目标类别1000类
输入特征维度2048
使用交叉熵损失函数

模型

```
model = dict(  
    type='ImageClassifier',  
    backbone=dict(  
        type='ResNet',  
        depth=50,  
        num_stages=4,  
        out_indices=(3, ),  
        style='pytorch'),  
    neck=dict(type='GlobalAveragePooling'),  
    head=dict(  
        type='LinearClsHead',  
        num_classes=1000,  
        in_channels=2048,  
        loss=dict(type='CrossEntropyLoss',  
            loss_weight=1.0)),  
)
```

DataLoader

Dataset

数据

设置 batch size

设置数据加载进程数

定义训练数据子集

ImageNet数据积类型

指定数据文件的路径

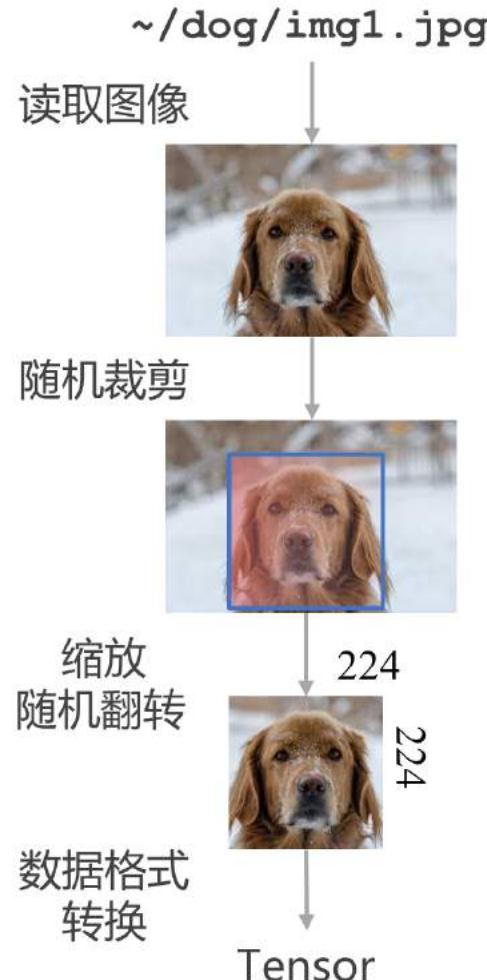
指定数据加载流水线

类似的方式

定义验证子集

和测试子集

```
data = dict(  
    samples_per_gpu=32,  
    workers_per_gpu=2,  
    train=dict(  
        type='ImageNet',  
        data_prefix='data/imagenet/train',  
        pipeline=train_pipeline),  
    val=dict(  
        # similar to train  
    ),  
    test=dict(  
        # similar to val  
    ),  
)
```



像素归一化的均值和标准差

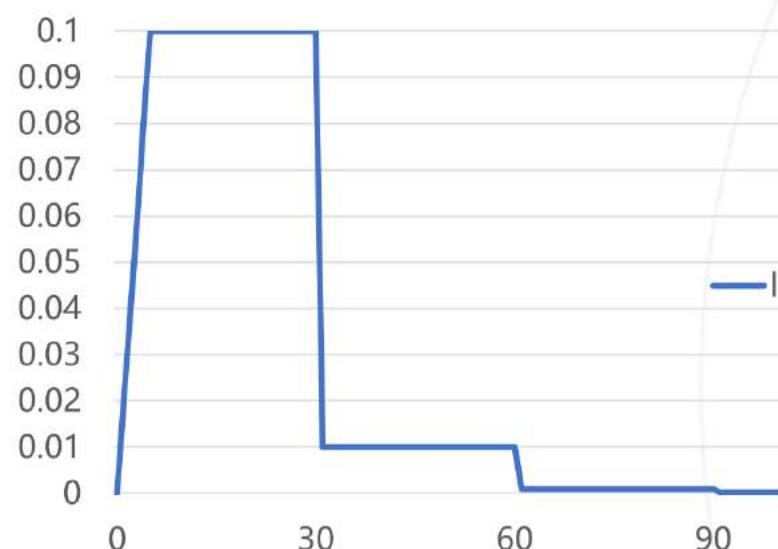
定义数据加载流水线

- 从文件中读取图像
- 随机裁剪与缩放
- 随机水平翻转
- 像素值归一化
- 将数据转换为 PyTorch Tensor

```

img_norm_cfg = dict(
    mean=[123.675, 116.28, 103.53], std=[58.395,
    57.12, 57.375], to_rgb=True)

train_pipeline = [
    dict(type='LoadImageFromFile'),
    dict(type='RandomResizedCrop', size=224),
    dict(type='RandomFlip', flip_prob=0.5,
        direction='horizontal'),
    dict(type='Normalize', **img_norm_cfg),
    dict(type='ImageToTensor', keys=['img']),
    dict(type='ToTensor', keys=['gt_label']),
    dict(type='Collect', keys=['img', 'gt_label'])
]
  
```



优化器配置

使用 SGD 优化器

初始学习率 = 0.1

动量 = 0.9

权重衰减 = 0.0001

学习率策略

使用步长下降策略

在特定周期降低学习率至 1/10

使用线性 warmup 策略

5个周期的 warmup

运行器 Runner 设置

基于轮数的运行器

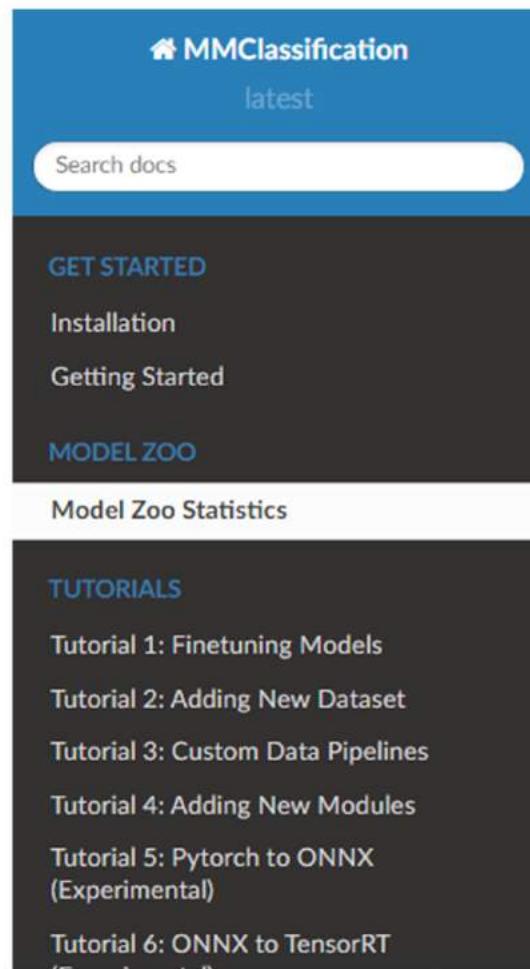
最多训练 100 轮

```
optimizer = dict(  
    type='SGD',  
    lr=0.1,  
    momentum=0.9,  
    weight_decay=0.0001)
```

```
lr_config = dict(  
    policy='step',  
    step=[30, 60, 90],  
    by_epoch=True,  
    warmup='Linear',  
    warmup_iters=5  
)
```

```
runner = dict(  
    type='EpochBasedRunner',  
    max_epochs=100  
)
```

https://mmclassification.readthedocs.io/en/latest/modelzoo_statistics.html



Docs » Model Zoo Statistics

Edit on GitHub

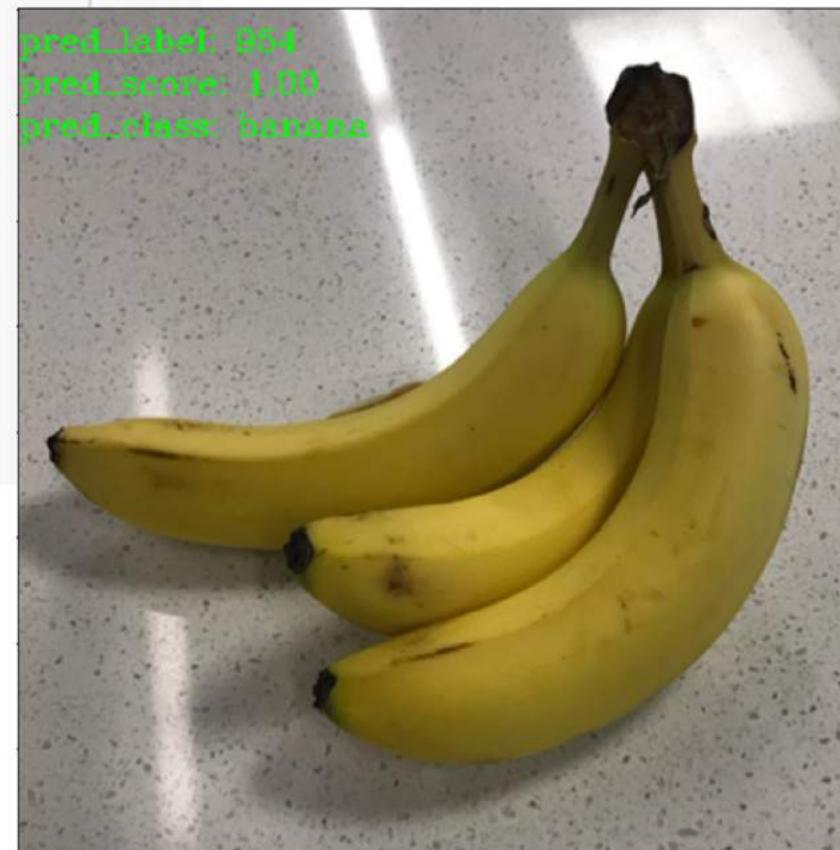
Model Zoo Statistics

- Number of papers: 8
 - ALGORITHM: 7
 - OTHERS: 1
- Number of checkpoints: 31
 - [OTHERS] Mixed Precision Training (1 ckpts)
 - [ALGORITHM] MobileNetV2: Inverted Residuals and Linear Bottlenecks (1 ckpts)
 - [ALGORITHM] Deep Residual Learning for Image Recognition (13 ckpts)
 - [ALGORITHM] Aggregated Residual Transformations for Deep Neural Networks (4 ckpts)
 - [ALGORITHM] Squeeze-and-Excitation Networks (2 ckpts)
 - [ALGORITHM] ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices (1 ckpts)
 - [ALGORITHM] Shufflenet v2: Practical guidelines for efficient cnn architecture design (1 ckpts)
 - [ALGORITHM] Very Deep Convolutional Networks for Large-Scale Image Recognition (8 ckpts)

```
from mmcls.apis import inference_model, init_model, show_result_pyplot

# Specify the path to config file and checkpoint file
config_file = 'configs/mobilenet_v2/mobilenet_v2_b32x8_imagenet.py'
checkpoint_file = 'checkpoints/mobilenet_v2_batch256_imagenet_20200708-3b2dc3af.pth'
# Specify the device. You may also use cpu by `device='cpu'`.
device = 'cuda:0'
# Build the model from a config file and a checkpoint file
model = init_model(config_file, checkpoint_file, device=device)
# Test a single image
img = 'demo/banana.png'
result = inference_model(model, img)
# Show the results
show_result_pyplot(model, img, result)
```

```
{'pred_class': 'banana',
 'pred_label': 954,
 'pred_score': 0.9999284744262695}
```



单张图像推理

```
python demo/image_demo.py ${IMAGE_FILE} ${CONFIG_FILE} ${CHECKPOINT_FILE}
```

整个数据集推理

- 单机单卡

```
python tools/inference.py ${CONFIG_FILE} ${CHECKPOINT_FILE} [--out ${RESULT_FILE}]
```

- 分布式推理

```
./tools/dist_inference.sh ${CONFIG_FILE} ${CHECKPOINT_FILE} ${GPU_NUM} [--out ${RESULT_FILE}]
```

举例：

假设预训练模型已经存放至checkpoints文件夹，基于ResNet50推理ImageNet的验证集的示例如下：

```
python tools/inference.py configs/imagenet/resnet50_batch256.py checkpoints/xxx.pth
```

单卡训练

```
python tools/train.py ${CONFIG_FILE} [optional arguments]
```

分布式训练

```
./tools/dist_train.sh ${CONFIG_FILE} ${GPU_NUM} [optional arguments]
```

支持任务调度器 Slurm

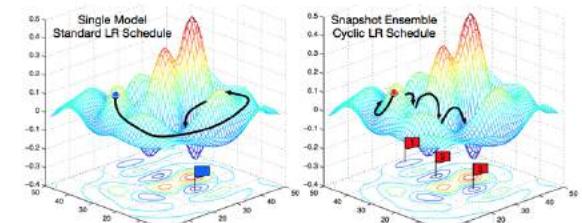
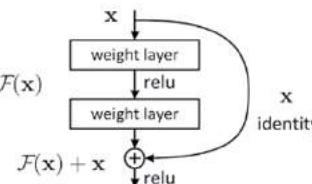
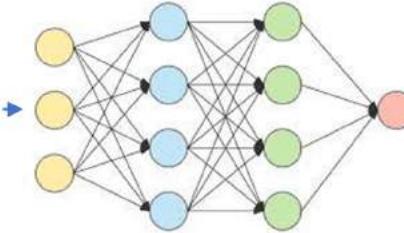
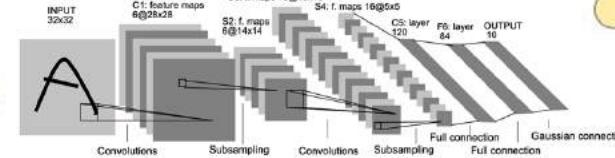
在通过slurm管理的集群上训练，可以使用slurm_train.sh脚本：

```
[GPUS=${GPUS}] ./tools/slurm_train.sh ${PARTITION} ${JOB_NAME} ${CONFIG_FILE} ${WORK_DIR}
```

- 机器学习视角下的图像分类
- 多层感知机
- 卷积神经网络
- 图像分类模型设计**
- 图像分类模型训练
- PyTorch 介绍
- MMClassification 图像分类框架

$$\mathcal{H} = \{h(x; \theta) \mid \theta \in \Theta\}$$

$$h^* = \underset{h \in \mathcal{H}}{\operatorname{argmin}} \mathcal{L}(h | \mathcal{D})$$



PYTORCH

MMClassification